

**UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
MESTRADO PROFISSIONALIZANTE EM ENGENHARIA**

**PREVISÃO DE RECEITAS TRIBUTÁRIAS – O CASO DO ICMS NO
ESTADO DO PARANÁ**

Marlon Jorge Liebel

**Porto Alegre
2004**

**UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
MESTRADO PROFISSIONALIZANTE EM ENGENHARIA**

**PREVISÃO DE RECEITAS TRIBUTÁRIAS – O CASO DO ICMS NO ESTADO DO
PARANÁ**

Marlon Jorge Liebel

Orientador: Professor Flávio Sanson Fogliatto, *Ph.D.*

Banca Examinadora:

Prof. Dr. Antônio Carlos Gastaud Maçada

Prof. Dr. Guilherme Luís Roche Vaccaro

Prof. Dr. Lorí Viali

**Trabalho de Conclusão do Curso de Mestrado Profissionalizante em Engenharia como
requisito parcial à obtenção do título de Mestre em Engenharia – modalidade
Profissionalizante – Ênfase Qualidade e Desenvolvimento do Processo e do Produto**

**Porto Alegre
2004**

Este Trabalho de Conclusão foi analisado e julgado adequado para a obtenção do título de mestre em ENGENHARIA e aprovada em sua forma final pelo orientador e pelo coordenador do Mestrado Profissionalizante em Engenharia, Escola de Engenharia, Universidade Federal do Rio Grande do Sul.

Prof. Flávio Sanson Fogliatto, *Ph.D.*

Orientador
Escola de Engenharia
Universidade Federal do Rio Grande do Sul

Prof^a. Helena Beatriz Bettella Cybis, *Ph.D.*

Coordenadora
Mestrado Profissionalizante em Engenharia
Escola de Engenharia
Universidade Federal do Rio Grande do Sul

BANCA EXAMINADORA

Prof. Dr. Antônio Carlos Gastaud Maçada
PPGA/UFRGS

Prof. Dr. Guilherme Luís Roehe Vaccaro
FAMAT/PUC-RS

Prof. Dr. Lorí Viali
FAMAT/PUC-RS

A meus pais, Marcos (*in memoriam*) e Odivéte, responsáveis pela minha educação e incansáveis ao estimular a busca do conhecimento, dos valores morais e da realização pessoal.

A minha esposa, Soemis, cuja dedicação, compreensão e apoio têm sido fundamentais para meu crescimento pessoal e profissional.

AGRADECIMENTOS

Gostaria de expressar os meus agradecimentos àqueles que contribuíram para a realização deste trabalho:

Ao professor Flávio Sanson Fogliatto, por seu profissionalismo ao longo do período de elaboração da dissertação, sua orientação e principalmente por sua paciência.

Aos colegas da Coordenação da Receita do Estado que, direta ou indiretamente, colaboraram com a realização deste trabalho. Especialmente agradeço ao Antônio – Toninho –, pela companhia nas noites de trabalho.

A meus familiares e amigos, pelo incentivo.

A minha mãe e minha esposa, que me apoiaram em todos os momentos nesta caminhada, me incentivaram e me confortaram.

A minha esposa, por ter realizado a revisão final deste trabalho.

A Deus, pelo dom da vida e por permitir que eu alcançasse este objetivo.

SUMÁRIO

LISTA DE FIGURAS	viii
LISTA DE TABELAS.....	x
RESUMO.....	xiii
ABSTRACT	xiv
1 INTRODUÇÃO.....	1
1.1 Tema e justificativa do tema.....	3
1.2 Objetivos.....	5
1.3 Método.....	5
1.4 Estrutura	7
1.5 Limitações do estudo	8
2 REVISÃO BIBLIOGRÁFICA.....	9
2.1 Técnicas de <i>forecasting</i>	9
2.2 Padrões nas séries temporais	10
2.3 Modelos de <i>forecasting</i> quantitativo	11
2.3.1 Regressão Linear	11
2.3.2 Suavização Exponencial Simples	13
2.3.3 Suavização Exponencial - Modelo de Holt	15
2.3.4 Suavização Exponencial - Modelos de Winters	16
2.3.5 Decomposição	18
2.3.6 Modelos de Box-Jenkins	19
2.3.6.1 Séries temporais e processos estocásticos	20
2.3.6.2 Processos estacionários e não-estacionários.....	21
2.3.6.3 Autocorrelação	24
2.3.6.4 Operadores de defasagem e de diferenciação.....	28
2.3.6.5 Modelo de filtro linear.....	29
2.3.6.6 Modelos autoregressivos	30
2.3.6.7 Modelos de média móvel.....	31
2.3.6.8 Modelos mistos autoregressivos e de média móvel.....	32
2.3.6.9 Modelos não-estacionários	33
2.3.6.10 Identificação dos modelos	34

2.3.6.11 Verificação dos modelos	36
2.3.6.12 Resultados obtidos com modelos de Box-Jenkins.....	37
2.4 <i>Forecasting</i> qualitativo.....	37
2.4.1 O método delphi	38
2.4.2 Delphi clássico.....	40
2.4.3 Delphi de políticas.....	42
2.4.4 Delphi de decisão	43
2.4.5 Considerações sobre o método Delphi	44
2.5 Critérios de avaliação e comparação de modelos de <i>forecasting</i>	44
2.6 Desenvolvimentos e aplicações recentes de <i>forecasting</i>	47
3 MÉTODO DE TRABALHO	49
3.1 Coleta de dados.....	52
3.2 Análise dos dados	52
3.2.1 Depuração dos dados	52
3.3 Consolidação da base de dados	53
3.4 Geração da série temporal	53
3.4.1 <i>Forecasting</i> qualitativo.....	53
3.5 Realização da previsão com modelos matemáticos.....	54
3.6 Comparação dos resultados obtidos	54
3.7 Escolha do modelo	54
3.8 Implantação e avaliação periódica do modelo.....	55
3.9 Realização da previsão e análise dos resultados obtidos.....	55
3.9.1 Revisão dos valores de previsão - <i>Forecasting</i> qualitativo	56
4 ESTUDO DE CASO	57
4.1 O Estado do Paraná	57
4.2 Previsão no Estado do Paraná.....	59
4.3 Coleta de dados.....	63
4.4 Análise dos dados	64
4.4.1 Depuração dos dados.....	65
4.5 Consolidação da base de dados	68
4.6 Geração das séries temporais.....	68
4.7 Realização da previsão com modelos matemáticos.....	68
4.7.1 Regressão Linear	70
4.7.2 Suavização Exponencial Simples	72

4.7.3 Suavização Exponencial – Holt.....	73
4.7.4 Suavização Exponencial – Winters Multiplicativo	75
4.7.5 Suavização Exponencial – Winters Aditivo	76
4.7.6 Decomposição	77
4.7.7 Modelos de box-jenkins	80
4.7.7.1 Série 72.....	80
4.7.7.2 Série 36.....	84
4.8 Comparação dos resultados obtidos	86
4.9 Escolha do modelo	89
4.10 Implantação e avaliação periódica do modelo.....	89
4.11 Realização da previsão e análise dos resultados obtidos.....	89
4.11.1 Revisão dos valores de previsão - <i>Forecasting</i> qualitativo	96
5 CONCLUSÃO.....	98
5.1 Sugestões para trabalhos futuros	100
REFERÊNCIAS BIBLIOGRÁFICAS	101
ANEXO A – Previsão para o exercício 2003 – Resultados da série 72	110
ANEXO B – Previsão para o exercício 2003 – Resultados da série 36	113
ANEXO C – Previsão para o exercício 2004 – Resultados da série 84	116
ANEXO D – Previsão para o exercício 2004 – Resultados da série 48	119

LISTA DE FIGURAS

Figura 1 - Padrões de séries temporais	11
Figura 2 - Série temporal de ruído aleatório.....	22
Figura 3 - Série temporal com ruído autocorrelacionado - estacionária.....	22
Figura 4 - Série temporal não-estacionária.....	23
Figura 5 - Série temporal da viscosidade medida em um processo tipo batelada	26
Figura 6 - Gráfico da função autocorrelação da série temporal de dados de viscosidade.....	27
Figura 7 - Execução de pesquisa - Método Delphi.....	39
Figura 8 - Seleção de um modelo de previsão.....	46
Figura 9 - Sequência para previsão da receita	51
Figura 10 - Gráfico dos dados de ICMS 100% após subtração da média - 1997 a 2003	65
Figura 11 - Gráfico dos dados de ICMS 100% após subtração da média e tratamento dos dados- 1997 a 2003.....	67
Figura 12 - Gráfico da Série 72	69
Figura 13 - Gráfico da Série 36	70
Figura 14 - Gráfico da Regressão Linear Simples - Série 72	71
Figura 15 - Gráfico da Regressão Linear Simples - Série 36	71
Figura 16 - Gráfico da Suavização Exponencial Simples - Série 72.....	72
Figura 17 - Gráfico da Suavização Exponencial Simples - Série 36.....	73
Figura 18 - Gráfico da Suavização Exponencial de Holt - Série 72.....	74
Figura 19 - Gráfico da Suavização Exponencial de Holt - Série 36.....	74
Figura 20 - Gráfico da Suavização Exponencial de Winters multiplicativo - Série 72.....	75
Figura 21 - Gráfico da Suavização Exponencial de Winters multiplicativo - Série 36.....	76
Figura 22 - Gráfico da Suavização Exponencial de Winters aditivo - Série 72	76
Figura 23 - Gráfico da Suavização Exponencial de Winters aditivo - Série 36	77
Figura 24 - Gráfico dos padrões da Série 72	78
Figura 25 - Gráfico da Decomposição da Série 72.....	79
Figura 26 - Gráfico da Decomposição da Série 36.....	79
Figura 27 - Gráfico da Função de Autocorrelação da Série 72	80
Figura 28 - Gráfico da Função de Autocorrelação Parcial da Série 72	81
Figura 29 - Série gerada após a diferenciação de primeira ordem da Série 72	81

Figura 30 - Gráfico da Função de Autocorrelação da Série 72 após a diferenciação de primeira ordem.....	82
Figura 31 - Gráfico da Função de Autocorrelação Parcial da Série 72 após a diferenciação de primeira ordem	82
Figura 32 - Gráfico do modelo SARIMA $(1,1,0) \times (2,0,1)_{12}$ - Série 72.....	84
Figura 33 - Gráfico da Função de Autocorrelação da Série 36 após a diferenciação de primeira ordem.....	85
Figura 34 - Gráfico da Função de Autocorrelação Parcial da Série 36 após a diferenciação de primeira ordem	85
Figura 35 - Gráfico do modelo SARIMA $(1,1,0) \times (1,0,1)_{12}$ - Série 36	86
Figura 36 - Gráfico da Série 84	91
Figura 37 - Gráfico da Série 48	91
Figura 38 - Gráfico da Suavização Exponencial de Winters aditivo - Série 84	94
Figura 39 - Gráfico da Suavização Exponencial de Winters multiplicativo - Série 48.....	94
Figura 40 - Gráfico da Suavização Exponencial de Holt - Série 48.....	95

LISTA DE TABELAS

Tabela 1 - Livros de <i>forecasting</i> publicados por ano	4
Tabela 2 - Livros de <i>forecasting</i> - Comparação com o total de livros publicados	5
Tabela 3 - Passos para aplicação do Método de PO	6
Tabela 4 - Série temporal de dados de viscosidade	26
Tabela 5 - Coeficiente de autocorrelação r_k da série de dados de viscosidade	27
Tabela 6 - Propriedades das FAC e FACP para modelos ARIMA	35
Tabela 7 - Propriedades das FAC e FACP para modelos SARIMA	36
Tabela 8 - Características do Delphi Clássico, do Delphi de Políticas e do Delphi de Decisão	41
Tabela 9 - Evolução nominal do PIB/PR em R\$ milhões	57
Tabela 10 - Evolução nominal do ICMS 100% em R\$ milhões	58
Tabela 11 - Arrecadação de ICMS 100% no Paraná em R\$ milhões - 1997 a 2003	63
Tabela 12 - Arrecadação de ICMS 100% no Paraná em R\$ milhões após depuração - 1997 a 2003	67
Tabela 13 - Resultado dos modelos SARIMA - Série 72	83
Tabela 14 - Resultado dos modelos SARIMA - Série 36	86
Tabela 15 - Comparação de modelos - Série 72	87
Tabela 16 - Comparação de modelos - Série 36	88
Tabela 17 - Arrecadação de ICMS 100% no Paraná em R\$ milhões - 2004	90
Tabela 18 - Arrecadação de ICMS 100% no Paraná em R\$ milhões após depuração - 2004	90
Tabela 19 - Comparação de modelos - Série 84	92
Tabela 20 - Comparação de modelos - Série 48	92
Tabela 21 - Comparação da arrecadação realizada em 2004 após a depuração e sua previsão pelo modelo de Winters aditivo - Série 84 - Em R\$ milhões	93
Tabela 22 - Comparação da arrecadação realizada em 2004 após a depuração e sua previsão pelo modelo de Winters multiplicativo - Série 48 - Em R\$ milhões	95
Tabela A-1 - Série 72 - Modelo de Regressão Linear	110
Tabela A-2 - Série 72 - Modelo de Suavização Exponencial Simples	110
Tabela A-3 - Série 72 - Modelo de Suavização Exponencial de Holt	110
Tabela A-4 - Série 72 - Modelo de Suavização Exponencial de Winters Multiplicativo	110
Tabela A-5 - Série 72 - Modelo de Suavização Exponencial de Winters Aditivo	111
Tabela A-6 - Série 72 - Modelo de Decomposição	111
Tabela A-7 - Série 72 - Modelo SARIMA $(1,1,0) \times (0,0,1)_{12}$	111
Tabela A-8 - Série 72 - Modelo SARIMA $(1,1,0) \times (0,0,2)_{12}$	111

Tabela A-9 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,0)_{12}$	111
Tabela A-10 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,1)_{12}$	111
Tabela A-11 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,2)_{12}$	112
Tabela A-12 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,0)_{12}$	112
Tabela A-13 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,1)_{12}$	112
Tabela A-14 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,2)_{12}$	112
Tabela B-1 - Série 72 - Modelo de Regressão Linear	113
Tabela B-2 - Série 72 - Modelo de Suavização Exponencial Simples	113
Tabela B-3 - Série 72 - Modelo de Suavização Exponencial de Holt	113
Tabela B-4 - Série 72 - Modelo de Suavização Exponencial de Winters Multiplicativo.....	113
Tabela B-5 - Série 72 - Modelo de Suavização Exponencial de Winters Aditivo	114
Tabela B-6 - Série 72 - Modelo de Decomposição	114
Tabela B-7 - Série 72 - Modelo SARIMA $(1,1,0) \times (0,0,1)_{12}$	114
Tabela B-8 - Série 72 - Modelo SARIMA $(1,1,0) \times (0,0,2)_{12}$	114
Tabela B-9 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,0)_{12}$	114
Tabela B-10 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,1)_{12}$	114
Tabela B-11 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,2)_{12}$	115
Tabela B-12 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,0)_{12}$	115
Tabela B-13 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,1)_{12}$	115
Tabela B-14 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,2)_{12}$	115
Tabela C-1 - Série 72 - Modelo de Regressão Linear	116
Tabela C-2 - Série 72 - Modelo de Suavização Exponencial Simples	116
Tabela C-3 - Série 72 - Modelo de Suavização Exponencial de Holt	116
Tabela C-4 - Série 72 - Modelo de Suavização Exponencial de Winters Multiplicativo.....	116
Tabela C-5 - Série 72 - Modelo de Suavização Exponencial de Winters Aditivo	116
Tabela C-6 - Série 72 - Modelo de Decomposição	116
Tabela C-7 - Série 72 - Modelo SARIMA $(1,1,0) \times (0,0,1)_{12}$	117
Tabela C-8 - Série 72 - Modelo SARIMA $(1,1,0) \times (0,0,2)_{12}$	117
Tabela C-9 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,0)_{12}$	117
Tabela C-10 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,1)_{12}$	117
Tabela C-11 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,2)_{12}$	117
Tabela C-12 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,0)_{12}$	117
Tabela C-13 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,1)_{12}$	118
Tabela C-14 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,2)_{12}$	118

Tabela D-1 - Série 72 - Modelo de Regressão Linear	119
Tabela D-2 - Série 72 - Modelo de Suavização Exponencial Simples.....	119
Tabela D-3 - Série 72 - Modelo de Suavização Exponencial de Holt.....	119
Tabela D-4 - Série 72 - Modelo de Suavização Exponencial de Winters Multiplicativo	119
Tabela D-5 - Série 72 - Modelo de Suavização Exponencial de Winters Aditivo	119
Tabela D-6 - Série 72 - Modelo de Decomposição	119
Tabela D-7 - Série 72 - Modelo SARIMA $(1,1,0) \times (0,0,1)_{12}$	120
Tabela D-8 - Série 72 - Modelo SARIMA $(1,1,0) \times (0,0,2)_{12}$	120
Tabela D-9 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,0)_{12}$	120
Tabela D-10 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,1)_{12}$	120
Tabela D-11 - Série 72 - Modelo SARIMA $(1,1,0) \times (1,0,2)_{12}$	120
Tabela D-12 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,0)_{12}$	120
Tabela D-13 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,1)_{12}$	121
Tabela D-14 - Série 72 - Modelo SARIMA $(1,1,0) \times (2,0,2)_{12}$	121

RESUMO

Esta dissertação apresenta um estudo sobre a aplicação de técnicas de previsão na arrecadação tributária. Buscou-se a aplicação das principais técnicas quantitativas de previsão a uma série temporal de arrecadação de ICMS – Imposto sobre operações relativas à circulação de mercadorias e sobre prestações de serviços de transporte interestadual, intermunicipal e de comunicação. Além disto, procurou-se estimular a discussão sobre a utilização de técnicas de previsão qualitativas como forma de melhorar a acurácia dos resultados obtidos com os modelos estatísticos de previsão. O método de trabalho proposto apresenta uma seqüência estruturada de passos para a realização da previsão de receitas tributárias. Baseado neste método de trabalho e no referencial teórico, realizou-se um estudo de caso a partir dos dados de arrecadação de ICMS no Estado do Paraná. Os modelos de previsão foram testados com séries de mais de 50 observações – consideradas mais adequadas para utilização da maioria dos modelos estatísticos – e com séries mais curtas, visando comparar o grau de acurácia de cada modelo.

Palavras-chave: Previsão, receitas tributárias, ICMS.

ABSTRACT

This thesis presents a study about the use of forecasting techniques on government tax revenue. The use of the main quantitative forecasting techniques on a ICMS (Brazilian state tax) time series was sought. In addition, the work intended to show the relevance of qualitative forecasting techniques as a means to improve the accuracy of the results obtained with the statistical forecasting models. The proposed work method presents a structured sequence of steps for the government tax revenue forecasting. Based on this work method and on the theoretical references, a case study was conducted with the data series of Paraná State ICMS revenue. The forecasting models were tested on series of more than 50 observations – considered more adequate for the use of most statistical models – and on shorter series, in order to compare the accuracy of each model.

Key-words: Forecasting, tax revenue, ICMS.

1 INTRODUÇÃO

O Brasil tem passado por diversas mudanças nas últimas duas décadas. Em 1984, a eleição do presidente Tancredo de Almeida Neves representou a ruptura com o sistema ditatorial militar. A partir de 1994, com o lançamento do Plano Real, a economia tornou-se mais estável e previsível. Contudo, a estabilização da economia e da inflação em patamares por volta de 10% ao ano expôs o problema do déficit das contas públicas.

Em outras palavras, a estabilização da moeda mostrou a precária situação financeiro-tributária da União, Estados e Municípios que, em grande parte, haviam comprometido com despesas, especialmente de pessoal, valores superiores àqueles que efetivamente eram arrecadados, fato esse que os levou ao endividamento interno e externo.

A primeira tentativa de conter as despesas dos governos federal, estaduais e municipais veio através da Lei Complementar 82/95, de 27 de março de 1995, conhecida como Lei Camata, publicada no Diário Oficial da União em 28 de março do mesmo ano. Esta Lei foi importante por ser o primeiro instrumento legislativo a tratar com responsabilidade o tema do déficit fiscal. Porém, carecia de punições aos infratores. Mais tarde, a Lei Camata foi alterada pela Lei Complementar 96/99 de 31 de maio de 1999 para que alguns estados tivessem mais dois anos para implementar medidas de ajuste fiscal.

No dia 04 de maio de 2000, o Congresso Nacional aprovou a Lei Complementar 101/00, que ficou conhecida como Lei de Responsabilidade Fiscal – LRF (Diário Oficial da União, 05/05/2000). Além de reeditar as premissas da Lei Camata, regulamentando e restringindo o gasto dos governos com pessoal, a LRF foi mais detalhada, determinando os percentuais da arrecadação tributária que poderiam ser gastos com cada um dos três poderes – Judiciário, Legislativo e Executivo. Além disso, as punições que não foram inseridas na Lei Camata (porque talvez naquele momento a simples regulamentação do gasto com pessoal já fosse um enorme avanço) aparecem rigorosas na Lei de Responsabilidade Fiscal.

A partir do momento em que a Lei Complementar entrou em vigor os governos passaram a se preocupar com a arrecadação de suas unidades administrativas (União, Estados

e Municípios). Isso se fez necessário graças à objetividade com que a Lei dispõe, em seu art. 73, sobre as consequências para seus infratores, que vão desde a perda do cargo – tornando-se o réu inelegível por 5 anos, quando condenado – até a pena de reclusão de 12 anos.

Para alcançar o tão almejado equilíbrio fiscal, é necessário ter um bom planejamento orçamentário. A peça base do orçamento é a receita orçamentária, ou seja, quanto de dinheiro determinado governo disporá no ano seguinte para pagar os servidores públicos, as amortizações de dívidas e seus juros, e para realizar novas obras.

Tendo em vista o rigor imposto pela LRF, os governantes passaram a exigir de seus técnicos da instituição fazendária previsões mais acuradas das receitas futuras. A própria Lei determina a execução da previsão da receita e seu rigor técnico, em seus artigos 11 e 12 (Lei Complementar 101/00):

Art. 11. Constituem requisitos essenciais da responsabilidade na gestão fiscal a instituição, previsão e efetiva arrecadação de todos os tributos da competência constitucional do ente da Federação.

...

Art. 12. As previsões de receita observarão as normas técnicas e legais, considerarão os efeitos das alterações na legislação, da variação do índice de preços, do crescimento econômico ou de qualquer outro fator relevante e serão acompanhadas de demonstrativo de sua evolução nos últimos três anos, da projeção para os dois seguintes àquele a que se referirem, e da metodologia de cálculo e premissas utilizadas.

Pode-se concluir a importância que os setores de previsão passaram a ter nas decisões estratégicas dos governos. Estas previsões, tal qual são feitas pelas empresas para determinar a previsão de demanda e conseqüentemente a programação da produção, as compras a realizar e onde concentrar os esforços de *marketing*, são (ou deveriam ser) realizadas por todos os níveis de governo (federal, estadual e municipal) para que o Orçamento seja elaborado de forma responsável e sua realização acompanhada e revista a cada dois meses, conforme art. 9.º, da Lei de Responsabilidade Fiscal:

Art. 9.º Se verificado, ao final de um bimestre, que a realização da receita poderá não comportar o cumprimento das metas de resultado primário ou nominal estabelecidas no Anexo de Metas Fiscais, os Poderes e o Ministério Público promoverão, por ato próprio e nos montantes necessários, nos trinta

dias subseqüentes, limitação de empenho e movimentação financeira, segundo os critérios fixados pela lei de diretrizes orçamentárias.

Segundo Elsayed & Boucher (1994), a idéia central que norteia os métodos de *forecasting* é a utilização de dados passados para predizer (isto é, projetar) valores futuros de uma variável de interesse. Partindo deste conceito, poder-se-ia deduzir que, para a realização de qualquer tipo de previsão faz-se necessária a existência de dados prévios.

Entretanto, a disponibilidade de dados históricos é pré-requisito essencial apenas dos métodos quantitativos de *forecasting*. Métodos qualitativos são aqueles que se apóiam na opinião de especialistas para obter previsões. Por opinião entende-se a experiência passada do analista acerca da variável de interesse e considerações de caráter subjetivo. Esse tipo de previsão é utilizada preferencialmente quando não se dispõe de dados prévios, como por exemplo, na previsão de vendas de um produto totalmente novo.

Técnicas quantitativas baseiam-se no estudo de séries temporais. Segundo Makridakis *et al.* (1998), séries temporais são seqüências ordenadas de valores de uma variável, observados em intervalos de tempo igualmente espaçados. Tais seqüências de dados podem ou não apresentar padrões de evolução.

Esta dissertação apresenta um estudo de caso desenvolvido junto à Secretaria de Estado da Fazenda do Estado do Paraná, no intuito de estabelecer qual dos diversos modelos utilizados como métodos quantitativos de *forecasting* melhor se aplica para prever as receitas de ICMS – Imposto sobre operações relativas à circulação de mercadorias e sobre prestações de serviços de transporte interestadual, intermunicipal e de comunicação. Além disso, verificar-se-á de que maneira os métodos qualitativos de *forecasting* podem auxiliar na acurácia da previsão após a utilização dos métodos quantitativos.

1.1 TEMA E JUSTIFICATIVA DO TEMA

O tema deste trabalho é a comparação dos principais modelos de *forecasting* aplicados à previsão de receita gerada por um imposto de competência estadual e distrital, o ICMS. Nesta dissertação a pergunta fundamental para a qual se busca a resposta é: como realizar a previsão de receitas de impostos com mais acurácia.

A realização deste trabalho pode ser justificada, em primeiro lugar, pela não existência de um método de trabalho estruturado para realização de previsão no contexto das receitas tributárias. Tais previsões são instrumento fundamental na tomada de decisão por parte dos gestores públicos, que dependem das receitas dos impostos para desenvolverem seus programas de governo. Uma previsão mais acurada pode permitir a concretização de um orçamento mais realista.

Outra justificativa consistente para esta dissertação são os aspectos legais abordados na seção introdutória. Além disso, tendo em vista que se pretende apresentar um estudo detalhado dos modelos de *forecasting* com vistas à melhoria da acurácia dos resultados das previsões, justifica-se a realização desta dissertação do ponto de vista prático. Zorn (1982) fornece outra justificativa para o estudo do tema proposto quando afirma que a estimação da receita é um elemento primordial no gerenciamento financeiro dos governos.

Ressaltada a relevância prática do tema em seu contexto de aplicação, cabe ainda destacar o crescente interesse acadêmico na área, comprovado por Armstrong (1988) através da análise do número de livros publicados por ano sobre *forecasting*, conforme apresentado na Tabela 1.

Tabela 1: Livros de *forecasting* publicados por ano nos Estados Unidos da América

Período	Livros por ano
1900 – 1939	2
1940 – 1949	7
1950 – 1959	14
1960 – 1969	38
1970 – 1979	223
1980 – 1986	336

Fonte: Adaptado de Armstrong (1988)

O mesmo estudo aponta ainda o crescimento relativo das publicações sobre *forecasting* quando comparada com toda a produção de livros do período, como pode ser observado na Tabela 2.

Com base nos dados apresentados e pelo uso que empresas privadas já fazem dos diferentes modelos de *forecasting*, justifica-se a preocupação em aprofundar o conhecimento nessa área, analisando a sua aplicação no setor público.

Tabela 2: Livros de *forecasting* - Comparação com o total de livros publicados nos Estados Unidos da América

Período	Participação (%)
1900 – 1939	-
1940 – 1949	0,2*
1950 – 1959	0,3
1960 – 1969	0,5
1970 – 1979	1,9
1980 – 1986	2,6

* Baseado em interpolação usando o total de livros publicados de 1947 a 1949.
Fonte: Adaptado de Armstrong (1988)

1.2 OBJETIVOS

Esta dissertação tem como objetivo principal a proposição de uma sequência estruturada de passos que permita a escolha de modelos de *forecasting* para receitas tributárias, visando melhorar a acurácia das previsões de arrecadação de ICMS nos estados.

Tem-se por objetivos secundários deste trabalho:

- (i) apresentar modelos de *forecasting* e suas bases teóricas, analisando as vantagens e desvantagens de cada modelo;
- (ii) conhecer o comportamento da arrecadação do ICMS no Estado do Paraná, bem como apresentar o melhor modelo de *forecasting* quantitativo para sua implantação no âmbito da Secretaria de Estado da Fazenda do Paraná;
- (iii) analisar a interferência da quantidade de dados de uma série temporal na acurácia da previsão de valores futuros; e
- (iv) discutir de que forma métodos qualitativos de *forecasting* podem contribuir quando já existem previsões quantitativas para a variável de interesse.

1.3 MÉTODO

A escolha do método de pesquisa, dadas as especificidades deste estudo, recaiu sobre o Método de PO – Pesquisa Operacional. Wagner (1986) define que a análise

quantitativa de um problema de decisão, como o proposto nesta dissertação, deve ser precedida de uma análise qualitativa completa, na qual devem ser identificados os fatores essenciais para a definição do problema, para a construção, solução, validação e implementação do modelo, observando-se ainda que os resultados do modelo proposto devem ter aceitação por parte dos responsáveis pela tomada de decisão.

A Tabela 3 apresenta os passos que devem ser seguidos para utilização do Método de PO (WAGNER, 1986; MAÇADA, 2001).

Tabela 3: Passos para aplicação do Método de PO

Passo	Detalhamento
A – Formulação do Problema	<ul style="list-style-type: none"> - Identificação dos elementos do problema, suas restrições e objetivos. - Determinação dos limites da análise de forma qualitativa.
B – Construção do Modelo	<ul style="list-style-type: none"> - Decisão sobre os dados de entrada. - Projeção das informações de saída. - Identificação de elementos estruturais. - Aplicação de modelos matemáticos.
C – Solução do Modelo	<ul style="list-style-type: none"> - Atribuição de valores para mensuração das variáveis de decisão. - Adequação às condições tecnológicas existentes.
D – Validação do Modelo	<ul style="list-style-type: none"> - Execução de teste de sensibilidade da solução apontada para validar o modelo.
E – Implementação do Resultado e Atualização do Modelo	<ul style="list-style-type: none"> - Orientação e participação da administração no projeto, em seu planejamento e controle. - Percepção, por parte da administração, das vantagens de implantação do projeto e de sua credibilidade. - Repetição do Método de PO com revisão do modelo. - Planejamento da atualização.

Fonte: Adaptado de Wagner (1986) e Maçada (2001)

Maçada (2001) afirma que a sequência de passos não é rígida, mas indica as principais etapas que devem ser vencidas. Para o caso abordado nesta dissertação, a realização da previsão de receitas de impostos, o processo inicia-se a partir da questão de pesquisa apresentada na seção 1.1.

O método de desenvolvimento deste trabalho consta das seguintes etapas:

- Realização inicial de revisão bibliográfica sobre os assuntos que compõem o escopo do tema abordado;

- Coleta de dados e de seu ajuste (eliminação de fatores externos pontuais que afetam a série temporal);
- Avaliação crítica dos modelos de *forecasting* analisados e sua comparação através dos resultados obtidos em uma aplicação prática;
- Considerações finais e recomendações para estudos futuros.

1.4 ESTRUTURA

A presente dissertação está estruturada em cinco capítulos, com conteúdos resumidos na seqüência:

O Capítulo 1 apresenta a contextualização do tema e justificativas para sua escolha, os objetivos que se pretende alcançar, o método de pesquisa e trabalho adotados, a estrutura e as limitações do trabalho.

No Capítulo 2 é feita a revisão bibliográfica do tema central da dissertação, com o objetivo de apresentar a teoria que sustentará as conclusões obtidas na prática. Busca-se apresentar os conceitos e definições relevantes sobre o tema, bem como a análise de exemplos de aplicações dos modelos de *forecasting* estudados.

O Capítulo 3 descreve o método de trabalho proposto, indicando os passos que serão seguidos para sua aplicação.

O Capítulo 4 descreve o cenário do caso em estudo, detalhando suas particularidades, o desenvolvimento do trabalho e os resultados obtidos através do uso de cada modelo, bem como a discussão do estudo de caso, confirmando ou não as hipóteses inicialmente formuladas.

No capítulo 5 analisa-se o atingimento dos objetivos propostos inicialmente, são tecidos os comentários finais, apresentadas as conclusões deste trabalho e as sugestões para trabalhos futuros.

Ao final da dissertação apresenta-se a lista de referências bibliográficas utilizadas e os anexos.

1.5 LIMITAÇÕES DO ESTUDO

Este trabalho foi realizado com a intenção de comparar alguns modelos de *forecasting* entre si indicando a melhor opção em um contexto específico de aplicação, apresentado no estudo de caso. Portanto, não se pretende apresentar um modelo de previsão da receita de ICMS aplicável universalmente, pois isso demandaria conhecimento e acesso a dados das demais unidades da Federação. Entretanto, é razoável que aqueles estados cujo perfil econômico seja similar ao do Paraná possam tomar as conclusões deste trabalho, bem como o modelo indicado, como base para iniciar estudos semelhantes.

Além disso, o estudo analisa um determinado período da arrecadação do estado do Paraná (1997 – 2002). Deve-se considerar que foi um período de relativa estabilidade da economia, cenário que pode variar ao longo dos anos. Análises feitas a partir de outros períodos, podem levar a conclusões diferentes das alcançadas neste trabalho.

A utilização do modelo indicado nesta dissertação deve ser reavaliada em intervalos de tempo pré-definidos, para validá-lo ou recomendar sua substituição. Em outras palavras, não há garantias de que o modelo apresente bons resultados no futuro.

Por fim, deve-se lembrar que a arrecadação de impostos é objeto de leis que, se mudadas, afetam diretamente os resultados aqui apresentados. Com a perspectiva de uma Reforma Tributária nos próximos anos, deve-se enfatizar que as conclusões deste estudo são válidas enquanto permanecer o mesmo conjunto de leis hoje em vigor.

2 REVISÃO BIBLIOGRÁFICA

2.1 TÉCNICAS DE *FORECASTING*

As técnicas de previsão podem ser divididas em duas categorias (ELSAYED & BOUCHER, 1994): técnicas qualitativas e quantitativas.

Técnicas qualitativas (ou de previsão por julgamento) são utilizadas quando existem poucos dados disponíveis. A previsão por julgamento depende de especialistas na área em que se necessita fazer a previsão e suas opiniões tendem a ser a palavra final da previsão. Um caso em que esse tipo de previsão é imprescindível dá-se no lançamento de produtos novos, para os quais não se dispõe de um histórico de vendas.

Técnicas quantitativas são utilizadas quando da existência de um histórico de dados (vendas, produção, receita), ao qual podem ser aplicados diferentes métodos matemáticos com o intuito de extrapolar estes dados e obter os valores futuros prováveis. Existem duas técnicas quantitativas principais (ELSAYED & BOUCHER, 1994): a análise de séries temporais e os modelos estruturais.

A análise de séries temporais compreende modelos com os quais se realizam previsões a partir de seqüências de dados históricos, ou seja, previsões feitas em função do passado. Nos modelos estruturais, a análise é feita a partir das observações de variáveis emparelhadas (STEVENSON, 1981). Assumindo-se que a arrecadação de impostos e o Produto Interno Bruto – PIB de um estado ou país estão relacionados, por exemplo, estas são as variáveis emparelhadas. A partir disto tentar-se-á construir uma equação com as variáveis envolvidas para efetuar as previsões daquela que for considerada a variável dependente, no caso, o valor da arrecadação de impostos. Um modelo estrutural nos moldes deste exemplo foi desenvolvido por Cocco (2000) para previsão da arrecadação de ICMS do Estado do Rio Grande do Sul.

Para Makridakis *et al.* (1998) há ainda uma categoria de eventos aos quais não se aplicam técnicas qualitativas ou quantitativas de *forecasting*. São os eventos imprevisíveis, sobre os quais não existem dados ou informação qualitativa. Desta forma, as previsões seriam desenvolvidas pela apresentação de diversas hipóteses sobre um determinado evento, sendo

impossível a comprovação científica de qualquer uma delas até que o evento venha a se confirmar. Desta maneira, todas as possibilidades devem ser consideradas, ainda que tenham sido previstas sem qualquer teoria que as apóie.

2.2 PADRÕES NAS SÉRIES TEMPORAIS

Krajewski & Ritzman (1998) apresentam cinco padrões básicos, verificados em observações de séries temporais. Tais padrões podem ser encontrados em diferentes séries temporais, não apenas naquelas que tratam de demanda. Esta hipótese poderá ser verificada especificamente para a série econométrica em análise no estudo de caso apresentado neste trabalho.

Os padrões de séries temporais apontados por Krajewski & Ritzman (1998) são: (i) horizontal/linearidade: é a série temporal na qual ocorre a flutuação dos dados em torno de uma média constante; (ii) tendência: ocorre quando a série temporal apresenta um acréscimo ou decréscimo sistemático em sua média ao longo do tempo; (iii) sazonal: é um padrão de acréscimos e/ou decréscimos que se repete em períodos determinados de tempo da série temporal (podem ser dias, semanas, meses ou estações); (iv) cíclicos: são padrões de acréscimos e/ou decréscimos graduais no valor da média de observações da série temporal em períodos mais longos de tempo (anos ou décadas) e (v) randômico: ocorre quando não se pode prever o comportamento da série temporal.

Os primeiros quatro fatores, representados na Figura 1, podem ser encontrados em combinações diversas, que acabam resultando num padrão identificável e previsível em séries temporais. Já o quinto padrão (randômico) ocorre ao acaso e não pode ser previsto. Quando o padrão randômico ocorrer em uma série com padrões definidos e previsíveis, as observações atípicas podem ser consideradas como decorrentes de causas especiais, necessitando de um estudo mais aprofundado para entender sua ocorrência.

A partir destes padrões, poder-se-ão diferenciar os modelos de *forecasting* quantitativos abordados neste trabalho.




Figura 1: Padrões de séries temporais

2.3 MODELOS DE *FORECASTING* QUANTITATIVO

2.3.1 REGRESSÃO LINEAR

Por estar disponível em softwares como Excel e Quattro Pro, a regressão linear simples é a técnica de *forecasting* mais difundida e utilizada na atualidade (PELLEGRINI, 2000). Uma das finalidades da regressão linear é prever os valores que uma variável poderá assumir no futuro (STEVENSON, 1981).

A equação genérica de regressão linear simples, adaptada ao contexto do *forecasting*, é dada por (MAKRIDAKIS *et al.* 1998):

$$Y_i = \alpha + \beta X_i + \varepsilon_i \quad (1)$$

onde Y_i representa a $i^{\text{ésima}}$ observação da variável Y , X_i representa o $i^{\text{ésimo}}$ valor atribuído à variável independente X , α e β são as constantes de suavização (desconhecidas) e ε_i é uma variável randômica que segue a distribuição normal com média zero e variância σ_ε^2 .

No modelo da equação (1) todos os dados têm pesos iguais, independentemente de serem mais ou menos atuais. A relação desse tipo de regressão é representada por uma reta; conseqüentemente, as previsões são pontos desta reta. Para que sejam feitas extrapolações é necessário que a correlação entre X e Y seja suficientemente forte, garantindo um valor de R^2 próximo de 1.

O R^2 é o coeficiente de determinação, e seu valor pode variar de 0 a 1. Este coeficiente permite medir o ajuste do modelo proposto aos dados amostrais, ou seja, o quanto o modelo adere aos dados. Um coeficiente de determinação igual a 0,85 indica que aproximadamente 85% da variação apresentada pela variável em estudo Y deve-se à variação em X . Valores próximos a zero indicam que a reta proposta não resultará em uma previsão adequada para a série temporal analisada.

O objetivo é estimar os valores de α e β , isto é, determinar os valores a – estimador de α – e b – estimador de β –, que se ajustem à série de dados, ou seja, que minimizem o erro. O erro ε_i é a diferença entre o valor real da variável dependente Y_i e sua estimativa, representada por \hat{Y}_i . De acordo com Stevenson (1981), o método dos mínimos quadrados, ou Média Quadrada dos Erros (MQE), é o mais utilizado para estimar os parâmetros da linha de regressão. Todas as medidas de erro citadas nesta dissertação são apresentadas formalmente na seção 2.3.5.

Pode-se demonstrar que o método dos mínimos quadrados gera as seguintes expressões para estimar α e β , isto é, para determinar a e b :

$$a = \bar{Y} - b\bar{X} \quad (2)$$

$$b = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} \quad (3)$$

onde \bar{Y} é a média dos valores Y_i e \bar{X} é a média dos valores assumidos pela variável independente X_i .

Cirincione *et al.* (1999) aplicaram a regressão linear simples para realizar a previsão da receita não tributária de 6 municípios norte-americanos e obtiveram um erro médio absoluto percentual (EMAP) de 41,4% para previsões mensais. Deve-se ressaltar que o referido estudo utilizou séries de arrecadação de quatro anos e meio, três anos e meio e dois anos e meio anteriores à data do estudo para realizar a modelagem e previsão das receitas um ano e meio à frente. Por similaridade, tendo em vista que o estudo testou 17 modelos de previsão para diferentes quantidades de observações, bem como para diferentes frequências, citam-se nesta dissertação aqueles resultados obtidos com 54 observações (quatro anos e meio) e numa base mensal de previsão.

Para casos que envolvam três ou mais variáveis, pode-se utilizar a regressão linear múltipla, que é simplesmente a extensão do modelo de regressão linear simples para um número maior de variáveis.

O modelo de regressão linear múltipla também possui apenas uma variável dependente, podendo ter duas ou mais variáveis independentes, cada qual com seu respectivo coeficiente de regressão. As equações para o modelo de regressão linear múltipla seguem a mesma lógica de derivação apresentada nas equações (1), (2) e (3).

A variáveis usadas em modelos econométricos são, normalmente, quantitativas. Quando for necessário incluir no modelo uma variável qualitativa, deve-se utilizar variáveis *dummies* (WOOLDRIDGE, 2003). Estas variáveis assumem os valores inteiros 0 ou 1, indicando se uma condição é verdadeira (1) ou falsa (0).

A utilização de variáveis *dummies* pode minimizar a influência de observações atípicas sobre as estimativas dos parâmetros e, desta forma, reduzir o erro de previsão do modelo estimado (COCCARO, 2000). No estudo da receita não tributária dos municípios de Connecticut (CIRINCIONE *et al.*, 1999), os resultados obtidos com essa técnica foram de um EMAP de 32,2% e de 8,3% na previsão do ICMS do Estado do Rio Grande do Sul (COCCARO, 2000).

2.3.2 SUAVIZAÇÃO EXPONENCIAL SIMPLES

O método de suavização exponencial baseia-se em um sistema de médias ponderadas móveis que atribui um peso maior aos dados mais recentes da série temporal

(KRAJEWSKI & RITZMAN, 1998). Os pesos atribuídos aos elementos da série temporal decaem exponencialmente (razão do nome suavização exponencial), do mais recente para o mais antigo (PELLEGRINI & FOGLIATTO, 2002)

O método agrega duas qualidades essenciais em um contexto de previsão de demanda em empresas: é simples e requer poucos dados. Administrativamente isso implica em pouco gasto com treinamento de pessoal para sua utilização e com coleta de dados. Ao contabilizarem-se essas qualidades, conclui-se tratar-se de um método econômico.

Para a utilização da Suavização Exponencial Simples (SES), necessita-se de dados anteriores realizados e previstos, como pode-se observar na equação dada por Moore (1999):

$$F_{t+1} = F_t + \alpha(Y_t - F_t) \quad (4)$$

onde F_t representa a estimativa da série no momento t , Y_t representa o valor da variável Y no momento t , α é uma constante de suavização a ser calculada e F_{t+1} representa a previsão da variável Y para o próximo período.

Pode-se observar que a nova previsão fornecida pela equação (4) é a previsão anterior acrescida de um ajuste do erro verificado. A forma mais comum da equação do método de Suavização Exponencial Simples é a seguinte (GAYNOR & KIRKPATRICK, 1994):

$$F_{t+1} = \alpha Y_t + (1 - \alpha) F_t \quad (5)$$

Pode-se dizer que a previsão para o próximo período é obtida atribuindo-se um peso (α) à observação mais recente e um peso ($1 - \alpha$) a sua respectiva previsão. Assim, a chave para a utilização deste método é a estimação da constante α . De maneira semelhante à utilizada no método da Regressão Linear Simples, busca-se um valor de α que minimize a MQE.

Cirincione *et al.* (1999) obtiveram um EMAP de 42,1% na aplicação deste modelo em uma série temporal de receitas não tributárias.

2.3.3 SUAVIZAÇÃO EXPONENCIAL - MODELO DE HOLT

Holt *apud* Makridakis *et al.* (1998) realizou estudos que permitiram a aplicação de um modelo de suavização exponencial a uma série temporal com padrão de tendência acrescentado à série estacionária. Para tanto, utilizou-se de duas constantes de suavização, α e β (variando entre 0 e 1 e independentes entre si), ou seja:

$$L_t = \alpha Y_t + (1 - \alpha)(L_{t-1} + b_{t-1}) \quad (6)$$

$$b_t = \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1} \quad (7)$$

$$F_{t+m} = L_t + b_t m \quad (8)$$

onde L_t representa a estimativa do nível da série (média) no momento t , b_t representa a estimativa da inclinação da série no momento t , β é a constante de suavização a ser calculada, m representa o número de períodos que constituem o horizonte de previsão e F_{t+m} representa a previsão para m períodos no futuro. Os demais termos são aqueles definidos na equação (4).

A equação (6) ajusta o nível L_t da série diretamente pela tendência verificada no período anterior b_{t-1} , através de sua soma ao último valor suavizado L_{t-1} . Isso traz L_t ao nível aproximado dos dados atuais.

A equação (7) atualiza a tendência da série, que é expressa pela diferença entre os dois últimos valores suavizados. Isso deve ser feito pois, se houver tendência na série, os valores futuros serão maiores ou menores que os atuais, de acordo com o resultado desta operação.

A equação (8) fornecerá as previsões através da substituição dos dados calculados pelas equações (6) e (7). Logo, supõe-se a existência de valores iniciais do nível da série L_t e de sua tendência b_t . A forma mais simples é adotar o último valor observado na série temporal como L_0 e calcular uma média da declividade das últimas observações para b_0 .

Para determinação das constantes de suavização α e β , deve-se utilizar um instrumento de comparação entre os valores previstos e realizados, como a média dos

quadrados dos erros (MQE). Os valores ideais para as constantes de suavização serão aqueles que minimizarem a MQE.

O modelo de Holt foi aplicado por Cirincione *et al.* (1999) na modelagem de uma série temporal de receitas não tributárias com obtenção de um EMAP de 42,6%.

2.3.4 SUAVIZAÇÃO EXPONENCIAL - MODELOS DE WINTERS

Nos modelos de Winters o padrão de sazonalidade é acrescido aos padrões horizontal e de tendência, o que permite presumir serem modelos mais completos do que os vistos anteriormente.

Existem dois tipos de modelo de Winters: o aditivo e o multiplicativo. No modelo multiplicativo a amplitude do ciclo sazonal varia em função do tempo, ou seja, a diferença entre o maior e o menor valor da variável em estudo aumenta ou diminui dependendo das características da série temporal ao longo do tempo. No modelo aditivo verifica-se a constância desta diferença, o que implica em um ciclo sazonal constante (PELLEGRINI, 2000).

As expressões do modelo multiplicativo são apresentadas por Makridakis *et al.* (1998):

$$L_t = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha)(L_{t-1} + b_{t-1}) \quad (9)$$

$$b_t = \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1} \quad (10)$$

$$S_t = \gamma \frac{Y_t}{L_t} + (1 - \gamma)S_{t-s} \quad (11)$$

$$F_{t+m} = (L_t + b_t m)S_{t-s+m} \quad (12)$$

onde S_t representa a estimativa da sazonalidade da série no momento t , γ é a constante de suavização e s é o número de subperíodos do ano (por exemplo s é igual a 4 quando a periodicidade é trimestral). Os demais termos são aqueles definidos nas equações (6), (7) e (8).

Neste modelo, além do cálculo do nível e da tendência da série [equações (9) e (10)], calcula-se o valor da sazonalidade (S_t), representando sua influência na previsão através da equação (11).

A equação (9), usada para calcular o nível da série temporal, passou a integrar o componente sazonalidade. Da mesma forma a equação (12), usada para calcular os valores previstos, teve o mesmo componente inserido em seu cálculo. Apenas a equação (12), de tendência, permaneceu igual ao cálculo realizado para o modelo de Holt [vide equação (7)].

Como ocorre com os demais modelos de suavização exponencial, são necessários valores iniciais para utilização do algoritmo; são eles os valores iniciais do nível da série L_t , da tendência b_t e dos índices de sazonalidade S_t . Para a determinação dos índices de sazonalidade, é necessário pelo menos uma estação completa composta de s períodos no banco de dados a ser modelado.

Para determinação das constantes de suavização α , β e λ , pode-se utilizar a média dos quadrados dos erros (MQE), como mencionado nas seções 2.3.1, 2.3.2 e 2.3.3, ou o erro médio absoluto percentual (EMAP). Os valores ideais para as constantes de suavização serão, da mesma forma, aqueles que minimizarem a MQE ou o EMAP.

O modelo multiplicativo de Winters foi aplicado por Cirincione *et al.* (1999) com o elevado EMAP de 2.549,4%, explicado devido à presença de um dado espúrio na amostra. Em outra aplicação, na previsão de demanda de diversos produtos derivados de carne suína, Pellegrini (2000) obteve melhores resultados, com percentuais de erro que variaram de 4,3% a 16,6%, dependendo do produto analisado.

As expressões do modelo aditivo de Winters são apresentadas por Makridakis *et al.* (1998):

$$L_t = \alpha(Y_t - S_{t-s}) + (1 - \alpha)(L_{t-1} + b_{t-1}) \quad (13)$$

$$b_t = \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1} \quad (14)$$

$$S_t = \gamma(Y_t - L_t) + (1 - \gamma)S_{t-s} \quad (15)$$

$$F_{t+m} = L_t + b_t m + S_{t-s+m} \quad (16)$$

Todos os termos utilizados já foram anteriormente definidos.

Observe-se que a equação (14) é idêntica à equação (10) apresentada no método multiplicativo. Nas demais equações, os índices sazonais passaram a ser adicionados e subtraídos; no modelo anterior tais índices eram fatores de multiplicação e divisão, respectivamente. O início da utilização do algoritmo e a determinação das constantes de suavização α , β e λ ocorrem como descrito para o modelo multiplicativo de Winters.

Melo (2001) obteve um EMAP de 4,0% na previsão de uma série de arrecadação de Imposto de Renda, demonstrando uma boa aproximação do modelo aditivo de Winters aos dados empíricos analisados.

2.3.5 DECOMPOSIÇÃO

O estudo do método da decomposição de séries temporais data do início do séc. XX. Aqui se pressupõe a existência de dois componentes básicos de uma série: o padrão e o erro aleatório.

Os padrões podem ser horizontais, de tendência, sazonais e cíclicos (vide seção 2.2). Como o objetivo da decomposição é modelar as variações das séries temporais, os três últimos padrões citados, bem como o erro aleatório, comporão o modelo matemático, como demonstram Gaynor & Kirkpatrick. (1994):

$$Y_t = f(T_t; S_t; C_t; E_t) \quad (17)$$

onde T_t representa o componente de tendência da série no momento t , S_t o componente sazonal da série no momento t , C_t o componente cíclico da série no momento t e E_t é o componente irregular (ou remanescente) da série no momento t . Os demais termos são aqueles definidos na equação (4).

Os modelos que derivam do método de decomposição podem assumir as formas aditiva e multiplicativa. Suas representações matemáticas são dadas por Gaynor & Kirkpatrick (1994), respectivamente nas equações (18) e (19). Todos os termos utilizados já foram definidos nas equações (4), (9), e (17).

$$Y_t = T_t + S_t + C_t + E_t \quad (18)$$

$$Y_t = T_t S_t C_t E_t \quad (19)$$

A escolha do modelo dependerá da série temporal. O modelo aditivo, representado na equação (18), é mais adequado quando as flutuações sazonais não variam com o nível da série, ou seja, independentemente dos valores obtidos, as variações nominais do efeito sazonal permanecem semelhantes.

Em contrapartida, se ocorre variação na magnitude da sazonalidade em função do nível da série, o modelo multiplicativo [equação (19)] é mais recomendado.

Além dos modelos estudados, pode-se obter outros por transformações matemáticas nas fórmulas apresentadas. Os resultados dos modelos derivados estarão entre aqueles obtidos com o modelo aditivo e com o modelo multiplicativo.

2.3.6 MODELOS DE BOX-JENKINS

Nesta seção far-se-á a apresentação dos modelos Auto Regressivos Integrados à Média Móvel. Tais modelos serão chamados no decorrer desta dissertação de ARIMA, sigla proveniente do inglês *Auto Regressive Integrated Moving Average*.

Os modelos ARIMA foram propostos por George Box (1919 –) e Gwilym Jenkins (1933 – 1982) no início da década de 70, especialmente a sua aplicação à análise de séries temporais e sua previsão. Diferentemente dos modelos de regressão e suavização, que pressupõem observações dependentes de outras variáveis, os modelos ARIMA se ajustam às séries temporais nas quais as observações são fortemente dependentes entre si.

As previsões feitas para as séries temporais em que as observações são dependentes entre si podem não ter a acurácia necessária se utilizados os modelos de regressão ou suavização (MONTGOMERY *et al.*, 1990). Isso ocorre pois tais modelos não fazem uso da dependência existente entre as observações da variável em estudo.

A modelagem ARIMA é composta de três estágios (PANKRATZ, 1983):

- Identificação do modelo: após a análise sobre a estacionariedade da série, os modelos potenciais são escolhidos pela análise dos diagramas da série ou empregando técnicas estatísticas.

- Estimaco do modelo: neste estgio estimam-se os parmetros para os modelos definidos na fase anterior e escolhe-se um deles.

- Teste do modelo: consiste na realizao de testes que apontaro se o modelo escolhido na etapa anterior  efetivamente o mais adequado. Caso este no seja considerado adequado, deve-se reiniciar o procedimento a partir da identificao do modelo. Se adequado, o modelo est pronto para ser aplicado.

A utilizao de um modelo para realizar previses de sries temporais deve ser avaliada continuamente, pois a identificao, estimaco e testes so aplicados a um conjunto de dados em determinado momento. Como os dados futuros podem alterar as caractersticas da srie, recomenda-se a revalidao do modelo a perodos que sejam considerados pelo especialista como suficientes para identificao de mudanas no comportamento da srie temporal estudada.

2.3.6.1 SRIES TEMPORAIS E PROCESSOS ESTOCSTICOS

Sempre que  possvel descrever o comportamento exato de uma srie temporal atravs de modelos matemticos, diz-se que o modelo  determinstico. Exemplos destes modelos so as funes trigonomtricas e quadrticas usadas nos problemas clssicos de Fsica. Nestes problemas, uma varivel dependente (espao, velocidade, acelerao, etc.) pode ser precisamente prevista em funo de uma varivel independente como, por exemplo, o tempo.

Para resoluo simplificada deste tipo de modelo, freqentemente so desconsideradas as variveis externas ao processo, como presso atmosfrica, resistncia do ar ou outros fatores imprevisveis que possam influenciar no resultado do experimento. Esses fatores so denominados fontes de variabilidade e podem afetar o processo de maneira distinta (RIBEIRO, 2000).

A previso dos valores futuros de uma srie temporal geralmente no pode ser obtida atravs de modelos determinsticos, pois estes no consideram a variabilidade existente no processo. A alternativa  realizar a previso destes valores atravs de um clculo de probabilidades. Os modelos matemticos capazes de analisar sistemas probabilsticos so conhecidos como modelos estocsticos.

Um modelo que descreve a estrutura de probabilidade para obtenção de previsão de valores futuros de uma seqüência de observações é chamado de processo estocástico (BOX *et al.*, 1994). Os modelos adequados para séries temporais são designados processos estocásticos, ou seja, processos desenvolvidos de acordo com as leis de probabilidade (MORETTIN & TOLOI, 1985).

No estudo dos modelos de Box-Jenkins, apresentados nas seções seguintes, apenas os processos estocásticos serão utilizados, e doravante serão denominados apenas processos.

2.3.6.2 PROCESSOS ESTACIONÁRIOS E NÃO-ESTACIONÁRIOS

Um processo estocástico é identificado por uma família de variáveis aleatórias que se deseja analisar num espaço de probabilidades (MORETTIN & TOLOI, 1985). Se esta família de variáveis apresenta estimativas de média (\bar{Y}) e variância ($\hat{\sigma}_Y^2$) constantes independentemente da escolha da origem dos tempos, este é dito um processo estacionário (BOX *et al.*, 1994).

A estacionariedade ou não-estacionariedade de uma série temporal pode também ser identificada visualmente, ao analisar-se o gráfico das observações desta série. A série representada na Figura 2 é uma série estacionária, pois suas observações oscilam em torno da média. Trata-se de uma série denominada de ruído aleatório, composta de dois elementos independentes: o nível da série (c) e o erro aleatório (e_t).

O modelo matemático que representa a série estacionária de ruído aleatório é dado por (MAKRIDAKIS *et al.*, 1998):

$$Y_t = c + e_t \quad (20)$$

Não é possível realizar previsões para este tipo de série utilizando as observações anteriores, pois a ordem em que ocorrem não permite que se depreenda qualquer conclusão sobre a série (BOX & LUCENO, 1997).




Figura 2: Série temporal de ruído aleatório - estacionária

A Figura 3 representa uma série estacionária com ruídos autocorrelacionados. Significa que há algum grau de dependência estatística entre as diferenças das observações e a média (nível) da série. Esta dependência pode ser explicada, de maneira simplificada, pelo fato de que diferenças positivas entre as observações da série têm mais probabilidade de serem seguidas por sucessivas diferenças positivas. O mesmo é válido para as diferenças negativas.




Figura 3: Série temporal com ruído autocorrelacionado - estacionária

Fonte: Adaptado de Morettin & Toloí (1986).

A Figura 4 apresenta uma série temporal não-estacionária. Isso implica que seus valores não oscilam de forma aleatória em torno da média.




Figura 4: Série temporal não-estacionária

Fonte: Boletins Informativos da Inspetoria Geral de Arrecadação do Paraná 1997-2002.

As séries temporais com variação não-estacionária são encontradas com frequência em estudos econométricos e em aplicações na indústria e nos negócios (BOX *et al.*, 1994). Séries não-estacionárias homogêneas são aquelas cujo nível e/ou inclinação mudam com o decorrer do tempo mas que, tomando-se um número finito de diferenças d , tornam-se estacionárias (MORETTIN & TOLOI, 1985). Esta dissertação apresentará uma modelagem de séries não-estacionárias homogêneas.

Para aplicação dos modelos de Box-Jenkins faz-se necessário transformar, num primeiro momento, séries não-estacionárias em estacionárias. Para tal, é necessário remover os padrões não-estacionários existentes na série. Um dos métodos utilizados é o das diferenças sucessivas (MORETTIN & TOLOI, 1985), que visa estabilizar a série na média. Sua representação matemática é dada por:

$$Y'_t = Y_t - Y_{t-1} \quad (21)$$

onde Y'_t é o resultado da diferenciação de primeira ordem. A série resultante terá uma observação a menos do que a série original, pois não é possível calcular Y'_1 .

Na maioria dos casos a estacionariedade da série será obtida após a diferenciação de primeira ordem. Se a série resultante ainda não for estacionária, deve-se aplicar a diferenciação de segunda ordem, que consiste na aplicação da equação (21) sobre a nova série:

$$Y_t'' = Y_t' - Y_{t-1}' \quad (22)$$

onde Y_t'' é o resultado da diferenciação de segunda ordem.

Para as séries em que for identificado um padrão de sazonalidade, a diferenciação pode ser feita entre as observações afastadas $t-s$ períodos de tempo, onde s representa o padrão de sazonalidade (3 para trimestral, por exemplo). Assim ter-se-á que:

$$Y_t^* = Y_t - Y_{t-s} \quad (23)$$

onde Y_t^* é o resultado da diferenciação sazonal.

Caso a série temporal não tenha sua estacionariedade assegurada através da diferenciação sazonal, aplicar-se-á então a diferenciação de primeira ordem na série resultante, cuja representação matemática é:

$$Y_t' = Y_t^* - Y_{t-1}^* \quad (24)$$

onde Y_t' é o resultado da diferenciação de primeira ordem aplicada sobre a série resultante da diferenciação sazonal (Y_t^*, Y_{t-1}^*, \dots).

A ordem em que forem aplicadas as diferenciações sazonal e de primeira ordem não afeta o resultado da série obtida ao final do processo (MAKRIDAKIS *et al.*, 1998).

2.3.6.3 AUTOCORRELAÇÃO

O coeficiente de autocorrelação é uma das principais estatísticas na análise de séries temporais. Este coeficiente tem a função de medir como estão relacionadas as observações de uma série temporal afastadas k períodos entre si. Sua fórmula é dada por Montgomery *et al.* (1990):

$$r_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} \quad (25)$$

Desta forma, o valor de r_1 demonstrará a existência ou não de correlação entre as observações sucessivas de Y_t , sendo esta chamada de autocorrelação de defasagem 1. Seguindo este raciocínio, o valor obtido por r_{12} determinará se há ou não relação entre dados afastados 12 períodos de tempo, ou ainda, se há autocorrelação de defasagem 12. Este último coeficiente é de grande utilidade para análise de séries econômicas com observações mensais, pois permite comprovar a existência ou não de sazonalidade na série.

Após a obtenção dos valores do coeficiente de autocorrelação para defasagens de 1, 2, 3 ou mais períodos de tempo, tem-se a série que permite construir a função de autocorrelação – FAC. Ao transportar os valores de r_k para um gráfico pode-se analisar a existência ou não de autocorrelação de defasagem k .

Para a obtenção de uma estimativa útil da FAC são necessárias pelo menos 50 observações na série e os coeficientes devem ser calculados até o máximo de um quarto do número de observações (BOX *et al.*, 1994).

Para testar a existência de autocorrelação de defasagem k utilizando-se o gráfico da FAC, deve-se estabelecer os limites críticos da função. Se o valor de r_k ultrapassar esse limite, há forte indicação de existência de autocorrelação de defasagem k . Os limites com confiança de 95% são $\pm 1,96/\sqrt{n}$, onde n é o número de observações da série. O número 1,96 vem da tabela de probabilidade da Distribuição Normal Padronizada. Este número é freqüentemente arredondado para 2 (MAKRIDAKIS *et al.*, 1998), e este será o valor adotado nesta dissertação por ser o utilizado pelo software NCSS 6.0.

Os gráficos da FAC de uma série estacionária tendem a zero rapidamente, apresentando correlações significativas apenas para defasagens pequenas. No caso de séries não-estacionárias o gráfico da FAC tende a zero lentamente, com diversas correlações significativas. Se a série apresentar padrão de sazonalidade, o gráfico apresentará um formato senoidal, oscilando indefinidamente (MORETTIN & TOLOI, 1986).

Como exemplo, considere os dados de viscosidade apresentados na Tabela 4, com observações Y_t e sua representação gráfica (Figura 5).

Tabela 4: Série temporal de dados de viscosidade

t	Y_t	t	Y_t	t	Y_t	t	Y_t
1	13.3	21	14.9	41	15.8	61	16.0
2	15.5	22	13.7	42	13.7	62	14.9
3	15.3	23	15.2	43	15.1	63	13.6
4	15.3	24	14.5	44	13.4	64	15.3
5	14.3	25	15.3	45	14.1	65	14.3
6	14.8	26	15.6	46	14.8	66	15.6
7	15.2	27	15.8	47	14.3	67	16.1
8	14.5	28	13.3	48	14.3	68	13.9
9	14.6	29	14.1	49	16.4	69	15.2
10	14.1	30	15.4	50	16.9	70	14.4
11	14.3	31	15.2	51	14.2	71	14.0
12	16.1	32	15.2	52	16.9	72	14.4
13	13.1	33	15.9	53	14.9	73	13.7
14	15.5	34	16.5	54	15.2	74	13.8
15	12.6	35	14.8	55	14.4	75	15.6
16	14.6	36	15.1	56	15.2	76	14.5
17	14.3	37	17.0	57	14.6	77	12.8
18	15.4	38	14.9	58	16.4	78	16.1
19	15.2	39	14.8	59	14.2	79	16.6
20	16.8	40	14.0	60	15.7	80	15.6

Fonte: Montgomery (1997).




Figura 5: Série temporal da viscosidade medida em um processo tipo batelada

Fonte: Adaptado de Montgomery (1997).

A série em estudo é aparentemente estacionária, pois oscila aleatoriamente em torno de uma média. Para determinar a existência ou não de autocorrelação na série, deve-se calcular o coeficiente r_k . Conforme visto anteriormente, para o exemplo abordado sugere-se calcular no máximo 20 coeficientes de autocorrelação, dada a amostra com 80 observações. Os limites críticos são 0,224 e -0,224. O cálculo de cada coeficiente pode ser feito através da equação (27).

Para a série temporal analisada, obtêm-se os coeficientes de auto regressão expostos na Tabela 5.

Tabela 5: Coeficientes de autocorrelação r_k da série de dados de viscosidade

r_k	valor	r_k	valor	r_k	valor	r_k	valor
r_1	-0,047	r_6	0,049	r_{11}	-0,021	r_{16}	-0,051
r_2	0,059	r_7	-0,075	r_{12}	0,035	r_{17}	0,095
r_3	0,008	r_8	-0,066	r_{13}	-0,027	r_{18}	0,039
r_4	0,067	r_9	0,039	r_{14}	0,061	r_{19}	-0,080
r_5	-0,178	r_{10}	-0,236	r_{15}	0,070	r_{20}	-0,023

Os resultados apresentados na Tabela 5 determinam a função de autocorrelação da série, cuja representação gráfica é vista na Figura 6.




Figura 6: Gráfico da função de autocorrelação da série temporal de dados de viscosidade

Verificando-se tanto os dados da Tabela 5 em comparação aos limites críticos, quanto o gráfico da FAC (Figura 6), conclui-se que há autocorrelação significativa na série para uma defasagem de 10 períodos. Ainda que estatisticamente significativa, a autocorrelação sazonal identificada deve ainda justificar-se à vista do processo analisado, permitindo sua melhor compreensão.

Uma forma complementar de confirmar a existência ou não de autocorrelação em uma série temporal é a análise do gráfico da função de autocorrelação parcial – FACP.

As autocorrelações parciais objetivam medir o grau de associação entre Y_t e Y_{t-k} após a remoção dos efeitos das autocorrelações de defasagens 1, 2, 3 ... $k-1$. A eliminação dos efeitos das autocorrelações já identificadas permite que se realizem novas análises de autocorrelação entre duas observações não consecutivas.

O cálculo do coeficiente de autocorrelação parcial α_k é dado por Makridakis *et al.* (1998) através da regressão da observação Y_t em suas próprias observações anteriores:

$$Y_t = b_0 + b_1 Y_{t-1} + b_2 Y_{t-2} + \dots + b_k Y_{t-k} \quad (26)$$

onde b_k é a estimativa do coeficiente de autocorrelação parcial de ordem k e os demais termos já foram definidos anteriormente. A equação (26) é a equação genérica de um modelo de autoregressão, que será estudada com mais detalhes na seção 2.3.6.6.

Seguindo o mesmo conceito visto na FAC, o gráfico da FACP também apresentará as autocorrelações significativas de defasagem k quando o valor de b_k ultrapassar os limites críticos da função – calculados de forma idêntica à apresentada para a função de autocorrelação. Os gráficos da FAC e da FACP são úteis também para a identificação de sazonalidade na série temporal.

2.3.6.4 OPERADORES DE DEFASAGEM E DE DIFERENCIAÇÃO

Para análise dos modelos ARIMA, faz-se necessário familiarizar-se com as definições de operadores.

Operadores são notações adotadas para simplificar a apresentação de fórmulas. O operador de defasagem é definido por BY_t , e representa a observação da série Y no momento $t-1$. Assim, tem-se que:

$$BY_t = Y_{t-1} \quad (27)$$

Generalizando-se a equação (27) obtém-se:

$$B^w Y_t = Y_{t-w}$$

O operador de diferenciação é definido por ∇Y_t , e tem como finalidade representar as diferenciações aplicadas a uma série, conforme apresentado na equação (28):

$$\nabla Y_t = Y_t - Y_{t-1} \quad (28)$$

Substituindo-se a equação (27) na equação (28) tem-se:

$$\nabla Y_t = (1 - B)Y_t$$

2.3.6.5 MODELO DE FILTRO LINEAR

Os modelos estocásticos utilizados baseiam-se na idéia de que uma série temporal com valores altamente dependentes podem ser gerados a partir de uma série de ruído aleatório a_t (Yule, 1927 *apud* Box *et al.*, 1994).

A série de ruído aleatório pode ser transformada em uma série temporal de ruídos autocorrelacionados através de um modelo chamado de filtro linear. Este modelo consiste na soma das observações aleatórias a_t anteriores com atribuição de diferentes pesos à cada observação, como apresentado na equação (31):

$$Y_t = \mu + a_t + \psi_1 a_{t-1} + \psi_2 a_{t-2} + \dots \quad (29)$$

Como:

$$\psi(B) = 1 + \psi_1 B + \psi_2 B^2 + \dots \quad (30)$$

a equação (29) pode ser reescrita como:

$$Y_t = \mu + \psi(B)a_t \quad (31)$$

onde μ é o parâmetro que determina o nível da série e $\psi(B)$ é denominada *função de transferência* do filtro, e é responsável pela transformação de a_t em Y_t .

A sequência de pesos ψ pode ser finita ou infinita. Independentemente disso, a soma destes pesos será determinante para a análise da série. Se esta soma tiver um resultado menor que o infinito, então o filtro é estável e o processo Y_t é estacionário (Box *et al.*, 1994). Atendida a exigência de estacionariedade, tem-se que μ é a média ao redor da qual o processo varia.

2.3.6.6 MODELOS AUTOREGRESSIVOS

Os modelos autoregressivos são um caso especial do modelo de filtro linear. Matematicamente, são uma adaptação do modelo de regressão apresentado na equação (1). A principal característica do modelo autoregressivo é que em lugar das variáveis independentes o processo utilizar-se-á dos valores prévios da série temporal para estimação do modelo. Considerando a série z , com observações $Y_t, Y_{t-1}, Y_{t-2}, \dots$, e seus desvios da média $\tilde{Y}_t, \tilde{Y}_{t-1}, \tilde{Y}_{t-2}, \dots$, dados por:

$$\tilde{Y}_t = Y_t - \mu \quad (32)$$

então o modelo autoregressivo de ordem p , que pode ser representado por $AR(p)$, é estimado por:

$$\tilde{Y}_t = \phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \dots + \phi_p \tilde{Y}_{t-p} + a_t, \quad (33)$$

onde ϕ é o parâmetro a ser estimado. A estimação de ϕ é feita, como nos casos já vistos de regressão, através da MQE.

Para simplificar a representação do modelo, utiliza-se um operador autoregressivo de ordem p , dado por:

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p \quad (34)$$

e reduz-se o modelo autoregressivo de ordem p para:

$$\phi(B) \tilde{Y}_t = a_t \quad (35)$$

Este modelo tem $p+2$ parâmetros desconhecidos que devem ser estimados: os p parâmetros ϕ da equação (33) e a média e variância da série de ruído aleatório a .

Partindo-se das equações (31) e (32), pode-se concluir que:

$$\tilde{Y}_t = \psi(B)a_t, \quad (36)$$

e por substituição na equação (35) tem-se ainda:

$$\psi(B) = \phi^{-1}(B). \quad (37)$$

A estacionariedade para os processos autoregressivos é garantida se todas as raízes da equação $\phi(B) = 0$, com base no polinômio apresentado pela equação (34), forem maiores do que 1 em módulo.

Para os processos autoregressivos de primeira ordem, AR(1), também chamados de processos Markovianos, a estacionariedade é obtida se $|\phi| < 1$ (MONTGOMERY *et al.*, 1990).

Os processos de segunda ordem, AR(2), têm sua estacionariedade assegurada quando (BOX *et al.*, 1994):

$$\begin{aligned} \phi_1 + \phi_2 &< 1 \\ \phi_2 - \phi_1 &< 1. \\ |\phi_2| &< 1 \end{aligned}$$

2.3.6.7 MODELOS DE MÉDIA MÓVEL

Nos processos de média móvel, a estimação de \tilde{Y}_t é linearmente dependente de um número finito q de valores prévios de uma série de ruído aleatório a . Desta forma, o processo de média móvel de ordem q pode ser representado por:

$$\tilde{Y}_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}, \quad (38)$$

onde θ é o parâmetro a ser estimado e os demais termos já foram definidos. A estimação de θ é feita através da MQE.

Similarmente aos modelos autoregressivos, utiliza-se um operador de média móvel de ordem q para simplificar a representação do modelo, que é dado por:

$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q \quad (39)$$

e reduz-se o modelo de média móvel de ordem q para:

$$\tilde{Y}_t = \theta(B)a_t. \quad (40)$$

Este modelo tem $q+2$ parâmetros desconhecidos que devem ser estimados: os q parâmetros θ da equação (38) e a média e variância da série de ruído aleatório a .

Para os processos de média móvel de ordem p , a estacionariedade é garantida independentemente dos valores dos parâmetros $\theta_1, \theta_2, \dots, \theta_p$ (MONTGOMERY *et al.*, 1990). A inversibilidade dos processos de média móvel de primeira e de segunda ordem é assegurada quando θ_1 e θ_2 cumprem os mesmos requisitos de estacionariedade de ϕ_1 e ϕ_2 nos processos autoregressivos (BOX *et al.*, 1994).

Matematicamente, tem-se que a inversibilidade para um processo MA(1) é assegurada quando $|\theta_1| < 1$. Para processos MA(2), as condições são as seguintes:

$$\begin{aligned} \theta_1 + \theta_2 &< 1 \\ \theta_2 - \theta_1 &< 1 \\ |\theta_2| &< 1 \end{aligned}$$

2.3.6.8 MODELOS MISTOS AUTOREGRESSIVOS E DE MÉDIA MÓVEL

Os modelos mistos autoregressivos e de média móvel são mais flexíveis, pois utilizam tanto os termos dos modelos autoregressivos quanto dos modelos de média móvel. Desta forma, os modelos mistos conseguem adequar-se mais facilmente às séries temporais. O modelo matemático é dado por:

$$\tilde{Y}_t = \phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \dots + \phi_p \tilde{Y}_{t-p} + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q} \quad (41)$$

ou, de maneira simplificada:

$$\phi(B)\tilde{Y}_t = \theta(B)a_t.$$

Este modelo tem $p+q+2$ parâmetros desconhecidos que devem ser estimados.

A representação adequada de séries estacionárias reais podem ser obtidas, na maior parte dos casos, com modelos autoregressivos, de média móvel e mistos nos quais os valores de p e q são iguais ou inferiores a 2 (BOX *et al.*, 1994).

Especificamente para o processo misto autoregressivo de primeira ordem e de média móvel de primeira ordem ARMA(1,1), a estacionariedade e inversibilidade são asseguradas, respectivamente, quando $|\phi| < 1$ e $|\theta| < 1$ (MONTGOMERY *et al.*, 1990). São as mesmas condições aplicadas individualmente aos modelos autoregressivo e de média móvel.

2.3.6.9 MODELOS NÃO-ESTACIONÁRIOS

Os modelos não-estacionários, como já definido na seção 2.3.6.2, não apresentam média ou variância constantes. Isso, porém, não impede que uma série não-estacionária apresente algum tipo de homogeneidade. Este comportamento homogêneo pode ser representado pelo operador autoregressivo genérico $\varphi(B)$ de ordem d , que é dado por:

$$\varphi(B) = 1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_d B^d. \quad (42)$$

Este operador pode também ser representado por (BOX *et al.*, 1994):

$$\varphi(B) = \phi(B)(1 - B)^d, \quad (43)$$

onde $\phi(B)$ é o operador estacionário e d é a quantidade de raízes do polinômio $\varphi(B) = 0$ que estão no círculo unitário ($|\varphi_d| < 1$), ou seja, não atendem à condição de estacionariedade. Desta forma, pode-se rescrever o modelo que representa um comportamento homogêneo não-estacionário como:

$$\varphi(B)Y_t = \phi(B)(1 - B)^d Y_t = \theta(B)a_t \quad (44)$$

ou seja,

$$\phi(B)w_t = \theta(B)a_t \quad (45)$$

onde:

$$w_t = \nabla^d Y_t \quad (46)$$

assim, o comportamento não-estacionário homogêneo pode ser representado pela $d^{\text{ésima}}$ diferença do processo. A ordem de diferenciação d será normalmente igual a 0 ou 1 e raramente alcançará o valor 2 (GRANGER & NEWBOLD, 1986).

A partir do processo da equação (46), pode-se descrever um modelo para processos autoregressivos integrados à média móvel de ordem p , d e q – ARIMA(p , d , q), definido por (BOX *et al.*, 1994):

$$w_t = \phi_1 w_{t-1} + \phi_2 w_{t-2} + \dots + \phi_p w_{t-p} + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q} \quad (47)$$

Visto que $w_t = \nabla^d Y_t$, pode-se ainda demonstrar que, para $d = 0$ o modelo passa a ser misto autoregressivo e de média móvel, visto na seção 2.3.6.7.

Em muitos casos, o processo apresenta componentes sazonais, devendo-se acrescentar essa informação ao modelo, que será dado por:

$$\Phi(B^s) \nabla_s^D Y_t = \Theta(B^s) \alpha_t \quad (48)$$

onde $\Phi(B^s)$ e $\Theta(B^s)$ são respectivamente polinômios de ordem P e Q que atendem às condições de estacionariedade e inversibilidade, D é o número de diferenciações sazonais, α_t é o componente de erro e os demais termos já foram previamente definidos. Neste caso, porém, espera-se que os erros sejam correlacionados e, portanto, podem ser descritos pelo modelo ARIMA, como segue:

$$\phi(B) \nabla^d \alpha_t = \theta(B) a_t. \quad (49)$$

Substituindo-se a equação (49) na equação (48) obtém-se a fórmula genérica do modelo autoregressivo integrado à média móvel sazonal multiplicativo de ordem $(p, d, q) \times (P, D, Q)_s$ – SARIMA $(p, d, q) \times (P, D, Q)_s$, dada por:

$$\phi_p(B) \Phi_P(B^s) \nabla^d \nabla_s^D Y_t = \theta_q(B) \Theta_Q(B^s) a_t. \quad (50)$$

2.3.6.10 IDENTIFICAÇÃO DOS MODELOS

A identificação dos modelos costuma ser problemática e não há consenso a respeito de qual estratégia seguir (GRANGER & NEWBOLD, 1986). A Tabela 6, apresentada

por Mills (1990), define o comportamento esperado dos gráficos da função de autocorrelação e da função de autocorrelação parcial para os modelos ARIMA.

Tabela 6: Propriedades da FAC e FACP para modelos ARIMA

Modelo	FAC	FACP
$(1, d, 0)$	Decaimento exponencial ou oscilatório	$b_k=0$ para $k>1$
$(2, d, 0)$	Decaimento exponencial ou senoidal	$b_k=0$ para $k>2$
$(p, d, 0)$	Decaimento exponencial ou senoidal	$b_k=0$ para $k>p$
$(0, d, 1)$	$r_k=0$ para $k>1$	Prevalece decaimento exponencial
$(0, d, 2)$	$r_k=0$ para $k>2$	Prevalece decaimento exponencial ou senoidal
$(0, d, q)$	$r_k=0$ para $k>q$	Prevalece combinação linear de decaimento exponencial e/ou senoidal
$(1, d, 1)$	Decaimento exponencial a partir da defasagem 1	Prevalece decaimento exponencial a partir da defasagem 1
(p, d, q)	Decaimento exponencial e/ou senoidal a partir da defasagem $q-p$	Prevalece decaimento exponencial e/ou senoidal a partir da defasagem $q-p$

Fonte: Mills (1990).

A análise das características dos gráficos da FAC e FACP é uma estratégia bastante utilizada na identificação de modelos, haja vista que alguns pacotes computacionais de previsão como *Statgraphics*, *NCSS* e *ITSM*, geram tais gráficos automaticamente.

Para modelos sazonais, pode-se também utilizar os gráficos da FAC e FACP na análise, tomando-se o cuidado de analisar os dados a cada s períodos, respeitando as defasagens sazonais. A Tabela 7, apresentada por Bowerman & O'Connell (1987), resume as propriedades dos gráficos da FAC e FACP para modelos SARIMA.

Além da identificação dos valores de p , q , P e Q , os graus de diferenciação da série d e D precisam ser conhecidos (MELO, 2001). Isso pode ser feito conforme detalhado na seção 2.3.6.2.

Outra estratégia que pode ser utilizada na identificação do modelo é a determinação de um conjunto de regras que utilizem um critério de informação para tal (Mills, 1990). Os principais critérios são o AIC - *Akaike Information Criterion*, o AICC - *Akaike Information Criterion Corrected* e o BIC - *Bayesian Information Criterion* (Melo, 2001).

Todos os critérios possuem mecanismos para privilegiar os modelos com menor número de parâmetros. Para aprofundar os conhecimentos nesse assunto, sugere-se a consulta a Melo (2001), Brockwell & Davis (1996) e Granger & Newbold (1986).

Tabela 7: Propriedades da FAC e FACP para modelos SARIMA

Modelo	FAC	FACP
$(P, D, 0)$	Decaimento	Picos nas defasagens $s, 2s, \dots, Ps$ com corte após Ps
$(0, D, Q)$	Picos nas defasagens $s, 2s, \dots, Qs$ com corte após Qs	Decaimento
$(P, D, 0)$ ou $(0, D, Q)$	Picos nas defasagens $s, 2s, \dots, Qs$ com corte após Qs	Picos nas defasagens $s, 2s, \dots, Ps$ com corte após Ps
$(P, D, 0)$ e $(0, D, Q)$	Decaimento rápido na defasagem sazonal	Decaimento rápido na defasagem sazonal
Nenhum operador sazonal	Não há picos pois os valores das defasagens sazonais não são estatisticamente significativos	Não há picos pois os valores das defasagens sazonais não são estatisticamente significativos

Fonte: Bowerman & O'Connell (1987).

2.3.6.11 VERIFICAÇÃO DOS MODELOS

Uma das formas de verificação da adequação do modelo é a aplicação de *portmanteau tests* – que podem ser entendidos como testes que abrangem vários itens considerados como apenas um. Essa tradução tortuosa deve-se ao fato de que a palavra *portmanteau* não tem tradução direta para a Língua Portuguesa.

Porém, a descrição supra indica exatamente o que teste de Box-Pierce realiza com as estimativas dos coeficientes de autocorrelação (r_k). Este teste considera um conjunto de coeficientes de autocorrelação de uma só vez. O resultado da estatística de Box-Pierce (Q) é comparado aos valores de uma tabela de distribuição do Qui-Quadrado (χ^2) para que se verifique se é significativamente diferente de zero (MAKRIDAKIS *et al.*, 1998). Se o modelo for inadequado, o valor de Q excederá o valor da distribuição do Qui-Quadrado com $k - p - q$ graus de liberdade (MONTGOMERY *et al.*, 1990). A estatística Q é dada por:

$$Q = n \sum_{k=1}^h r_k^2 \quad (51)$$

onde h é a maior defasagem considerada para o teste e os outros termos já foram definidos anteriormente. Se os termos de erro (e_t) constituírem um processo de ruído aleatório, o modelo pode ser considerado adequado.

Outra estatística utilizada da mesma forma é o teste de Ljung-Box e sua estatística alternativa (Q^*), cuja fórmula é dada por Melo (2001):

$$Q^* = n(n+2) \sum_{k=1}^h (n-k)^{-1} r_k^2 \quad (52)$$

2.3.6.12 RESULTADOS OBTIDOS COM MODELOS DE BOX-JENKINS

Coccaro (2000) utilizou um modelo ARMA(2,0)(1,0) e obteve um EMAP de 7,3% na previsão dos valores do ICMS do Estado do Rio Grande do Sul. Cirincione *et al.* (1999), em seu estudo da receita não tributária dos municípios de Connecticut, obtiveram um EMAP de 32,9% ao utilizar os modelos de Box-Jenkins.

Siqueira (2002) fez um estudo que compreendeu a análise de nove séries utilizadas pela Secretaria da Receita Federal, apontando um modelo para cada série. As seis séries com modelagem ARIMA obtiveram valores do EMP que variaram entre -7,4% e -14,9%. Para as três séries em que os modelos SARIMA foram mais adequados, os resultados do EMP variaram entre 3,6% e -10,1%. A série com o melhor ajuste foi a do Imposto sobre Produtos Industrializados, cujo erro médio percentual foi de -2,54%.

Arraes & Chumvichitra (1996) realizaram uma análise sobre séries de dados trimestrais de arrecadação de ICMS entre 1970 a 1995, com aplicação exclusiva de modelos ARIMA. Neste trabalho, obteve-se um erro de previsão anual da ordem de 3,5%, quando utilizados os modelos mais adequados para cada trimestre, concluindo ainda que se somente um modelo tivesse que ser escolhido, este seria o ARIMA(1,1,0).

2.4 FORECASTING QUALITATIVO

Quando não se dispõe de dados para efetuar uma previsão quantitativa, as empresas e organizações vêm-se obrigadas a mudar a base de suas decisões gerenciais. Uma possibilidade é a adoção de métodos de previsão qualitativos, conhecidos também como Métodos de Julgamento.

Deve-se ressaltar que a existência de dados e a conseqüente aplicação de um modelo matemático de previsão não exclui a possibilidade de utilização de um método qualitativo para a mesma situação, sendo que este último pode até alterar os resultados do primeiro.

Krajewski & Ritzman (1998) apontam quatro métodos de *forecasting* qualitativo: as estimativas do setor de vendas, a pesquisa de mercado, a opinião dos executivos da empresa e o método Delphi. De acordo com Armstrong (1987), pode-se ainda acrescentar a esta relação a Teoria dos Jogos, os questionários de intenção, a extrapolação por analogia, os experimentos laboratoriais, os experimentos de campo e o *role playing* – que consiste em assumir diferentes papéis como parte de um experimento.

Esta dissertação deter-se-á na análise do método Delphi por sua versatilidade e adequação ao assunto estudado.

2.4.1 O MÉTODO DELPHI

Genericamente, o Delphi é um método para estruturar um processo de comunicação grupal de modo a permitir que um grupo de indivíduos trabalhe uma tarefa complexa (LINSTONE & TUROFF, 1975). Seu principal objetivo é tentar obter o mais confiável consenso entre os especialistas (DALKEY & HELMER, 1963). Mais especificamente, trata-se de uma técnica para a busca de um consenso de opiniões de um grupo de especialistas a respeito de um evento futuro (WRIGHT & GIOVINAZZO, 2000).

Percebe-se, pela análise da definição e do objetivo do método Delphi, que sua aplicação é possível nas mais variadas áreas. Este método tem sido bastante utilizado no planejamento, na análise de políticas e nas previsões de longo prazo, tanto na área pública quanto na área privada (GUPTA & CLARKE, 1996).

O método consiste na aplicação sucessiva de questionários a um grupo de especialistas ao longo de várias rodadas (KAYO & SECURATO, 1997). Esses questionários são elaborados por um grupo de coordenação do estudo, que é responsável por seu envio aos especialistas que participarão da pesquisa, formando o grupo de respondentes.

Após a aplicação do primeiro questionário, os resultados são tabulados e, dependendo da avaliação do grupo de coordenação, novas perguntas podem ser incluídas. Na

segunda rodada o grupo de respondentes receberá, além das questões, os resultados obtidos na primeira rodada. Essa informação adicional serve como subsídio para uma eventual reavaliação de sua postura diante das questões propostas. O processo é repetido até que se obtenha uma convergência satisfatória (consenso) sobre o assunto em análise. A Figura 7 apresenta a seqüência de execução de uma pesquisa através do método Delphi.




Figura 7: Execução de pesquisa – Método Delphi

Fonte: Adaptado de Wright & Giovinazzo (2000).

A obtenção do consenso é polêmica e não é uma condição necessária, dependendo da variação do método que esteja sendo usada. Para o Delphi em seu formato original, entretanto, o consenso é obrigatório, fazendo com que os respondentes cujas

respostas não sejam convergentes com a da maioria vejam-se obrigados a justificar suas respostas.

Ressalte-se que as justificativas permanecem anônimas, pois nenhum dos participantes do grupo de respondentes tem conhecimento de quem são seus pares no estudo. O anonimato é uma das condições em que se pautam diversas vertentes do método Delphi. Com isso, pretende-se garantir que um grupo não será influenciado por componentes que exercem maior poder de persuasão.

Outra questão controversa é a utilização apenas de especialistas como respondentes no estudo. A justificativa para esta escolha é a de que os especialistas constituem um grupo de potenciais criadores e/ou formadores de opinião, cujas declarações refletiriam previsões confiáveis (KAYO & SECURATO, 1997).

A adaptabilidade do método a diferentes problemas e situações deve-se a sua capacidade de ser transformado de acordo com a necessidade dos pesquisadores. Rauch (1979) apresenta três vertentes do método: (i) o *Classical Delphi* - Delphi Clássico, (ii) o *Policy Delphi* - Delphi de Políticas e (iii) o *Decision Delphi* - Delphi de Decisão. As principais características de cada uma das abordagens são apresentadas na Tabela 8.

2.4.2 DELPHI CLÁSSICO

A idéia básica do Delphi Clássico é a obtenção de um prognóstico científico condicionado. Esta previsão será científica porque segue um método científico, e condicionada porque depende da manutenção da situação considerada para a previsão.

O objetivo do método clássico, também chamado de convencional, é a obtenção de consenso entre os participantes do grupo de especialistas. Para tanto, a previsão é feita a partir de uma situação real, que não gera dúvidas sobre sua interpretação. A discussão se dá sobre as conseqüências prováveis decorrentes da situação dada.

Um exemplo de previsão poderia ser: “As vendas da empresa ABC crescerão de 12% a 14% no primeiro semestre, mantidas as taxas de juros e de crescimento do Produto Interno Bruto – PIB”.

Tabela 8: Características do Delphi Clássico, do Delphi de Políticas e do Delphi de Decisão

	<i>Delphi Clássico</i>	<i>Delphi de Políticas</i>	<i>Delphi de Decisão</i>
Conceitos			
A importância da realidade:	A realidade é dada e sua compreensão é clara. As discussões são acerca das conseqüências.	A realidade é dada e sua compreensão é objeto de discussão.	A realidade será criada.
Objetivos			
O Delphi funciona como fórum para:	Fatos.	Idéias.	Decisões.
O procedimento tenta:	Obter consenso.	Definir e diferenciar visões.	Preparar e dar apoio a decisões.
A idéia básica é:	Previsão.	Pluralismo.	Atingimento de metas.
Participantes			
Os participantes são:	Especialistas.	Lobistas.	Tomadores de decisão.
Os participantes tentam:	Obter previsões e declarações realistas.	Apoiar seus próprios interesses.	Criar base para tomada de decisões úteis e realísticas.
A participação tem que:	Ser alta. (grande quantidade de especialistas)	Considerar todos os grupos interessados.	Alcançar um alto percentual dos tomadores de decisão.
Método			
O <i>feedback</i> serve para:	Obter uma previsão ou resposta realística.	Obter posições bem definidas de cada grupo.	Estimular e informar os tomadores de decisão.
O anonimato significa que:	Os participantes não sabem quem são seus pares e todas as respostas são anônimas.	Os participantes não sabem quem são seus pares e todas as respostas são anônimas.	Os participantes se conhecem desde o princípio; as respostas são, contudo, anônimas.
A razão para o anonimato é:	Limitar os acordos e o uso da influência pessoal.	Facilitar a exposição de pontos de vista extremos e a objetividade.	Apoiar as idéias pessoais e aumentar a participação nas decisões.
A objetividade da avaliação tem:	Razões metodológicas (evitar vieses).	Razões pragmáticas (obter visão do todo).	Razões éticas (o coordenador do estudo não deve influenciar o processo de decisão).

Fonte: Adaptado de Rauch (1979).

Parenté *et al.* (2003) realizaram dois experimentos com o método Delphi a partir dos quais puderam concluir que o método aumenta a acurácia da previsão. O primeiro estudo foi realizado testando se a existência de *feedback* influencia as respostas do segundo questionário e como isso afeta o resultado. Os pesquisadores obtiveram uma acurácia de 80% entre os respondentes que não foram informados dos resultados da primeira rodada contra 90% de previsões corretas daqueles que tinham esta informação. A pesquisa foi conduzida

acerca da possibilidade de ocorrência de eventos no caso Monica Lewinsky, inclusive questionando quando eles aconteceriam.

O segundo experimento foi sobre a possibilidade de atividades terroristas dentro dos Estados Unidos e no exterior e ainda sobre o resultado da incursão militar no Afeganistão. Neste caso, concluiu-se que um maior número de rodadas não é um fator que garante maior acurácia no processo, pois, embora os resultados da segunda rodada tenham sido significativamente superiores aos obtidos na primeira rodada, os resultados da terceira rodada foram levemente inferiores aos da Segunda.

2.4.3 DELPHI DE POLÍTICAS

A composição do grupo de respondentes é alterada. Em lugar dos especialistas entram os lobistas – pessoas que representam interesses de um ou outro grupo sobre determinado assunto.

Diferentemente do Delphi Clássico, o Delphi de Políticas não tenta alcançar o consenso entre os participantes do grupo de respondentes. Isso fica claro quando Turoff (1970) cita, como objetivos possíveis para o Delphi de Políticas, o desenvolvimento de alternativas para uma situação e a exploração de informações que levam a diferentes julgamentos.

Schneider (1972) aplicou o Delphi de Políticas no planejamento do desenvolvimento do distrito central de negócios de Seattle. A grande questão a ser discutida era se o crescimento do distrito de central de negócios de Seattle deveria ser encorajado ao longo dos 20 ou 30 anos subseqüentes ou se a melhor opção seria o desenvolvimento do distrito central de negócios de Bellevue, cidade vizinha de Seattle. A segunda opção poderia transformar a cidade de Bellevue no segundo pólo de geração de empregos na área de comércio da região.

Dada a situação das duas cidades, temas como transporte, meio-ambiente, habitação e infra-estrutura mereceram especial atenção na elaboração das declarações de política (15 no total) apresentadas ao grupo de respondentes. Todas as declarações foram avaliadas sob quatro enfoques: (i) a importância da declaração (prioridade/relevância), (ii) o quanto se almeja que a declaração seja implantada (desejo/efetividade), (iii) a probabilidade

de sua implantação e (iv) a validade da mesma. O estudo foi concluído após duas rodadas de aplicação do método.

Da mesma forma, Setty *et al.* (1987) utilizaram o método para estudos de planejamento de conservação de energia. O estudo foi concluído após três rodadas, e foi possível selecionar 4 declarações como as mais importantes dentre as 22 apresentadas.

Na área médica pode-se citar o trabalho de Mara (2000), que utilizou o Delphi de Políticas para realizar o planejamento estratégico de uma organização sem fins lucrativos – no caso, um hospício.

2.4.4 DELPHI DE DECISÃO

O objetivo do Delphi de Decisão é, como pode-se deduzir do nome, uma pesquisa aplicada para auxiliar a tomada de decisões. O método Delphi pode contribuir com o processo decisório quando há limitação de dados empíricos (ANGUS *et al.*, 2003).

Novamente a composição do grupo de respondentes é alterada. Neste caso os participantes serão tomadores de decisão, ou seja, o corpo gerencial de uma empresa. Para que seja efetiva, a pesquisa deve contar com a participação do maior número de pessoas responsáveis pelas decisões da empresa (RAUCH, 1979).

Poder-se-ia imaginar que o anonimato aqui não faria sentido, pois todos os participantes se conhecem, já que trabalham na mesma empresa. Porém, o anonimato permanece válido e diz respeito às respostas dadas nos questionários. Desta forma, um integrante do grupo de respondentes pode expressar livremente uma posição contrária à de seu superior, ainda que este também esteja participando do estudo. Essa opinião poderia ser reprimida caso tivesse que ser exposta abertamente aos integrantes do grupo.

Analisando novamente a Tabela 8, no que diz respeito ao Delphi de Decisão, verifica-se que a realidade *será criada*. Na prática, isso quer dizer que as pessoas envolvidas no processo devem tentar prever cenários (econômicos, sociais, políticos e outros de interesse) e traçar os objetivos para sua empresa dentro deste cenário. Para tal, devem receber todo o tipo de informação que necessitarem, a fim de tomar decisões realísticas.

2.4.5 CONSIDERAÇÕES SOBRE O MÉTODO DELPHI

Em geral, não há uma evidência clara de que o grau de especialização dos componentes do grupo de respondentes melhore a acurácia do método Delphi (PARENTÉ *et al.*, 2003). Dependendo do estudo que se deseja realizar, a seleção de especialistas pode demandar tempo e recursos que podem inviabilizar a pesquisa.

Outro fator que influencia os custos e a duração de uma pesquisa é o número de rodadas que devem ser aplicadas. Mullen (2003) relacionou estudos individuais que indicam de duas até cinco rodadas, e concluiu que a maioria utiliza na prática duas ou três rodadas.

Em contrapartida, Meyrick (2003) ressalta a facilidade com que se pode aplicar os questionários, não sendo necessários que os respondentes estejam no mesmo local ou que respondam ao mesmo tempo.

Okoli & Pawlowski (2004) citam como vantagem essencial do método o fato de evitar-se o confronto direto entre os especialistas, evitando que tentem exercer sua influência pessoal sobre os demais participantes.

Como instrumento de planejamento estratégico, Loo (2002) conclui que deve-se considerar seriamente a utilização do método Delphi, pois quando bem planejado e executado pode levar a descobertas úteis para os responsáveis por elaboração de políticas.

Análises mais aprofundadas e detalhes sobre o método Delphi podem ser obtidos em Okoli & Pawlowski (2004), Mullen (2003), Wright & Giovinazzo (2000) e Kayo & Securatto (1997).

2.5 CRITÉRIOS DE AVALIAÇÃO E COMPARAÇÃO DE MODELOS DE *FORECASTING*

Antes da seleção de um modelo, vários devem ser testados para que se possa comparar seus resultados com dados reais. Isso pode ser feito aplicando-se os modelos a uma série temporal de interesse e realizar uma previsão para um período do qual o resultado já é conhecido. Desta forma, o pesquisador poderá avaliar o grau de adaptação de cada modelo para o processo em análise.

Carbone & Armstrong (1982) realizaram uma pesquisa respondida por 70 pessoas ligadas ao meio acadêmico e 75 profissionais da área de previsão. O estudo revelou quais os critérios de avaliação mais importantes na escolha de um modelo. Os itens mais citados foram, na ordem: (i) acurácia do modelo, (ii) facilidade de interpretação, (iii) custo e tempo necessários para sua aplicação e (iv) facilidade de uso e implementação.

Relativamente à acurácia, o estudo revelou que três critérios foram eleitos por 81% dos acadêmicos e por 55% dos profissionais: a Média Quadrada dos Erros - MQE, o Erro Médio Absoluto - EMA e o Erro Médio Absoluto Percentual - EMAP.

Em pesquisa mais recente, envolvendo empresas canadenses (KLASSEN & FLORES, 2001), apurou-se que os critérios EMA e EMAP figuram entre os mais populares, e juntamente com o Erro Médio – EM e o Erro Médio Percentual – EMP, são utilizados por 60% das empresas que utilizam critérios matemáticos para comparação dos modelos. Para facilitar o entendimento, as expressões matemáticas dos critérios de comparação citados são dadas pelas equações (53) a (57):

$$EM = \frac{\sum_{i=1}^n (Y_t - F_t)}{n} \quad (53)$$

$$EMA = \frac{\sum_{i=1}^n (|Y_t - F_t|)}{n} \quad (54)$$

$$MQE = \frac{\sum_{i=1}^n (Y_t - F_t)^2}{n} \quad (55)$$

$$EMP = \frac{\sum_{i=1}^n \left(\frac{Y_t - F_t}{Y_t} \right) \times 100}{n} \quad (56)$$

$$EMAP = \frac{\sum_{i=1}^n \left(\left| \frac{Y_t - F_t}{Y_t} \right| \right) \times 100}{n} \quad (57)$$

onde F_t representa a estimativa da série no momento t , Y_t representa o valor da variável Y no momento t e n é a quantidade de observações utilizadas para calcular o erro.

Makridakis *et al.* (1982) realizaram um estudo com 1.001 séries temporais e identificaram que a frequência dos dados da série (mensal, trimestral, anual), o tipo da série (macro – envolvendo muitas variáveis, micro – envolvendo poucas variáveis) e horizonte de tempo a ser previsto influenciam os resultados. Os autores concluíram que modelos estatisticamente mais sofisticados não produzem resultados melhores que modelos simples quando há grande variabilidade nos dados. Dentre os cinco critérios de comparação de resultados dos modelos utilizados neste trabalho aparecem o MQE e o EMAP.

No estudo de modelos de previsão para receita de hotéis (WEATHERFORD & KIMES, 2003) foram utilizados os critérios de comparação de resultados EMA e EMAP. O EMAP também foi utilizado na avaliação de modelos de previsão em Cho (2003) e Smith *et al.* (2002), enquanto o EMA foi uma das escolhas em Meade (2002) e Yang *et al.* (2000).

Jaffry & Capon (2004) conduziram uma pesquisa junto à Marinha norte-americana visando comparar métodos quantitativos e qualitativos. Ambos apresentaram bons resultados, porém, as decisões somente foram tomadas depois que as previsões quantitativas confirmaram os riscos apontados pelos métodos qualitativos.

Independentemente do método utilizado para comparação dos modelos, deve-se ressaltar a importância da avaliação dos mesmos. A Figura 8 apresenta os passos sugeridos para utilização de modelos de previsão.




Figura 8: Seleção de um modelo de previsão

Fonte: Adaptado de Armstrong (2001).

Informações sobre os procedimentos adotados em cada uma das seis fases podem ser obtidas em Armstrong (2001).

2.6 DESENVOLVIMENTOS E APLICAÇÕES RECENTES DE *FORECASTING*

Considerando os resultados obtidos por Klassen & Flores (2001), indicando que em uma pesquisa com empresas canadenses 98% delas declararam utilizar pelo menos um método de *forecasting*, pode-se concluir pela relevância dos desenvolvimentos nesta área. Dentre as empresas da referida pesquisa, 78% utilizam três ou mais métodos de previsão e 21% utilizam o que o autor considera métodos recentes: teoria do caos, algoritmos genéticos, sistemas de especialistas e redes neurais.

O que se percebe ao analisar textos recentes sobre *forecasting*, é a tentativa constante de melhoria dos diversos métodos e suas aplicações em novas áreas e de criação de novos modelos.

O modelo Teta foi criado por Assimakopoulos & Nikolopoulos (2000). Este novo modelo de previsão é baseado na modificação da curvatura de uma série temporal através de um coeficiente representado pela letra grega teta. Porém, Hyndman & Billah (2003) demonstraram que o modelo Teta é apenas um caso especial de suavização exponencial simples.

Um modelo que se destaca pelo número de abordagens existentes é o autoregressivo de heterocedasticidade condicional, abordado em Taylor & Buizza (2004), McMillan & Speight (2004), Vrontos *et al.* (2003) e Park (2002). Outro modelo autoregressivo bastante estudado é o modelo autoregressivo vetorial analisado detalhadamente em Kim (2004), Canova & Ciccarelli (2004) e Joseph (2001).

Mesmo os modelos já consagrados são analisados de forma crítica, buscando o aprimoramento de seus resultados. É caso dos modelos ARMA (KOREISHA & FANG, 2004) e ARIMA (BIANCO *et al.*, 2001).

A integração de modelos de previsão é apresentada por Zhou (1999) como uma forma de desenvolver previsões diferenciadas para diferentes propósitos. Também realizaram estudos nesta área Trapletti *et al.* (2002) e McCrae *et al.* (2002), ambos com aplicações voltadas à previsão de cotação de moedas no mercado de câmbio internacional.

Na área pública, a melhoria nos resultados de previsão de receita é manifestada em Morrison (2002), que apresenta um roteiro através de perguntas e respostas. São feitas dez

perguntas cujas respostas apresentadas servem como guia dos passos a serem seguidos para obtenção de melhores previsões. Coccaro (2000) e Freitas (2002) testaram o modelo de redes neurais artificiais na previsão do ICMS do Estado do Rio Grande do Sul.

Um sistema sólido de regras institucionais é sugerido por Stinson (2002) para previsão de receitas públicas. Neste estudo é abordado o caso de Minnesota, nos Estados Unidos, e como a aplicação de tais regras ajudou o estado a manter o processo orçamentário adequado à sua realidade financeira.

Guajardo (2003) apresenta o caso do Condado de Nassau, que ao adotar as 59 práticas orçamentárias recomendadas pelo NACSLB – *National Advisory Council on State and Local Government Budgeting*, começou a enfrentar seu déficit estrutural e a desenvolver orçamentos funcionais baseados em projeções de receitas realistas.

Para uma síntese dos desenvolvimentos obtidos em vários métodos de previsão, quantitativos e qualitativos, recomenda-se a consulta a Martino (2003).

Enfim, percebe-se que há diversos temas e pesquisas sendo desenvolvidos sobre *forecasting*, visando o aprimoramento dos modelos e a validação das conclusões obtidas anteriormente. O volume de pesquisas, acrescido do interesse que o assunto tem despertado, tanto na área privada quanto na pública, permite concluir que o *forecasting* será de vital importância para a sobrevivência das empresas e para o equilíbrio financeiro desejado dos entes públicos.

3 MÉTODO DE TRABALHO

Neste capítulo apresenta-se uma sequência para realização de previsões de receita de ICMS. A proposta é implementada em 12 passos. A principal característica da previsão de receita de um tributo é que os resultados obtidos pelos modelos matemáticos podem ser alterados por um método qualitativo de previsão.

A previsão de receitas nos estados e municípios existe há alguns anos no Brasil, principalmente para controle do fluxo financeiro. Para isso são realizadas previsões de curto prazo, geralmente para um ou dois meses à frente. Entretanto, após a edição da Lei Complementar 101/00 – Lei de Responsabilidade Fiscal - LRF – verificou-se um aumento considerável na busca de previsões de receita de longo prazo (três anos) e que fossem razoavelmente acuradas.

Com a premente necessidade de realizar previsões condizentes com o cenário econômico e com a legislação em vigor, cada estado passou a aprimorar seus métodos de previsão. A implantação de um sistema de *forecasting* pode permitir que todo o procedimento seja padronizado e, desta forma, seus resultados sejam analisados com vistas à melhoria contínua do processo de previsão.

Pellegrini (2000) aponta três fatores organizacionais que são fundamentais para a implantação de um sistema de previsão: (i) como o *forecasting* será usado, (ii) onde será usado e (iii) como ele se insere no contexto da organização.

No caso de previsão de receita de tributos, a resposta à primeira pergunta é bastante objetiva, pois o *forecasting* será usado por um grupo de especialistas – geralmente componentes de um setor específico de análise de informações e de previsão de receitas – que será responsável pela execução de todos os passos necessários para obtenção da previsão.

A segunda questão levantada é onde o *forecasting* será usado. A previsão da receita é uma informação fundamental para tomada de decisões estratégicas do governo. A informação comporá o Orçamento do estado bem como o Plano Plurianual – PPA. Além disso, o resultado da previsão será considerado pelo órgão responsável pela arrecadação dos tributos como meta fiscal para o período projetado.

Por fim, o *forecasting* se insere no órgão responsável pelo gerenciamento da arrecadação de tributos de forma natural, pois é lá que podem ser encontrados os especialistas em matéria tributária. Além disso, as oscilações no comportamento da receita tributária devem ser fenômenos conhecidos dentro do órgão, o que facilita o entendimento da série de dados.

Quando se deseja definir qual é o modelo de *forecasting* quantitativo mais adequado a uma determinada série temporal, deve-se ainda considerar as seguintes condições de aplicabilidade destes modelos (MAKRIDAKIS *et al.* 1998): (i) a disponibilidade de informações históricas, (ii) a possibilidade de transformação das informações históricas em dados numéricos e (iii) a suposição de que os padrões observados repetir-se-ão no futuro.

No caso das receitas, pode-se ponderar, em resposta às condições de aplicabilidade sugeridas, que: (i) é esperado que os estados tenham as informações históricas, pois são periodicamente convocados a justificar os resultados de arrecadação pelo Poder Legislativo e, eventualmente, pelo Tribunal de Contas; (ii) a informação bruta, ou seja, os dados de arrecadação, já são uma informação numérica, tornando sem efeito prático a segunda condição e (iii) tendo em vista tratar-se de uma série econométrica, é sempre bastante provável que haja um padrão de sazonalidade anual, desde que mantidas as condições de arrecadação do tributo, em especial a legislação.

Considerando-se que as previsões de receita mais desejadas são as de longo prazo, em virtude da obrigatoriedade imposta pela Lei de Responsabilidade Fiscal – o horizonte destas previsões é de, no mínimo, 36 meses. Como há necessidade de se manter um sistema de previsão preparado para os Planos Plurianuais de Governo, editados a cada 4 anos, sugere-se que se mantenham 48 meses de previsão em todos os estudos, podendo-se, desta maneira, analisar o comportamento de longo prazo previsto para a série.

Para a realização de uma previsão de receita, sugere-se seguir os passos do fluxograma apresentado na Figura 9.

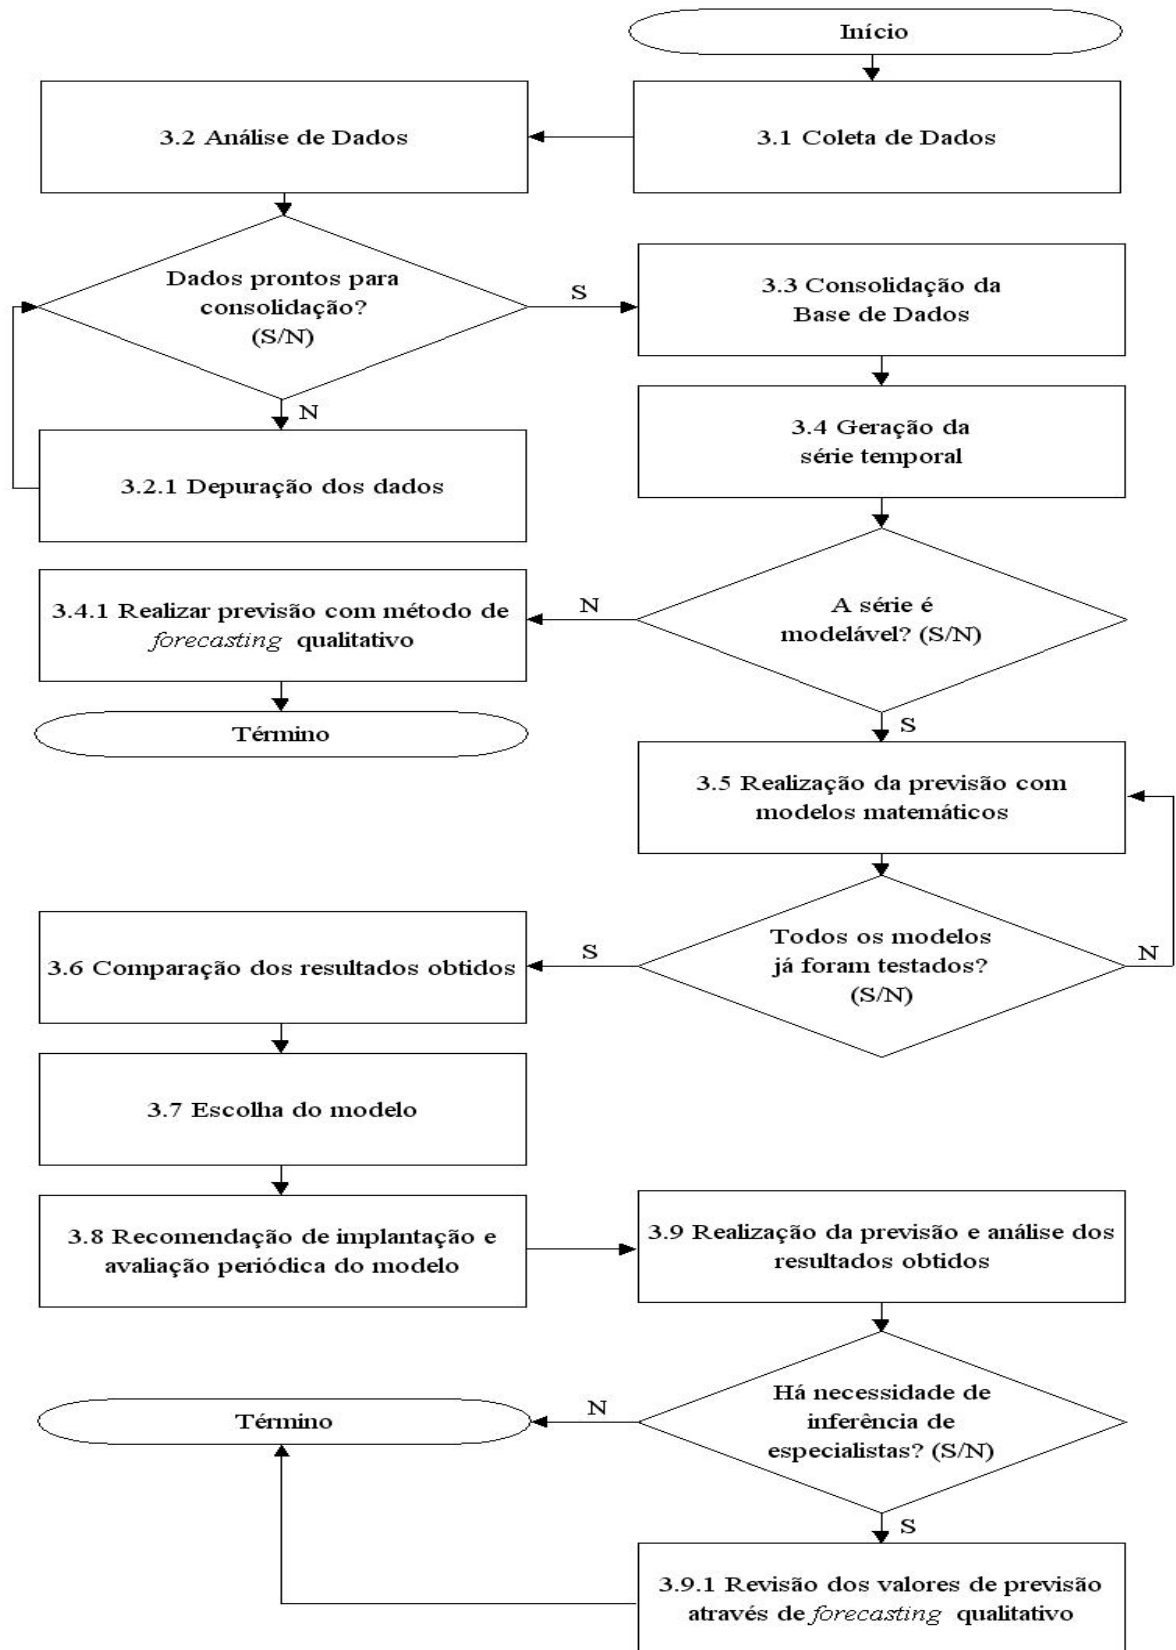


Figura 9: Sequência para previsão de receita

3.1 COLETA DE DADOS

A coleta de informações é uma fase crucial para um estudo de *forecasting*, pois a inexistência de dados impediria quaisquer análises comparativas acerca da acurácia dos modelos. Um fator que deve ser considerado desde o princípio é que os dados sobre a receita podem ser deliberadamente negados – por serem considerados estratégicos – ou podem não estar disponíveis para consulta pública, por não terem sido consolidados pelos sistemas de informação da própria Receita Estadual. Logo, ao iniciar seu estudo, deve-se entrar em contato com a Secretaria da Fazenda (ou de Finanças, em alguns casos) para descobrir se os dados necessários estão disponíveis e solicitar autorização para acessá-los.

Um cuidado a ser tomado acerca dos dados recai sobre a sua confiabilidade. Se possível, deve-se confirmar as informações obtidas com outras fontes – dentro ou fora do governo. Uma fonte alternativa de dados são institutos oficiais de pesquisa do estado ou município.

3.2 ANÁLISE DOS DADOS

O ideal para aplicação de modelos de previsão é que a série temporal esteja completa. Deve-se ressaltar que, ainda que a série esteja completa, cabe ao pesquisador decidir se os dados estão prontos para análise ou não. Em caso afirmativo, segue-se diretamente para a consolidação da base de dados. Do contrário, deve-se proceder à depuração dos dados.

3.2.1 DEPURAÇÃO DOS DADOS

Se os dados foram considerados inadequados para análise, deve-se proceder a sua depuração, que é um processo destinado a “limpar” dados espúrios. Esse procedimento serve para assegurar que fatores pontuais, por exemplo, a arrecadação realizada devido a um programa de recuperação de créditos fiscais, não sejam considerados na modelagem da série.

A substituição dos valores espúrios pode ser feita de três maneiras: (i) identificando o valor e ajustando determinada observação, (ii) aplicando a média dos valores adjacentes ou (iii) projetando os valores. A última alternativa somente será viável para substituição de observações próximas ao fim da série temporal, quando já existem dados

suficientes para aplicação de um modelo de previsão. Após a limpeza dos dados, tem-se a série temporal a ser trabalhada no estudo.

3.3 CONSOLIDAÇÃO DA BASE DE DADOS

Após a depuração dos dados e da estimação dos dados faltantes, quando for o caso, deve-se proceder à consolidação da base de dados. Se for do interesse da pesquisa, esta fase pode incluir a verificação dos dados mensais de cada município do estado. Ao final, todas as tabelas e eventuais relacionamentos por microrregião ou por unidades administrativas da Receita Estadual deverão ser testadas para que se faça a consolidação da base de dados. Se o interesse for apenas no total do estado, a base está consolidada logo após a depuração dos dados.

3.4 GERAÇÃO DA SÉRIE TEMPORAL

A série temporal da receita, com base na qual se pretende aplicar os modelos matemáticos de previsão, será gerada de acordo com a necessidade de cada pesquisa. Se a intenção é de analisar o comportamento de municípios ou grupos de municípios, dever-se-ão fazer os agrupamentos necessários e gerar-se-ão tantas séries quantas forem necessárias ao estudo. Se o interesse é a análise dos dados do estado, a série estará pronta agrupando-se os dados de todos os municípios ou, caso o estudo já tenha previsto que não haveria a necessidade dos dados por município, possivelmente a fase de consolidação dos dados já terá resultado na série temporal a ser analisada.

Devido às características de cada série, esta pode ou não ser modelável. Se a série obtida não for modelável, o processo seguirá para a realização de uma previsão qualitativa; caso seja modelável, parte-se para a realização das previsões com modelos matemáticos.

3.4.1 *FORECASTING* QUALITATIVO

Detectado o fato de que a série não é modelável (uma série de ruído aleatório, por exemplo) ou a inexistência de dados (criação de um novo tributo), a previsão da receita deverá ser elaborada a partir de um método de *forecasting* qualitativo.

Neste caso, poder-se-á optar por algum dos métodos elencados na seção 2.4 desta dissertação. A decisão sobre qual o método mais adequado deve levar em consideração os recursos e tempo disponíveis para realização da previsão.

3.5 REALIZAÇÃO DA PREVISÃO COM MODELOS MATEMÁTICOS

A partir da definição de que a série é modelável, passa-se à fase da realização das previsões com aplicação dos modelos definidos. Devido às características de cada modelo, pode-se ainda optar por testar a série em diferentes condições, como com períodos de dados diferentes (número de observações), ou aplicar os modelos a mais de uma série (mais de um produto, serviço ou receita), quando isso for possível.

Para elaboração dos modelos pode-se utilizar diversos pacotes computacionais de previsão, como, por exemplo, o *Statgraphics*, *NCSS* e *ITSM*. Fatores que ajudam na escolha do software são a facilidade de operação, a relação custo/benefício oferecida e a possibilidade de expansão/adequação a novas necessidades. A utilização de mais de um pacote computacional, dadas as suas especificações técnicas, pode facilitar o manuseio dos dados e a subsequente obtenção dos resultados para determinados modelos de *forecasting*.

Somente após a aplicação de todos os modelos é possível avançar para o passo seguinte, a comparação dos resultados obtidos pelos modelos testados.

3.6 COMPARAÇÃO DOS RESULTADOS OBTIDOS

De posse dos resultados de previsão de cada modelo, bem como dos valores efetivamente realizados no período, deve-se elencar um ou mais critérios para comparação dos valores obtidos. Alguns dos critérios mais utilizados foram abordados na seção 2.5 desta dissertação.

3.7 ESCOLHA DO MODELO

Aplicados os critérios determinados, pode-se definir qual o modelo mais adequado para realizar as previsões da receita. Se houver diversos impostos e/ou taxas, estes podem ser tratados individualmente ou agrupados de acordo com o sistema ABC, como proposto por Pellegrini (2000) para agrupar produtos conforme sua relevância. Em ambos os casos dever-se-á indicar o modelo mais adequado para cada série analisada.

Da mesma forma, se o estudo for direcionado a verificar o desempenho de diferentes regiões do estado, será necessário detectar qual modelo mais se adapta a cada uma das séries temporais geradas.

3.8 IMPLANTAÇÃO E AVALIAÇÃO PERIÓDICA DO MODELO

Após escolha do modelo, deve-se recomendar a implantação do sistema de previsão. A partir deste momento, o usuário deverá atentar para a reavaliação periódica do estudo, pois a sua replicação poderá tanto validar as descobertas anteriores como indicar erros ou a existência de uma nova situação (ADYA, 2000). As novas análises poderão demonstrar que o mesmo modelo ainda apresenta o melhor ajuste para a série ou apontar uma nova alternativa.

Em alguns casos, as influências externas podem ser muito significativas. Em caso de mudanças muito grandes – a possibilidade de uma reforma tributária, por exemplo –, geradas por fatores dos quais não se tem controle, pode implicar em uma revisão emergencial do sistema. Após um determinado período, os modelos tenderão a assimilar a mudança e deverão apresentar resultados mais adequados à nova realidade.

Nesta hipótese, os modelos que não atribuem peso a observações mais recentes perderiam em acurácia comparados àqueles que incorporam esta informação para projeção dos valores futuros da série.

3.9 REALIZAÇÃO DA PREVISÃO E ANÁLISE DOS RESULTADOS OBTIDOS

Definido o modelo que será utilizado no *forecasting* dos valores de arrecadação do estado, atualiza-se a base de dados até a informação mais recente e gera-se a previsão para o período desejado.

De posse dos resultados apresentados pelo modelo, os especialistas deverão fazer uma análise prévia, pois fatores externos não presentes nas observações passadas podem alterar o valor da previsão. Se os especialistas concluírem que os dados apresentados pelo modelo são satisfatórios, o processo de realização de previsão estará terminado. Caso contrário, far-se-á necessária uma revisão dos valores de previsão.

3.9.1 REVISÃO DOS VALORES DE PREVISÃO - *FORECASTING* QUALITATIVO

Neste passo, os métodos qualitativos contribuirão para o melhor desempenho dos resultados obtidos a partir de modelos matemáticos.

Este passo pode ser de grande valia para os casos em que se tem conhecimento de um fator externo que influenciará o resultado da arrecadação no futuro, mas cujos efeitos não podem ser modelados a partir de uma série temporal. A realização de um programa de recuperação fiscal, por exemplo, é uma situação que não pode ser modelada de forma eficiente, necessitando da opinião de um especialista, ou de um grupo de especialistas, para julgar o impacto que terão sobre a arrecadação.

Posteriormente, os resultados auferidos como no exemplo acima, deverão ser expurgados da série de dados para previsões futuras, conforme analisado na seção 3.2.1. Somente não haverá depuração de dados se a alteração for no perfil da arrecadação e de caráter permanente, o que poderia ser resultado de uma alteração na legislação.

4 ESTUDO DE CASO

Neste capítulo é apresentado o caso da previsão da receita de ICMS no Estado do Paraná. Inicialmente apresenta-se um breve histórico das características do estado, bem com da evolução na abordagem do problema da previsão da receita. Em seguida, realiza-se a previsão da receita de ICMS do Estado do Paraná, seguindo os passos da seqüência proposta no Capítulo 3.

4.1 O ESTADO DO PARANÁ

O Produto Interno Bruto do Estado do Paraná – PIB/PR – tem crescido continuamente ao longo dos últimos 10 anos, conforme dados do IPARDES – Instituto Paranaense de Desenvolvimento Econômico e Social – apresentados na Tabela 9.

Tabela 9: Evolução Nominal do PIB/PR em R\$ milhões

Exercício	PIB/PR	Evolução Nominal
1994	21.304	-
1995	38.369	80,1%
1996	47.720	24,4%
1997	52.849	10,7%
1998	56.798	7,5%
1999	61.724	8,7%
2000	65.969	6,9%
2001	72.770	10,3%
2002	83.041	14,1%
2003 ⁽¹⁾	96.381	16,1%

Fonte: IPARDES ⁽¹⁾ Projetado.

O crescimento de 80,1% em 1995, muito acima dos valores alcançados nos demais exercícios explica-se pelo fato de que os valores do primeiros meses do exercício 1994 precisaram ser transformados em Reais, pois a moeda corrente até o mês de julho era o Cruzeiro Real. A participação do Paraná no PIB nacional foi de 6% no exercício 2000, mantendo-se como a quinta economia do país.

Os resultados obtidos do PIB/PR são superiores aos registrados pelo PIB nacional, conforme os dados da Confederação Nacional do Comércio, que demonstram que no período 1996 a 2003 houve crescimento real máximo de 4,4%, registrado no ano 2000. O

exercício 2003 foi o único a apresentar crescimento negativo do PIB, com -0,2%, muito próximo à estabilidade em relação ao exercício anterior.

Para efeitos de comparação, a Tabela 10 traz as informações da arrecadação de ICMS 100% no Estado do Paraná para o mesmo período e adotados os mesmos critérios de transformação de dados. Por ICMS 100% entende-se o valor total de ICMS arrecadado pelo estado, antes da destinação constitucional obrigatória da parcela de 25% para composição do Fundo de Participação dos Municípios – FPM.

Tabela 10: Evolução Nominal do ICMS 100% em R\$ milhões

Exercício	Arrecadação ICMS 100%	Evolução Nominal
1994	1.415	-
1995	2.475	74,9%
1996	2.882	16,4%
1997	2.871	-0,4%
1998	2.953	2,8%
1999	3.459	17,1%
2000	4.349	25,7%
2001	4.927	13,3%
2002	5.681	15,3%
2003	6.769	19,2%

Fonte: Coordenação da Receita do Estado

A arrecadação de ICMS 100% apresenta um comportamento similar ao do PIB/PR até o exercício 1996. A queda da arrecadação, em termos nominais, na comparação entre 1997 e 1996 deve-se à desoneração do ICMS nas operações de exportação de produtos básicos e semimanufaturados, com a entrada em vigor da Lei Complementar 87/96. Como compensação às perdas registradas por diversos estados, a União criou um fundo provisório para repasse de valores aos estados prejudicados com a referida lei. Porém, dadas as pressões políticas dos estados, os repasses continuam existindo, muito embora com valores muito menos significativos que nos primeiros anos após a aprovação da lei.

Alguns fatores podem explicar os consecutivos desempenhos da arrecadação a partir de 1999. A implantação de novos sistemas integrados e novas ferramentas de gerenciamento da informação *on-line* a partir de 1999 no âmbito da Receita Estadual, colaborando para a melhoria do desempenho dos Auditores Fiscais em suas atividades de combate à evasão fiscal.

Outro fator foi o crescimento da capacidade produtiva industrial. A publicação Crescimento, Reestruturação e Competitividade Industrial no Paraná 1985-2000 (IPARDES, 2002) aponta para um crescimento de 101,8% da capacidade instalada da indústria no Paraná no período 1990 – 1995 e de 14,6% no período 1995 – 2000. Os efeitos na arrecadação de ICMS somente aparecem mais tarde. Este fato pode ser explicado principalmente pela adoção de programas de incentivos fiscais que proporcionaram a dilação do prazo de recolhimento do imposto, retardando o retorno financeiro destes investimentos aos cofres públicos.

A economia de forma geral apresentou boas taxas de crescimento durante a década de 90. O estudo Paraná: Diagnóstico Social e Econômico (IPARDES, 2003) revela que o setor de serviços industriais e de utilidade pública – entenda-se distribuição de energia – teve o expressivo crescimento anualizado de 8,7% entre 1990 e 2000.

O aumento do consumo de energia deve-se, principalmente, ao aumento do parque industrial, pois a população paranaense cresceu, entre 1991 e 2000, a uma taxa anualizada de apenas 1,4%, chegando no ano 2000 com 9,6 milhões de habitantes. Neste mesmo período, repetiu-se o movimento migratório para os centros urbanos que ocorre desde a década de 70. Em 1991 havia 6,2 milhões de paranaenses residentes na zona urbana e 2,3 milhões na zona rural. Em 2000 eram 7,8 milhões nas cidades contra 1,8 milhão no campo.

Relativamente à legislação tributária estadual, a alteração mais significativa dos últimos 10 anos aconteceu através da aprovação e publicação da Lei n.º 13.410 em 26 de dezembro de 2001, surtindo seus efeitos no exercício fiscal 2002. Esta lei alterou a alíquota do ICMS nas operações internas de 17% para 18%; aumentou de 25% para 26% a alíquota incidente nas operações com gasolina e álcool combustível e de 25% para 27% a alíquota para as operações com energia elétrica, bebidas alcoólicas e fumo, bem como na prestação de serviços de comunicação.

4.2 PREVISÃO NO ESTADO DO PARANÁ

O primeiro passo na análise da previsão de receitas no Paraná, foi elaborado pela CAFE – Coordenação da Administração Financeira do Estado – por ocasião do I Simpósio sobre Metodologias de Previsão e Classificação de Receitas Públicas, em 1977. Nesta época, o então imposto sobre circulação de mercadorias – ICM (posteriormente alterado

para ICMS), era a principal fonte de recursos do estado, sendo o trabalho totalmente dedicado a analisar sua previsão.

A previsão era realizada separando a arrecadação em três grandes grupos de atividades econômicas – indústria, comércio e produtos primários. O ICM sobre produtos primários era projetado com base nas perspectivas de intenção de plantio. As justificativas para adoção deste modelo de previsão foi a suscetibilidade dos produtos primários às condições climáticas e as variações de preço nos mercados nacional e internacional. Deve-se lembrar que este foi um período da história econômica do país em que as oscilações inflacionárias e de cotação da moeda americana eram muito altas.

A previsão do valor do imposto relativo às atividades industriais e comerciais, embora calculada separadamente, seguia critério idêntico. Sugeria-se estimar os valores futuros de arrecadação a partir de uma série histórica de três ou mais exercícios, a preços constantes, ou seja, depois de retirado o fator inflação da série. A partir destes valores aplicava-se a taxa real de crescimento do setor na série e acrescentava-se uma taxa de inflação presumida, geralmente em concordância com os índices estimados pelo governo federal.

Outro estudo voltado à previsão da receita foi o documento apresentado sob o título de “Modelo de Evolução e Projeção Econômico-Financeiro Estadual” (IPARDES, 1979). O relatório apresenta um modelo de regressão para previsões de curto prazo. Dada a escassez de dados estatísticos no âmbito estadual, o modelo foi elaborado a partir dos dados da União para, posteriormente, realizar-se a desagregação dos valores para obtenção da previsão da receita estadual.

Este modelo era bastante complexo e levava em consideração a despesa interna, o consumo pessoal, os investimentos privados, os gastos governamentais, o saldo da balança comercial, as exportações e importações, os impostos diretos e indiretos e a evolução do Produto Interno Bruto – PIB.

Por fim, em 1986, a CAFE desenvolve um novo trabalho, distinguindo as previsões para o orçamento anual e para o fluxo de caixa diário. As estimativas de longo prazo, foco desta dissertação, eram elaboradas a partir do acompanhamento do desempenho dos setores mais representativos do ICM, do acompanhamento das medidas de política econômica, financeira e tributária e do confronto entre o desempenho da arrecadação efetiva

com os pressupostos adotados. Este último procedimento visava realizar correções nas estimativas iniciais.

Novamente realizam-se previsões separadas para cada um dos três grandes grupos de atividades econômicas. O trabalho enfatiza que, para os produtos primários, as estimativas devem ser realizadas com base nas séries históricas de produção, área plantada, estoques nacional e estadual, quotas de exportação, distribuição e vendas de sementes, entre outras. Além destes dados, as previsões relativas ao ICM sobre os produtos primários deveriam ainda considerar as previsões das safras, os preços praticados nas diversas etapas do processo de comercialização, análises de órgãos oficiais e privados, análise da política de preços mínimos, dentre muitos outros. Contudo, não se apresenta de forma clara como são considerados tantos fatores em um modelo matemático de previsão.

Seguindo a mesma linha apresentada para os produtos primários, as previsões para o ICM referente a atividades industriais e comerciais deveriam contemplar outra relação de dados, estatísticas e previsões. Entretanto, nenhum modelo é apresentado para realização dos cálculos pertinentes. Como inovação, o estudo trouxe informação sobre as demais receitas correntes do estado.

A Coordenação da Receita do Estado, através da Inspetoria Geral de Arrecadação, é hoje a responsável pela elaboração das previsões de receitas tributárias de longo e curto prazo.

As previsões de curto prazo são realizadas com base em consultas às empresas mais importantes dos setores de maior representatividade na arrecadação do ICMS. Com base nas informações prestadas por aproximadamente 300 empresas, o Setor de Análise e Previsão da Receita – SAPR – estima, de forma ponderada, o percentual de evolução da arrecadação de um mês para o outro e realiza a projeção diária de entrada de recursos para o Tesouro do Estado.

Para melhorar a acurácia do método, são feitas intervenções pontuais nas datas de arrecadação dos 5 maiores contribuintes do estado, que representam 47,9% da arrecadação total de ICMS no estado (LIEBEL & STACHERA FILHO, 2004). Estas intervenções podem ser consideradas um método de *forecasting* qualitativo utilizado de forma combinada com um modelo matemático que resultou na variação percentual prevista de arrecadação.

Os dados resultantes desta previsão de curto prazo servem de parâmetro para a realização das despesas do estado, bem como para o planejamento dos desenhos financeiros.

As previsões de longo prazo do ICMS, cujos resultados compõem os orçamentos anuais do estado bem como seus planos plurianuais, são elaboradas através de um modelo estrutural que considera quatro variáveis: (i) a previsão de evolução do PIB/PR, (ii) a previsão de inflação, (iii) os resultados das ações do fisco e (iv) o retorno dos programas de incentivo fiscal.

Estudos internos da Inspeção Geral de Arrecadação estimaram a relação entre a variação do PIB/PR e a arrecadação de ICMS em 55%, valor que tem sido utilizado juntamente com a previsão de evolução do PIB/PR sugerida pelo IPARDES. A relação utilizada se aproxima do obtido por Prud'homme (1998), cujo estudo encontrou um coeficiente de determinação (R^2) de 61% entre as mesmas variáveis.

A inflação é integralmente considerada no modelo, e a estimativa a ser utilizada tem sido resultado das reuniões entre os técnicos da Secretaria de Estado da Fazenda e do IPARDES. Geralmente a escolha recai sobre um dos índices apresentados pelos órgãos oficiais, como o Banco Central do Brasil, cuja previsão é decisiva para diversas ações dos governos federal e estadual.

As ações do fisco devem, conforme determinação interna, aumentar em 1%, no mínimo, o resultado esperado a partir das variáveis econômicas citadas. A princípio pode parecer pouco representativo, mas a proposta deste esforço fiscal, tomando por base a arrecadação do exercício 2003, é da ordem de R\$ 67,7 milhões.

Os resultados provenientes de programas de incentivo devem ser analisados à parte na previsão, pois dependem dos resultados das empresas que usufruem do benefício. As informações referentes a estes programas são obtidas junto à CAEC – Coordenação de Assuntos Econômicos.

Após todas as fases apresentadas, tem-se a previsão do ICMS de longo prazo. Novamente são necessários modelos matemáticos, combinados com métodos qualitativos para obtenção de resultado mais preciso nas projeções. Os cálculos do modelo de causa e efeito são

realizados em um planilha de cálculos do software Microsoft Excel. Nesta mesma planilha reservam-se alguns campos para inserções manuais de valores fora do modelo, como no exemplo apresentado no parágrafo anterior.

4.3 COLETA DE DADOS

A coleta dos dados foi realizada junto ao Setor de Análise e Previsão da Receita. Os dados fornecidos são apresentados na Tabela 11. Todos os valores da arrecadação do ICMS 100% são apresentados em R\$ milhões e em valores correntes. Espera-se testar de que forma os modelos absorverão a inflação, tendo em vista a relativa estabilidade que a economia tem experimentado após o Plano Real em 1994.

Tabela 11: Arrecadação de ICMS 100% no Paraná em R\$ milhões – 1997 a 2003

Mês	1997	1998	1999	2000	2001	2002	2003
Janeiro	256,9	263,6	267,9	358,5	276,0	293,8	513,3
Fevereiro	225,3	241,2	244,1	312,4	362,5	433,9	588,6
Março	226,5	236,4	256,7	320,6	357,8	426,2	573,1
Abril	243,8	250,0	287,1	334,4	409,7	470,8	566,4
Maiο	237,0	250,5	280,5	344,0	394,7	474,2	510,3
Junho	245,7	242,0	274,3	340,2	390,8	464,9	528,1
Julho	233,3	244,4	274,6	353,5	400,6	484,9	554,6
Agosto	234,7	237,1	291,8	349,5	383,9	500,2	559,2
Setembro	235,0	249,4	309,8	403,1	514,8	521,9	612,2
Outubro	242,0	239,2	325,5	365,0	432,0	522,1	521,6
Novembro	259,3	253,4	321,7	360,3	423,8	544,9	616,9
Dezembro	231,8	245,6	324,8	507,3	580,2	543,0	624,8
TOTAL	2.871,3	2.952,6	3.458,8	4.348,9	4.927,0	5.680,8	6.769,1

Fonte: Coordenação da Receita do Estado

Os dados coletados abrangem o período de 1997 a 2003. Os resultados do exercício 2003 serão a base de comparação de desempenho dos diversos modelos. Optou-se por este período para que houvesse suficientes observações para aplicação de todos os modelos estudados na seção 2.3.

Esta dissertação estudará somente os dados totais do estado, não se utilizando dos dados por município ou por Delegacia Regional da Receita, que são as unidades da administração tributária no Paraná. Ressalte-se que todos estes dados estariam disponíveis, caso fosse esse o intuito do trabalho, a partir do exercício de 1994.

Os dados referentes aos exercícios de 1994 e 1995 não foram incluídos neste estudo porque este período pode ser considerado de adaptação à nova política econômica, implantada a partir do Plano Real. Os índices de inflação demonstram que este foi um período transitório para a estabilidade alcançada nos anos seguintes. O IPC-A/IBGE apresentou variação de 916,5% em 1994 e 22,4% em 1995, enquanto o INPC/IBGE variou 929,3% e 22,0% respectivamente. Nos exercícios subsequentes, até 2003, nenhum destes índices apresentou variação anual superior a 15%.

O exercício de 1996 foi excluído da análise devido à aprovação e implantação da Lei Complementar 87/96, mais conhecida como Lei Kandir. Esta lei desonerou a exportação de produtos básicos e semimanufaturados da incidência do ICMS, gerando uma significativa perda de receita de ICMS para o Estado do Paraná a partir do mês de setembro de 1996.

Muito embora a inclusão deste exercício pudesse ser considerada mais um teste aos modelos, uma reação possível seria, durante a depuração da série de dados, eliminar os resultados da arrecadação de ICMS com exportações no período de janeiro a agosto de 1996. Tal atitude seria uma tentativa de analisar todo o conjunto de dados sob as mesmas condições. Além disso, os dados de arrecadação disponíveis deste período não contêm o nível de detalhamento necessário para identificação dos valores e posterior ajuste da série, forçando a opção pela exclusão do exercício 1996 deste estudo.

4.4 ANÁLISE DOS DADOS

Uma análise preliminar pode ser feita através do gráfico dos valores de arrecadação de ICMS 100% do período em estudo, apresentado na Figura 10. Ressalte-se que o objetivo desta Figura não é a identificação dos valores no gráfico, mas a comparação do comportamento das séries. Diversos pontos das séries ficaram sobrepostos, especialmente no período de março a agosto, o que representa, aparentemente, uma constância da série de arrecadação.

Verifica-se que, subtraída a média das observações, os dados de arrecadação têm uma variação relativamente pequena ao longo do ano. Contudo, chama a atenção no gráfico da Figura 10 o comportamento da arrecadação de dezembro dos exercícios 2000 e 2001, por apresentarem um crescimento que destoia do comportamento dos demais, e a

arrecadação do mês de janeiro dos exercícios 2001 e 2002, desta vez com um resultado muito inferior ao que se observa nos demais exercícios.




Figura 10: Gráfico dos dados de ICMS 100% após subtração da média – 1997 a 2003

Além disso, a existência de picos e vales nas linhas dos exercícios 2001, 2002 e 2003 parece indicar a existência de algum fato estranho à série, o que evidencia a necessidade de efetuar a depuração dos dados.

4.4.1 DEPURAÇÃO DOS DADOS

Aprofundando a análise dos dados de arrecadação, foi possível realizar diversas alterações na série original. A seguir, apresenta-se as razões pelas quais foram efetuadas tais alterações.

- Programas de recuperação de créditos fiscais: o objetivo de tais programas está claro já em sua denominação, recuperar créditos fiscais. O principal alvo tem sido o recolhimento de créditos já inscritos em Dívida Ativa, ou seja, que deveriam ter sido quitados já há algum tempo - pelo menos dois meses, que é o prazo de inscrição de um crédito pendente em Dívida Ativa. Houve realização deste tipo de programa nos exercícios 2000, 2002 e 2003, e seus resultados financeiros foram excluídos do valor da arrecadação para fins de depuração da série temporal. Como o prazo final para adesão aos referidos programas – e realização dos respectivos pagamentos com benefício – sempre ocorreu no mês de setembro, justificam-se os picos de arrecadação verificados para este mês na Figura 10. Porém, em todos

os exercícios foram aprovadas consecutivas prorrogações de prazo até o mês de dezembro, justificando, pelo menos em parte, a elevação dos valores da arrecadação entre outubro e dezembro, ainda que com resultados mais modestos, especialmente em 2002 e 2003.

- Mudança na legislação de importação: a legislação de importação, no que se refere ao pagamento do ICMS, foi alterada em fevereiro de 2003, exigindo do contribuinte o recolhimento do ICMS referente à operação no momento do desembaraço aduaneiro. Tal medida afetou sobremaneira a arrecadação em virtude da refinaria de petróleo do estado, que realiza importações freqüentes que envolvem recolhimentos significativos do imposto. Para ajustar a série, todos os recolhimentos foram deslocados para os meses em que deveria ter sido efetuado o recolhimento conforme a lei anterior, que previa o lançamento dos valores das importações em conta gráfica para recolhimento no mês subsequente ao da operação. Os picos nos meses de fevereiro e setembro de 2003 e os vales em maio e outubro do mesmo ano são devidos, em grande monta, à vigência desta legislação.

- Recolhimento decendial do imposto: no mês de dezembro dos exercícios de 2000 e 2001, por decisão do poder executivo, foi implantado o recolhimento decendial do imposto para algumas atividades econômicas. Isso significa que as empresas enquadradas nesta legislação passaram a apurar o imposto devido – e efetuar o respectivo recolhimento – a cada dez dias, quando esta operação é, tradicionalmente, mensal. O efeito foi o aumento de arrecadação no mês de dezembro e a conseqüente diminuição nos recolhimentos de janeiro do exercício seguinte. Para depuração da série temporal, os efeitos dessa legislação foram anulados pela transferência dos valores pagos em dezembro para a arrecadação do mês de janeiro.

- Pagamento extraordinário: em setembro de 2001 foi detectado um pagamento isolado de uma empresa que encerrou suas atividades no estado, e recolheu aos cofres do Tesouro Estadual de uma só vez todo o ICMS cujo prazo de recolhimento havia sido dilatado. Como este valor não advém de um crescimento da atividade econômica no estado e constitui-se fato isolado, foi suprimido da série durante a fase de depuração dos dados.

A Tabela 12 traz os valores de arrecadação do ICMS 100% do Estado do Paraná após tratamento dos casos excepcionais listados acima. A representação gráfica dos dados, após a subtração de suas respectivas médias anuais, pode ser encontrada na Figura 11.

Tabela 12: Arrecadação de ICMS 100% no Paraná em R\$ milhões após depuração – 1997 a 2003

Mês	1997	1998	1999	2000	2001	2002	2003
Janeiro	256,9	263,6	267,9	358,5	386,2	444,3	527,9
Fevereiro	225,3	241,2	244,1	312,4	362,5	433,9	541,6
Março	226,5	236,4	256,7	320,6	357,8	426,2	553,5
Abril	243,8	250,0	287,1	334,4	409,7	470,8	576,1
Maio	237,0	250,5	280,5	344,0	394,7	474,2	527,4
Junho	245,7	242,0	274,3	340,2	390,8	464,9	549,8
Julho	233,3	244,4	274,6	353,5	400,6	484,9	542,1
Agosto	234,7	237,1	291,8	345,7	383,9	500,2	568,6
Setembro	235,0	249,4	309,8	357,8	411,1	496,7	572,2
Outubro	242,0	239,2	325,5	352,8	432,0	486,7	562,6
Novembro	259,3	253,4	321,7	357,5	423,8	529,4	611,2
Dezembro	231,8	245,6	324,8	380,0	429,7	513,2	614,7
TOTAL	2.871,3	2.952,6	3.458,8	4.157,6	4.783,0	5.725,4	6.747,6

O resultado da depuração parece satisfatório, tendo em vista que todas as alterações feitas decorreram de fatos que justificam as intervenções realizadas na série temporal. A Figura 11 corrobora esta análise, pois apresenta linhas com comportamento bastante semelhante para todos os exercícios.




Figura 11: Gráfico dos dados de ICMS 100% após subtração da média e tratamento dos dados – 1997 a 2003

A escala utilizada neste gráfico é, propositadamente, a mesma do gráfico da Figura 10, para que se possa comparar visualmente o efeito do tratamento dos dados. Cabe

relembrar que os dados foram subtraídos de suas médias anuais, para facilitar tal comparação, não sendo função desta figura a informação de valores de arrecadação, outrossim, do comportamento da série nos exercícios analisados.

4.5 CONSOLIDAÇÃO DA BASE DE DADOS

Como não há necessidade de agregação ou desagregação de valores, os dados obtidos na fase de depuração dos dados – Tabela 12 – já representam a base de dados consolidada. Todas as operações descritas foram executadas utilizando-se o software Microsoft Excel, especialmente pela facilidade com que se podem transferir os dados para os software de previsão.

4.6 GERAÇÃO DAS SÉRIES TEMPORAIS

Nesta fase foram geradas duas séries temporais. Uma que compreende os dados de 1997 a 2002, com 72 observações, e outra com os dados de 2000 a 2002, com 36 observações. Com isso, pretende-se analisar o comportamento dos modelos em duas situações distintas: a modelagem de uma série que traz um número considerado suficiente para operar com qualquer modelo matemático de previsão e a modelagem de uma série que apresenta apenas os dados mais recentes.

A análise da série de 72 observações é necessária porque contempla a situação estabelecida, ou seja, legislação sem maiores alterações nos últimos anos e dados disponíveis para realização da previsão.

Entretanto, com a possibilidade de uma reforma tributária, deve-se estar preparado para realizar previsões com séries menores de dados – talvez com um número ainda menor do que 36 observações. Neste caso, busca-se verificar o quão significativamente os modelos têm seus resultados alterados e qual, dentre os testados nesta dissertação, apresentam melhor acurácia nestas condições.

4.7 REALIZAÇÃO DA PREVISÃO COM MODELOS MATEMÁTICOS

Nesta seção são aplicados os modelos matemáticos de previsão analisados nesta dissertação. Para cada modelo serão efetuados os cálculos de previsão, cujos resultados são apresentados de forma gráfica. Para facilitar a comparação, os gráficos trazem a série de

dados da arrecadação de ICMS utilizada na geração da previsão, acrescida dos valores efetivos da arrecadação de ICMS do exercício 2003, e, em destaque, os valores projetados pelo modelo.

Inicialmente são apresentadas graficamente, nas Figuras 12 e 13, as duas séries utilizadas na geração das previsões, cujos valores constam da Tabela 12. A diferença reside no fato de que a série com 72 observações – doravante denominada série 72 – abrange o período 1997 a 2002, e a série com 36 observações – série 36 – apenas o período compreendido entre 2000 e 2002.




Figura 12: Gráfico da Série 72

A análise visual das séries permite verificar a diferença de comportamento entre elas. A série 72 apresenta, no período de janeiro/1997 a julho/1999 um comportamento de padrão horizontal, apresentando uma tendência de crescimento após agosto/1999.

A série 36, por sua vez, apresenta um claro padrão de tendência, o que poderá resultar em melhor ajuste no modelo de regressão linear e na suavização exponencial de Holt, dois modelos adequados a este tipo de série. Aparentemente, nenhum padrão sazonal pode ser imediatamente identificado.

Os resultados detalhados de cada modelo de previsão são apresentados nos Anexos A e B, referentes às séries 72 e 36 respectivamente.

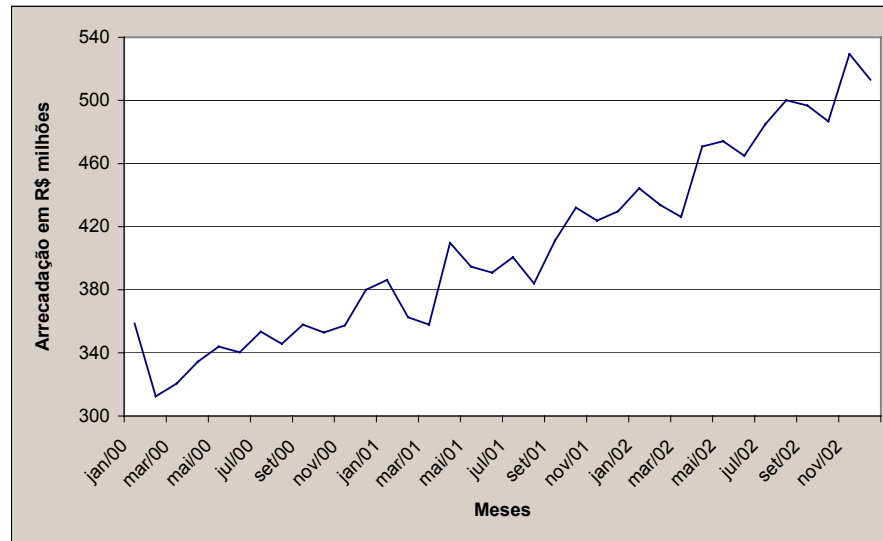


Figura 13: Gráfico da Série 36

4.7.1 REGRESSÃO LINEAR

Somente será testada a regressão linear simples, por não ser intuito deste trabalho relacionar a evolução do ICMS com outras variáveis que explicariam seu comportamento.

O modelo de regressão linear foi obtido utilizando-se a planilha de cálculo Microsoft Excel. Ainda que se trate do modelo mais simples de previsão abordado neste trabalho, seus resultados são relevantes por ser a técnica de *forecasting* mais utilizada na atualidade, como mencionado na seção 2.3.1.

A previsão obtida para a série 72 é apresentada na Figura 14 juntamente com os dados da série, e percebe-se o impacto das observações iniciais na inclinação da reta. A tendência de crescimento apresentada nos três últimos exercícios, justifica o fato dos valores projetados terem sido subestimados.

O coeficiente de determinação da reta foi de 0,9231, apresentando um ajuste satisfatório. O EMP do modelo alcançou 10,4%, reforçando a constatação gráfica de que o modelo subestimou a arrecadação.

A mesma técnica foi utilizada para obtenção do modelo para a série 36. O menor número de observações da série fez com que os resultados fossem inferiores aos obtidos com a série 72. Embora o coeficiente de determinação tenha sido muito próximo ao

da série anterior, de 0,9292, o EMP resultou em 4,1%. O gráfico do modelo é apresentado na Figura 15.




Figura 14: Gráfico da Regressão Linear Simples – Série 72




Figura 15: Gráfico da Regressão Linear Simples – Série 36

O resultado superior deste modelo já era esperado, devido ao padrão de tendência bem definido apresentado pela série 36. Embora melhor ajustado à série, ainda subestimou os resultados efetivos de arrecadação. Isso pode indicar um aumento na tendência de crescimento da arrecadação em 2003.

4.7.2 SUAVIZAÇÃO EXPONENCIAL SIMPLES

Todos os modelos apresentados a partir desta seção foram gerados com a utilização do *software* NCSS. Dentre as diversas estatísticas apresentadas no estudo dos modelos de *forecasting*, o NCSS informa o pseudo-coeficiente de determinação, equivalente ao coeficiente de determinação apresentado nos modelos de regressão e representado também por R^2 .

A suavização exponencial simples, por não considerar os padrões de tendência e sazonalidade, apresentou uma projeção baseada apenas no nível da série, utilizando para tal a última observação existente. Como a metodologia é a mesma para as duas séries, os valores previstos foram idênticos.

Os modelos apresentaram um EMP de 8,4%, superando a previsão fornecida pelo modelo de regressão linear para a série 72. Embora o padrão de tendência seja bastante claro na série 36, conforme explicado na seção 4.7, decidiu-se pela aplicação do modelo de suavização exponencial simples, que deve apresentar um ajuste inferior aos modelos que consideram o padrão de tendência em suas formulações, apenas para possibilitar sua comparação com os demais modelos testados. Os resultados gráficos das séries 72 e 36 são apresentados nas Figuras 16 e 17, respectivamente.




Figura 16: Gráfico da Suavização Exponencial Simples – Série 72

A estimação do R^2 , no entanto, proporcionou resultados diferentes para as duas séries analisadas. Isto acontece porque a estimação utiliza todos os dados da série. A série 72 apresentou um coeficiente de 0,9636, enquanto que a série 36 obteve o valor de 0,8978. Os altos valores se justificam pelo fato de que cada projeção do período $t+1$ é igual à última observação. Como os valores da arrecadação não apresentam variação percentual significativa entre um mês e seu subsequente, os valores calculados para o índice são próximos a 1.




Figura 17: Gráfico da Suavização Exponencial Simples – Série 36

4.7.3 SUAVIZAÇÃO EXPONENCIAL – HOLT

Espera-se que o modelo de Holt, por levar em consideração o padrão de tendência, apresente melhores resultados que a suavização exponencial simples.

O modelo de Holt, para a série 72, apresentou um R^2 de 0,9721 e um EMP de -1,5%. Observe-se que, dentre os modelos testados até o momento, este é o primeiro que apresenta uma projeção acima do valor efetivamente realizado. A capacidade deste modelo de ajustar-se à curvatura dos dados pode ter contribuído de maneira decisiva na obtenção do resultado verificado.

Na série 36, o modelo de Holt mostrou-se igualmente competente na realização da previsão. Ao ser aplicado a esta série, apresentou R^2 de 0,9195, inferior ao da série

anterior. Contudo, o EMP obtido foi de -0,7%, um índice duas vezes mais acurado que com a série 72.

Uma possível explicação para a diferença verificada na acurácia das projeções das duas séries pode estar na manifestação mais pronunciada do padrão de tendência entre os exercícios 2000 e 2002, que compõem a série 36. Os gráficos apresentados nas Figuras 18 e 19 parecem confirmar esta suspeita.




Figura 18: Gráfico da Suavização Exponencial de Holt – Série 72




Figura 19: Gráfico da Suavização Exponencial de Holt – Série 36

4.7.4 SUAVIZAÇÃO EXPONENCIAL – WINTERS MULTIPLICATIVO

Os modelos de Winters levam em consideração a sazonalidade, o que pode levá-lo a resultados ainda mais significativos que aqueles dos modelos já testados, caso exista de fato um padrão sazonal nos dados analisados.

A modelagem da série 72 usando o modelo de Winters multiplicativo resultou em um R^2 de 0,9804, enquanto o EMP foi de 0,5%. Como não há evidências da existência de um padrão sazonal, a obtenção de um resultado um pouco melhor pode ser devida ao fato de que os modelos de Winters utilizam mais parâmetros do que o modelo de Holt.

Embora fosse possível esperar um comportamento semelhante ao da série 72, a modelagem de Winters em sua versão multiplicativa resultou em um R^2 na série 36 de 0,9804, enquanto o EMP foi de -2,5%. Certamente não é um resultado ruim, mas destoa da melhoria obtida com a série 72. Neste caso, a maior quantidade de parâmetros em relação ao modelo de Holt parece não ter surtido o mesmo efeito que na série 72. Pode também indicar que não há padrão de sazonalidade na série, ou se existir, deve ser muito menos significativo que o padrão de tendência, de acordo com os resultados observados neste trabalho.

As Figuras 20 e 21 apresentam os resultados obtidos nas projeções do modelo de Winters multiplicativo para as séries 72 e 36, respectivamente. Observe-se que este é o primeiro modelo cujas projeções não seguem uma tendência linear.




Figura 20: Gráfico da Suavização Exponencial de Winters multiplicativo – Série 72




Figura 21: Gráfico da Suavização Exponencial de Winters multiplicativo – Série 36

4.7.5 SUAVIZAÇÃO EXPONENCIAL – WINTERS ADITIVO

O modelo aditivo de Winters aplicado à série 72 demonstrou grau de ajuste semelhante ao modelo multiplicativo. Seu R^2 foi igual a 0,9806, e o EMP ficou em 0,4%. Considerando-se que o número de parâmetros é o mesmo, e que são variações de um mesmo modelo, parece razoável que apresentem resultados similares. O gráfico dos valores projetados pelo modelo de Winters multiplicativo para a série 72 é apresentado na Figura 22.




Figura 22: Gráfico da Suavização Exponencial de Winters aditivo – Série 72

A modelagem da série 36 com Winters aditivo apresentou um R^2 de 0,9550. Da mesma forma verificada no resultado obtido com o modelo de Winters multiplicativo, o EMP de -2,3% para a série 36 foi mais elevado do que o obtido com o modelo de Holt.

A Figura 23 apresenta o gráfico dos valores projetados pelo modelo de Winters multiplicativo para a série 36. Percebe-se, visualmente, que o ajuste é melhor para a série 72, onde as previsões para alguns meses parecem se sobrepor aos valores efetivamente arrecadados de ICMS.




Figura 23: Gráfico da Suavização Exponencial de Winters aditivo – Série 36

4.7.6 DECOMPOSIÇÃO

A análise do modelo de decomposição deve permitir confirmar ou não a presença de padrões que, através dos resultados de outros modelos, inferiu-se existirem. A Figura 24 mostra o resultado apresentado pelo *software* NCSS na aplicação do modelo de decomposição sobre a série 72. A escolha deve-se ao fato de ser mais fácil visualizar os padrões nos gráficos de uma série de dados mais longa.

A análise da Figura 24 deixa claro que o padrão dominante na série é a tendência, seguida do padrão cíclico. O gráfico do erro apresenta valores quase tão significativos quanto os do padrão sazonal, o que pode indicar que este padrão não deve ser tão relevante quanto os demais na formulação da previsão dos valores futuros. O padrão de

erro apresentado pode prejudicar o resultado da previsão, piorando o ajuste do modelo às séries temporais estudadas.

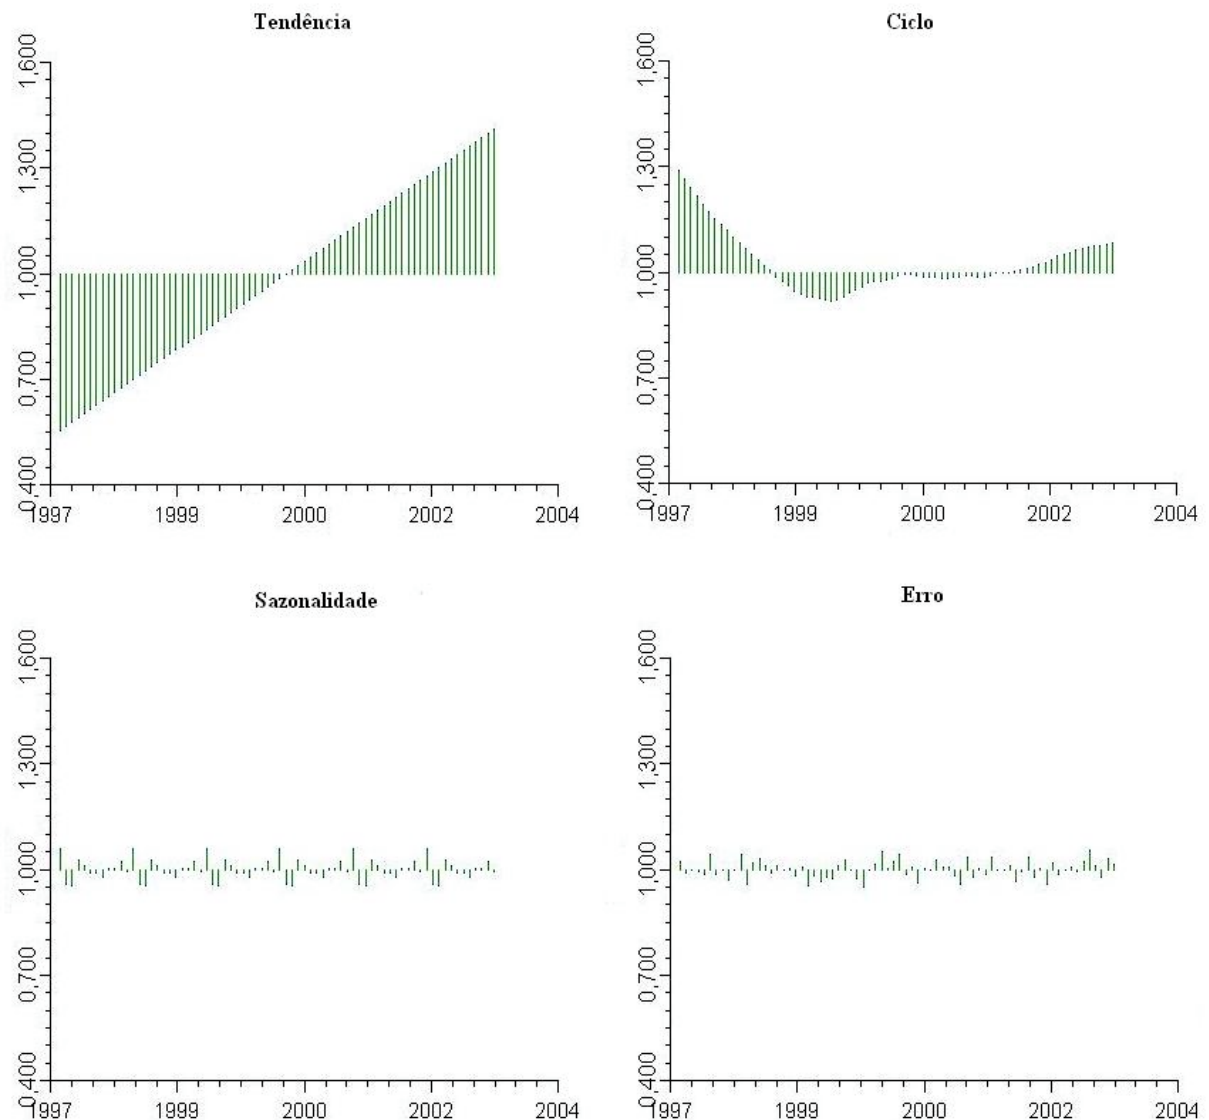


Figura 24: Gráficos dos padrões da Série 72

A modelagem da série 72 por decomposição resultou em um R^2 de 0,9912. Porém o EMP ficou em 11,9%, confirmando a suspeita de que o erro apresentado na Figura 24 poderia interferir no resultado da previsão.

Na aplicação do modelo de decomposição nos dados da série 36, houve queda no valor do R^2 , que resultou em 0,9762. O resultado do EMP, porém, melhorou, registrando

4,8%. A resposta para isso pode estar no componente de erro, que apresentou índices menores do que aqueles retratados na série 72.

As Figuras 25 e 26 apresentam os gráficos das séries 72 e 36, respectivamente, e os resultados obtido de previsão com o modelo de decomposição. Dentre os modelos analisados, este foi o que teve o resultado mais afetado pela diferença no número de observações, com vantagem para a série 36.




Figura 25: Gráfico da Decomposição – Série 72




Figura 26: Gráfico da Decomposição – Série 36

4.7.7 MODELOS DE BOX-JENKINS

De acordo com o que foi revisado no Capítulo 2, os modelos de Box-Jenkins merecem um tratamento diferenciado antes da realização das previsões. Além disso, como é provável que haja um número razoável de modelos que devam ser testados, somente será apresentado o gráfico de resultados do modelo que obtiver maior acurácia para cada uma das séries.

4.7.7.1 SÉRIE 72

A análise da representação gráfica da série de arrecadação de ICMS com 72 observações – apresentada na Figura 12, seção 4.7 – aponta para a não-estacionariedade na média. A identificação dos modelos será feita a partir da análise dos gráficos da FAC e FACP da série, apresentados nas Figuras 27 e 28, respectivamente. Para a série 72 os gráficos foram elaborados com os 40 primeiros coeficientes de autocorrelação – r_1 a r_{40} .

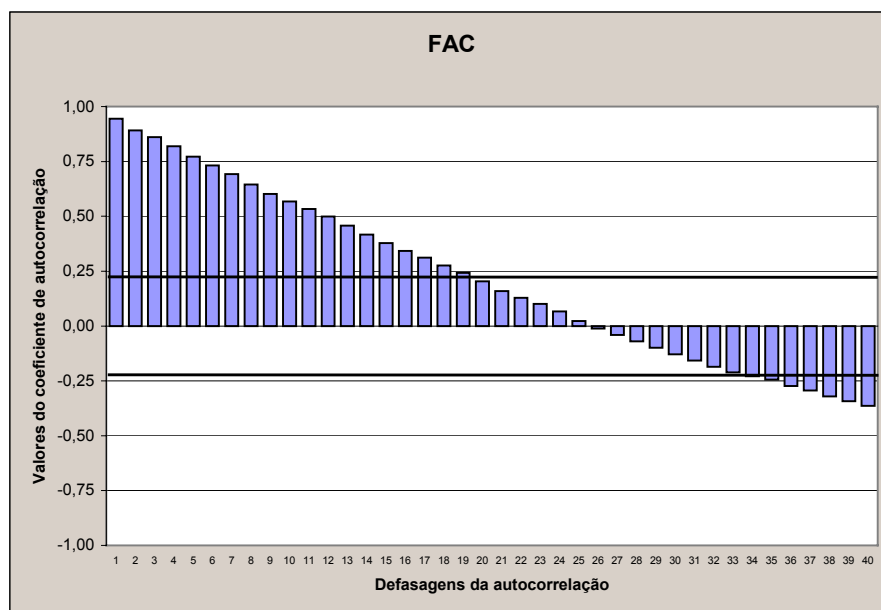


Figura 27: Gráfico da Função de Autocorrelação da Série 72




Figura 28: Gráfico da Função de Autocorrelação Parcial da série 72

O gráfico da FAC, bem como o fato de a primeira autocorrelação parcial ser muito próxima de 1, confirmam a não-estacionariedade da série. O procedimento indicado para prosseguir com a análise é a realização da diferenciação de primeira ordem. O gráfico da série resultante está apresentado na Figura 29. Os resultados da FAC e FACP após a primeira diferenciação são apresentados nas Figuras 30 e 31, respectivamente.




Figura 29: Série gerada após a diferenciação de primeira ordem da Série 72




Figura 30: Gráfico da Função de Autocorrelação da Série 72 após a diferenciação de primeira ordem




Figura 31: Gráfico da Função de Autocorrelação Parcial da Série 72 após a diferenciação de primeira ordem

A análise do gráfico da Figura 29 apresenta alguns picos, o que pode ser um indicativo de sazonalidade. Isso é confirmado pelo gráfico da FAC, que apresenta valores de r_{12} e r_{24} acima do limite crítico. Confirmada a existência de sazonalidade na série, identifica-

se que o modelo genérico para a série terá a forma SARIMA $(p,1,q) \times (P,0,Q)_{12}$, sendo ainda necessário estimar os valores de p , q , P e Q para efetuar os testes dos modelos.

Com base nas propriedades apresentadas nas Tabelas 6 e 7 e no resultado gráfico obtido da FAC, observa-se que a série apresenta decaimento oscilatório com picos nas defasagens sazonais. O comportamento verificado direciona a análise para modelos SARIMA $(1,d,0) \times (P,D,0)_{12}$ ou $(1,d,0) \times (0,D,Q)_{12}$. Tendo em vista que os valores de d e D já foram identificados, somente resta estimar os valores de P e Q .

Entretanto, considerando que pode ser difícil decidir qual modelo é o mais apropriado para uma série de dados (MAKRIDAKIS *et al.*, 1998), sugere-se a aplicação dos modelos com as variáveis P e Q assumindo valores entre 0 e 2, evitando o modelo em que ambos seriam igual a 0, pois isso retiraria o componente sazonal da projeção. Desta forma, conclui-se a definição dos modelos SARIMA que devem ser aplicados na realização de previsão para a série 72.

Os resultados obtidos pelos modelos selecionados e seus respectivos coeficiente de determinação e EMP são apresentados na Tabela 13.

Tabela 13: Resultado dos modelos SARIMA – Série 72

Modelo	R^2	EMP
$(1,1,0) \times (0,0,1)_{12}$	0,9683	5,0%
$(1,1,0) \times (0,0,2)_{12}$	0,9773	4,0%
$(1,1,0) \times (1,0,0)_{12}$	0,9730	2,4%
$(1,1,0) \times (1,0,1)_{12}$	0,9761	2,2%
$(1,1,0) \times (1,0,2)_{12}$	0,9789	4,0%
$(1,1,0) \times (2,0,0)_{12}$	0,9777	2,6%
$(1,1,0) \times (2,0,1)_{12}$	0,9785	1,6%
$(1,1,0) \times (2,0,2)_{12}$	0,9802	5,6%

Os resultados demonstram que o modelo que apresentou o melhor coeficiente de determinação não obteve o menor erro médio percentual. Como este último é um dos critérios de comparação de modelos de previsão, conclui-se que o modelo SARIMA $(1,1,0) \times (2,0,1)_{12}$ foi o mais acurado para a série 72. O gráfico das previsões deste modelo é apresentado na Figura 32.




Figura 32: Gráfico do modelo SARIMA $(1,1,0) \times (2,0,1)_{12}$ – Série 72

4.7.7.2 SÉRIE 36

A série com 36 observações – Figura 13 – apresentou comportamento idêntico à primeira série analisada. Seus gráficos da FAC e FACP iniciais sugerem a necessidade de diferenciação. O resultado da diferenciação de primeira ordem foi uma série estacionária. Conforme apresentado nas Figuras 33 e 34, nenhum coeficiente de autocorrelação ou de autocorrelação parcial atingiu valores significativos (ou seja, todos os valores ficaram dentro do limite crítico).

O resultado corrobora com a exigência de pelo menos 50 observações para aplicação dos modelos ARIMA. Como não há autocorrelações significativas, o padrão de sazonalidade verificado na série 72 não pode ser detectado a partir da análise do gráfico da FAC. Desta forma, opta-se pela aplicação dos mesmos modelos identificados para a série com 72 observações, para permitir a comparação dos resultados, os quais são apresentados na Tabela 14.

A série 36 deixa mais explícito em seus resultados que não há relação entre a acurácia apontada pelo EMP e o coeficiente de determinação calculado pelo *software*. Embora vários modelos tenham tido resultados próximos, selecionou-se o modelo SARIMA $(1,1,0) \times (1,0,1)_{12}$, que apresentou maior acurácia, com um EMP igual a 2,1%.




Figura 33: Gráfico da Função de Autocorrelação da série 36 após a diferenciação de primeira ordem





Figura 34: Gráfico da Função de Autocorrelação Parcial da série 36 após a diferenciação de primeira ordem

Tabela 14: Resultado dos modelos SARIMA – Série 36

Modelo	R^2	EMP
$(1,1,0) \times (0,0,1)_{12}$	0,9218	4,6%
$(1,1,0) \times (0,0,2)_{12}$	0,9290	2,3%
$(1,1,0) \times (1,0,0)_{12}$	0,9195	2,4%
$(1,1,0) \times (1,0,1)_{12}$	0,9221	2,1%
$(1,1,0) \times (1,0,2)_{12}$	0,9280	4,0%
$(1,1,0) \times (2,0,0)_{12}$	0,9233	2,8%
$(1,1,0) \times (2,0,1)_{12}$	0,9297	2,5%
$(1,1,0) \times (2,0,2)_{12}$	0,9522	6,7%

A partir dos resultados obtidos para a série 36, pode-se concluir que os modelos de Box-Jenkins também podem ter um bom desempenho na previsão de valores de séries com menos de 50 observações. Os resultados obtidos pelo modelo SARIMA $(1,1,0) \times (1,0,1)_{12}$ estão representados graficamente na Figura 35.

**Figura 35:** Gráfico do modelo SARIMA $(1,1,0) \times (1,0,1)_{12}$ – Série 36

4.8 COMPARAÇÃO DOS RESULTADOS OBTIDOS

Os resultados obtidos por todos os modelos serão comparados através da utilização de dois critérios: o EMP, já utilizado para demonstrar o grau de acurácia dos modelos ao longo deste capítulo, e o MQE, que serve para confirmar a precisão do modelo medida pelo EMP, ou como critério de desempate, em casos onde isso ocorre.

As Tabelas 15 e 16 apresentam os resultados obtidos pelos modelos para a série 72 e para a série 36, respectivamente. Cada modelo tem seus respectivos R^2 , EMP e MQE elencados para análise.

Verifica-se que, relativamente ao coeficiente de determinação, somente para o modelo de regressão linear, a série 36 obteve um resultado melhor. Assim, pode-se dizer que a série 72 se ajusta melhor aos demais modelos testados.

Tabela 15: Comparação de Modelos – Série 72

Modelo	R^2	EMP	MQE
Regressão Linear Simples	0,9231	10,4%	3.873,64
Suavização Exponencial Simples	0,9721	8,4%	3.069,44
Suavização Exponencial - Holt	0,9636	-1,5%	372,88
Suavização Exponencial - Winters Multiplicativo	0,9804	0,5%	424,78
Suavização Exponencial - Winters Aditivo	0,9806	0,4%	342,28
Decomposição	0,9912	11,9%	5.035,12
SARIMA (1,1,0)×(0,0,1) ₁₂	0,9683	5,0%	1.329,90
SARIMA (1,1,0)×(0,0,2) ₁₂	0,9773	4,0%	913,76
SARIMA (1,1,0)×(1,0,0) ₁₂	0,9730	2,4%	548,39
SARIMA (1,1,0)×(1,0,1) ₁₂	0,9761	2,2%	524,15
SARIMA (1,1,0)×(1,0,2) ₁₂	0,9789	4,0%	1.003,69
SARIMA (1,1,0)×(2,0,0) ₁₂	0,9777	2,6%	633,50
SARIMA (1,1,0)×(2,0,1) ₁₂	0,9785	1,6%	444,13
SARIMA (1,1,0)×(2,0,2) ₁₂	0,9802	5,6%	1.687,64

Quando trata-se do erro médio percentual, a maior diferença de acurácia foi detectada no modelo de decomposição, com desempenho 7,1% superior quando aplicado na série 36. Ao desconsiderar-se os modelos cuja diferença de acurácia foi inferior a 1% na comparação das séries 72 e 36, restam apenas seis modelos. Destes modelos, três obtiveram melhor acurácia para a série 72 e três para a série 36.

A média quadrada dos erros é uma segunda estatística utilizada aqui, e poderia ser útil se fosse necessário, por exemplo, escolher apenas entre os modelos SARIMA $(1,1,0) \times (0,0,2)_{12}$, $(1,1,0) \times (1,0,0)_{12}$ e $(1,1,0) \times (2,0,1)_{12}$, que apresentaram valores do EMP muito próximos para a série 36. Contrariamente ao que seria a escolha pelo EMP, o MQE indica que o modelo de melhor ajuste à série é o $(1,1,0) \times (1,0,0)_{12}$.

Tabela 16: Comparação de Modelos – Série 36

Modelo	R^2	EMP	MQE
Regressão Linear Simples	0,9292	4,1%	876,02
Suavização Exponencial Simples	0,9195	8,4%	3.069,44
Suavização Exponencial - Holt	0,8978	-0,7%	330,08
Suavização Exponencial - Winters Multiplicativo	0,9468	-2,5%	716,51
Suavização Exponencial - Winters Aditivo	0,9550	-2,3%	606,31
Decomposição	0,9762	4,8%	1.223,33
SARIMA $(1,1,0) \times (0,0,1)_{12}$	0,9218	4,6%	1.181,37
SARIMA $(1,1,0) \times (0,0,2)_{12}$	0,9290	2,3%	651,31
SARIMA $(1,1,0) \times (1,0,0)_{12}$	0,9195	2,4%	541,35
SARIMA $(1,1,0) \times (1,0,1)_{12}$	0,9221	2,1%	496,67
SARIMA $(1,1,0) \times (1,0,2)_{12}$	0,9280	4,0%	985,58
SARIMA $(1,1,0) \times (2,0,0)_{12}$	0,9233	2,8%	642,63
SARIMA $(1,1,0) \times (2,0,1)_{12}$	0,9297	2,5%	593,13
SARIMA $(1,1,0) \times (2,0,2)_{12}$	0,9522	6,7%	2.637,44

Na série 72 há outra situação em que a utilização do critério MQE é imprescindível. Qual a melhor modelagem para esta série entre SARIMA $(1,1,0) \times (0,0,2)_{12}$ e $(1,1,0) \times (1,0,2)_{12}$? Os valores do R^2 são muito próximos e os do EMP, idênticos até a primeira casa decimal. Nesta situação, optar-se-ia pelo modelo $(1,1,0) \times (0,0,2)_{12}$.

Outro fato importante que pode ser verificado nas duas séries de arrecadação analisadas é que os modelos de Box-Jenkins – mais complexos – não obtiveram resultados superiores a alguns modelos de suavização.

4.9 ESCOLHA DO MODELO

Embora não tenha sido identificado um padrão sazonal relevante nas séries estudadas, os resultados apresentados na seção anterior indicam que o modelo de suavização exponencial de Winters aditivo é o mais indicado para realização das previsões de ICMS no Estado do Paraná no caso da série 72.

Para a série 36, o modelo escolhido é o de suavização exponencial de Holt. A identificação deste modelo é útil como preparação para eventuais mudanças – reforma tributária, nova legislação estadual ou uma alteração do cenário econômico – que tenham impacto significativo sobre os valores da arrecadação de ICMS no Estado do Paraná. Também serve como teste para aplicações em séries com menor quantidade de dados conhecidos.

4.10 IMPLANTAÇÃO E AVALIAÇÃO PERIÓDICA DO MODELO

Recomenda-se a implantação do modelo de suavização exponencial Winters aditivo para a previsão de valores futuros da arrecadação de ICMS no Estado do Paraná. As avaliações periódicas deverão ocorrer a intervalos máximos de 3 exercícios. Porém, os integrantes do Setor de Análise e Previsão da Receita certamente utilizarão seus conhecimentos para identificar a necessidade de revisão do sistema a qualquer tempo – inclusive durante um exercício, para reavaliação das metas traçadas.

4.11 REALIZAÇÃO DA PREVISÃO E ANÁLISE DOS RESULTADOS OBTIDOS

Com base nos resultados obtidos, pode-se recomendar a implantação dos modelos escolhidos inclusive para os meses restantes do exercício 2004. Para validar – ou não – os modelos escolhidos, decidiu-se proceder uma previsão para os meses do exercício 2004 com resultado de arrecadação já conhecido. O foco do estudo foi o exercício 2003 com o intuito de colocar à prova as previsões para uma estação completa.

As comparações para o exercício 2004 utilizaram os mesmos modelos identificados anteriormente. Ressalte-se que, para o melhor funcionamento dos modelos de Box-Jenkins, o ideal seria a repetição da análise de estacionariedade das séries e nova identificação dos modelos.

Os meses do exercício 2004 com dados consolidados e disponíveis – janeiro a setembro – passaram pela mesma análise e depuração de dados apresentada com detalhes na seção 4.4.1. A Tabela 17 traz os dados originais de arrecadação de ICMS do Estado do Paraná e a Tabela 18 os valores após a depuração dos dados.

As séries analisadas para projeção dos valores referentes ao exercício 2004 foram acrescidas do exercício 2003, resultando em uma série com 84 observações – série 84 – e outra série com 48 observações – série 48, apresentadas, respectivamente, nas Figuras 36 e 37.

Tabela 17: Arrecadação de ICMS 100% no Paraná em R\$ milhões – 2004

Mês	Arrecadação
Janeiro	689,3
Fevereiro	621,7
Março	665,2
Abril	646,0
Maio	612,0
Junho	650,4
Julho	580,4
Agosto	682,1
Setembro	772,2

Fonte: Coordenação da Receita do Estado

Tabela 18: Arrecadação de ICMS 100% no Paraná em R\$ milhões após depuração – 2004

Mês	Arrecadação após depuração
Janeiro	633,8
Fevereiro	621,7
Março	600,8
Abril	642,6
Maio	632,1
Junho	624,1
Julho	625,3
Agosto	669,5
Setembro	684,5




Figura 36: Gráfico da Série 84




Figura 37: Gráfico da Série 48

Os resultados obtidos na projeção dos dados de arrecadação de ICMS para o período de janeiro a setembro do exercício 2004, com a aplicação dos modelos testados anteriormente, são apresentados nas Tabelas 19 e 20, para as série 84 e 48, respectivamente.

O detalhamento mensal das previsões realizadas para a série 84 está disponível no Anexo C deste trabalho, e as previsões referentes à série 48 são apresentadas no Anexo D.

Tabela 19: Comparação de Modelos – Série 84

Modelo	R^2	EMP	MQE
Regressão Linear Simples	0,9372	9,1%	3.783,61
Suavização Exponencial Simples	0,9757	4,4%	1.424,77
Suavização Exponencial - Holt	0,9816	-0,3%	325,70
Suavização Exponencial - Winters Multiplicativo	0,9818	-0,3%	214,08
Suavização Exponencial - Winters Aditivo	0,9827	-0,1%	268,32
Decomposição	0,9914	10,3%	4.615,77
SARIMA (1,1,0)×(0,0,1) ₁₂	0,9794	2,3%	794,91
SARIMA (1,1,0)×(0,0,2) ₁₂	0,9838	-1,0%	360,40
SARIMA (1,1,0)×(1,0,0) ₁₂	0,9818	0,5%	425,90
SARIMA (1,1,0)×(1,0,1) ₁₂	0,9826	-0,2%	282,37
SARIMA (1,1,0)×(1,0,2) ₁₂	0,9841	-2,4%	521,82
SARIMA (1,1,0)×(2,0,0) ₁₂	0,9829	-0,5%	258,39
SARIMA (1,1,0)×(2,0,1) ₁₂	0,9837	-0,9%	294,16
SARIMA (1,1,0)×(2,0,2) ₁₂	0,9841	-0,5%	378,88

Tabela 20: Comparação de Modelos – Série 48

Modelo	R^2	EMP	MQE
Regressão Linear Simples	0,9581	2,9%	685,55
Suavização Exponencial Simples	0,9446	4,2%	1.356,63
Suavização Exponencial - Holt	0,9566	-1,1%	373,80
Suavização Exponencial - Winters Multiplicativo	0,9587	0,1%	216,87
Suavização Exponencial - Winters Aditivo	0,9609	0,1%	263,47
Decomposição	0,9806	2,9%	599,69
SARIMA (1,1,0)×(0,0,1) ₁₂	0,9574	1,8%	848,51
SARIMA (1,1,0)×(0,0,2) ₁₂	0,9575	2,2%	1.048,16
SARIMA (1,1,0)×(1,0,0) ₁₂	0,9566	0,4%	424,80
SARIMA (1,1,0)×(1,0,1) ₁₂	0,9574	0,4%	455,40
SARIMA (1,1,0)×(1,0,2) ₁₂	0,9646	-0,5%	476,16
SARIMA (1,1,0)×(2,0,0) ₁₂	0,9574	0,5%	495,53
SARIMA (1,1,0)×(2,0,1) ₁₂	0,9576	0,1%	408,37
SARIMA (1,1,0)×(2,0,2) ₁₂	0,9697	2,6%	1.781,51

Os resultados obtidos pelos modelos estudados continuam bastante satisfatórios. Para a série 84, confirmou-se o desempenho obtido pelo modelo de Winters aditivo, que resultou em um EMP de -0,1%. Contudo, deve-se atentar para o fato de que o MQE de 268,32, obtido pelo modelo, é superior ao do modelo de Winters multiplicativo e ao do modelo SARIMA $(1,1,0) \times (2,0,0)_{12}$.

Este fato pode merecer um estudo mais aprofundado e um acompanhamento da realização dos próximos meses de arrecadação. Claramente isso não deve tornar-se motivo de preocupação, pois, como pode-se observar, 8 dos 14 modelos testados resultaram em um EMP menor que 1,0%, uma acurácia muito satisfatória para uma previsão. A comparação entre os valores realizados de arrecadação e sua previsão pelo modelo de Winters aditivo pode ser feita verificando-se os dados da Tabela 21.

Tabela 21: Comparação entre a arrecadação realizada em 2004 após a depuração e sua previsão pelo modelo Winters Aditivo – Série 84 – Em R\$ milhões

Mês	Realizado	Previsto	$\frac{(\text{Realizado} - \text{Previsto})}{\text{Realizado}}$	$(\text{Realizado} - \text{Previsto})^2$
Janeiro	633,8	610,6	3,7%	538,6
Fevereiro	621,7	609,7	1,9%	145,0
Março	600,8	622,1	-3,6%	456,8
Abril	642,6	635,0	1,2%	57,1
Maio	632,1	639,5	-1,2%	55,3
Junho	624,1	638,6	-2,3%	211,5
Julho	625,3	651,1	-4,1%	663,8
Agosto	669,5	664,0	0,8%	30,4
Setembro	684,5	668,5	2,3%	256,3
TOTAL	5.734,3	5.739,1		
EMP			-0,1%	
MQE				268,3

O gráfico da previsão do modelo de Winters aditivo para a série 84 é apresentado na Figura 38. A análise deste gráfico permite constatar que a linha das previsões permeia os dados efetivamente realizados. A Figura 38 completa a análise dos resultados e comprova a acurácia do modelo visualmente.




Figura 38: Gráfico da Suavização Exponencial de Winters aditivo – Série 84

Para a série 48, três modelos resultaram em um EMP de 0,1%: Winters aditivo, Winters multiplicativo e SARIMA $(1,1,0) \times (2,0,1)_{12}$. Com base no MQE, conclui-se que a melhor modelagem foi a do modelo de Suavização Exponencial de Winters multiplicativo. Embora este resultado seja mais próximo dos obtidos com as séries 72 e 84, ele representa uma mudança em relação à série 36, que apontava o modelo de Holt como mais adequado. A Figura 39 apresenta o gráfico da previsão do modelo de Winters multiplicativo e a Figura 40, para efeitos de comparação, os resultados do modelo de Holt.




Figura 39: Gráfico da Suavização Exponencial de Winters multiplicativo – Série 48




Figura 40: Gráfico da Suavização Exponencial de Holt – Série 48

Visualmente também é possível identificar que a linha de projeção do modelo de Winters multiplicativo tem um comportamento mais próximo ao da série 48. Entretanto, os dados da Tabela 20 apontam para um ajuste muito próximo, tanto em termos de EMP quanto de MQE. As previsões obtidas com o modelo de Winters multiplicativo são comparadas com os valores efetivamente arrecadados no período na Tabela 22.

Tabela 22: Comparação entre a arrecadação realizada em 2004 após a depuração e sua previsão pelo modelo Winters Multiplicativo – Série 48 – Em R\$ milhões

Mês	Realizado	Previsto	$\frac{(\text{Realizado} - \text{Previsto})}{\text{Realizado}}$	$(\text{Realizado} - \text{Previsto})^2$
Janeiro	633,8	611,7	3,5%	488,3
Fevereiro	621,7	604,6	2,8%	294,2
Março	600,8	618,5	-3,0%	315,3
Abril	642,6	639,1	0,5%	12,0
Maio	632,1	639,9	-1,2%	61,5
Junho	624,1	632,2	-1,3%	65,4
Julho	625,3	646,4	-3,4%	445,9
Agosto	669,5	667,6	0,3%	3,4
Setembro	684,5	668,2	2,4%	265,8
TOTAL	5.734,3	5.728,2		
EMP			0,1%	
MQE				216,9

Esta replicação do estudo, incluindo os dados de 2003 nas séries temporais para realização da previsão de 2004, ratificou a escolha feita pelo modelo de Winters aditivo

para as séries mais longas, com 72 e 84 observações. A alteração verificada nas projeções baseadas nas séries mais curtas – 36 e 48 observações – não deve ser vista com desconfiança, pois os modelos que obtiveram os melhores resultados em ambas as séries pertencem a uma mesma classe, a suavização exponencial.

Deve-se ressaltar também a evolução do desempenho dos modelos SARIMA após a inclusão de mais 12 observações nas séries originais. Isto pode significar que o comportamento da receita em 2003 foi semelhante ao dos exercícios imediatamente anteriores, favorecendo não apenas os modelos SARIMA, mas todos os que atribuem um peso maior às observações mais recentes. Os resultados dos modelos SARIMA reafirmam a teoria de que séries com maior quantidade de dados tendem a gerar previsões mais acuradas.

Desta forma, recomenda-se a implantação do modelo de suavização exponencial de Winters aditivo para a previsão da arrecadação do ICMS 100% do Estado do Paraná. A decisão de implantar – ou não – este modelo, caberá ao Diretor da Coordenação da Receita do Estado.

4.11.1 REVISÃO DOS VALORES DE PREVISÃO - *FORECASTING* QUALITATIVO

Reforça-se a necessidade da máxima utilização do conhecimento prévio de eventos futuros de cunho econômico, financeiro, fiscal ou tributário que possam representar incrementos ou decréscimos na arrecadação de ICMS do estado.

Para tanto, faz-se necessário que não somente as pessoas diretamente envolvidas no processo de previsão da receita desempenhem seu papel, mas que a organização possa prover informações de qualidade para que as “intervenções manuais” aplicadas ao modelo – em outras palavras, *forecasting* qualitativo – sejam o mais precisas possível.

Na prática, os componentes do Setor de Análise e Previsão da Receita enfrentam algumas dificuldades na realização do *forecasting* qualitativo. Quando questionados sobre as projeções para o exercício 2003, alegaram que somente foram informados da realização do programa de recuperação de créditos fiscais em julho. Como o programa começava em setembro, foi feita uma revisão nas projeções iniciais de arrecadação. Contudo, a previsão orçamentária é realizada sempre no exercício anterior ao de sua

aplicação, impossibilitando que esta informação fosse contemplada nas projeções que compuseram o Orçamento de 2003.

Outro ponto abordado pelos responsáveis pela previsão na Coordenação da Receita do Estado foram os recolhimentos extraordinários. Estes são geralmente desconhecidos até poucos dias antes de sua efetivação, restando-lhes justificar o ingresso de montante diferente do previsto. Deve-se ressaltar que tais justificativas somente são solicitadas quando o montante recolhido é significativo – o que pode representar alguns milhões de reais.

Um fator que não prejudica a acurácia da previsão anual, mas provoca deslocamentos significativos entre os meses do ano, são as importações, cujo recolhimento do imposto devido deve ser feito no momento do desembaraço aduaneiro.

De acordo com os técnicos da Receita Estadual, estes deslocamentos não comprometem a previsão, mas torna-se necessário relembrar a gerência superior de que um ingresso proveniente de importação ocorrido em determinado mês será compensado no mês subsequente. Em suma, reiteram os funcionários do Setor de Análise e Previsão da Receita, quaisquer informações sobre alteração nos valores de previsão da receita são cruciais para manutenção do equilíbrio do fluxo de caixa do estado.

Para o exercício 2005, os dados de previsão orçamentária foram gerados como descrito na seção 4.2, sendo os dados de retorno de programas de incentivo fiscal a única intervenção qualitativa realizada na projeção do ICMS.

5 CONCLUSÃO

Este trabalho permitiu um aprofundamento na questão da utilização do *forecasting*. Seu diferencial com relação a trabalhos similares na área foi abordar o problema na esfera pública, onde um pequeno número de pesquisas foi realizado. Com isso, identificou-se um potencial campo de estudo a ser desenvolvido em todas as esferas de governo, na busca do constante aprimoramento do desempenho da gestão pública.

A revisão bibliográfica apresentou alguns dos modelos de *forecasting* mais utilizados atualmente, bem como os critérios que permitem a seleção do melhor modelo para determinada série. Procurou-se apresentar os modelos com mesmo grau de ênfase, porém, modelos mais complexos – modelos de Box-Jenkins – necessitaram de maiores detalhamentos em relação aos demais.

Ficou claro, a partir dos resultados obtidos, que a maior complexidade de um modelo não resulta necessariamente em melhor resultado na modelagem dos dados. Nesta dissertação, os modelos de suavização exponencial, mais simples quanto à sua estrutura se comparados aos modelos de Box-Jenkins, provaram ser mais precisos em suas previsões, dadas as características da série analisada.

Os resultados obtidos no estudo de caso, tanto com a série com 72 observações quanto com a série de 36 observações, foram bastante positivos. A pequena margem de erro apresentada pelas previsões se constituirá em importante subsídio para tomada de decisões por parte dos gestores.

Deve-se ressaltar que a previsão será tanto mais acurada quanto melhor for a troca de informações entre as três áreas centrais da Receita Estadual – Arrecadação, Tributação e Fiscalização. Somente desta forma, tendo conhecimento das informações que possam afetar a arrecadação de ICMS, será possível para os responsáveis pela previsão realizarem um *forecasting* qualitativo que melhore os resultados apresentados pelos modelos matemáticos.

Quanto a seus objetivos, considera-se que o presente trabalho os alcançou de forma plena, conforme exposto na sequência.

O objetivo principal do trabalho, determinar uma sequência de passos para a realização da previsão que permitisse a escolha do modelo de *forecasting* mais adequado à série de arrecadação de ICMS, foi concluído no Capítulo 3, onde as fases de implantação de um sistema de *forecasting* foram definidas. O Capítulo 4 consolidou, de forma prática, os passos determinados no capítulo anterior.

Quanto aos objetivos específicos, foram abordados diferentes modelos de *forecasting* ao longo do Capítulo 2, além de serem apresentadas as suas vantagens, desvantagens, possibilidades de aplicação e resultados obtidos em estudos anteriores. Estes mesmos modelos foram aplicados à série de dados de arrecadação de ICMS do Estado do Paraná.

O comportamento da arrecadação do Estado do Paraná foi exaustivamente estudado no Capítulo 4, especialmente na aplicação de modelos SARIMA, que exigem maior entendimento e tratamento da série para execução das previsões. Foram identificados padrões de tendência, de ciclo e de sazonalidade na série.

A proposta de analisar os dados em duas séries com quantidades diferentes de observações foi realizada com todos os modelos aplicados no Capítulo 4. Os resultados foram extremamente relevantes e reveladores, já que denunciam que é possível realizar previsões bastante acuradas com apenas 36 observações.

A relevância do *forecasting* qualitativo ficou evidente na seção 4.4, quando os dados de exercícios anteriores foram analisados. Da mesma forma que havia informações “escondidas” nos dados de arrecadação, e após a depuração foi possível testar os modelos, pode-se inverter o processo e, após realizar a previsão quantitativa, inserir informações não disponíveis para o modelo. Caberia a um especialista – ou grupo de especialistas – determinar em que medida cada evento conhecido afetará a arrecadação no futuro.

Os resultados obtidos neste trabalho poderão ser aplicados na previsão da receita de ICMS do Estado do Paraná a partir de 2005, a critério das autoridades competentes. As conclusões sobre o grau de acurácia que se pode atingir com a utilização dos modelos testados no caso estudado, permitem a elaboração de orçamentos mais realistas e, por conseguinte, um melhor gerenciamento dos recursos dos cofres públicos.

Desta maneira, conclui-se que a tomada de decisão gerencial, especialmente no tocante às despesas do estado, sejam para manutenção dos serviços essenciais ou para investimentos e obras, poderá ser efetuada com mais segurança e embasamento teórico.

O horizonte de aplicação do método de trabalho proposto é de longo prazo, pois há flexibilidade suficiente para agregar novos modelos de previsão nas revisões periódicas sugeridas no item 4.11. Esta possibilidade faz com que o método de trabalho possa ser adequado a novas tecnologias e a novos modelos que venham a ser testados.

5.1 SUGESTÕES PARA TRABALHOS FUTUROS

Dada a velocidade com que as mudanças acontecem no setor de arrecadação de tributos, sugere-se a replicação deste estudo para séries de arrecadação de ICMS com menor número de observações (12 e 24 observações, por exemplo). Os resultados poderão ser relevantes quando – e se – for aprovada a Reforma Tributária.

Outra análise possível no âmbito da arrecadação tributária estadual, é a aplicação dos modelos de *forecasting* a séries de arrecadação do IPVA, segundo imposto em importância no Estado do Paraná.

Por fim, é possível fazer um estudo comparativo a partir de séries de dados de diversos estados. O ponto crítico para esta análise seria o conhecimento das especificidades de legislação e do comportamento da arrecadação de cada ente federado estudado.

REFERÊNCIAS BIBLIOGRÁFICAS

1. ADYA, M. – *Corrections to rule-based forecasting: findings from a replication*, International Journal of Forecasting, p. 125–127, Volume 16, 2000.
2. ANGUS, A. J.; HODGE, I. D.; McNALLY, S. & SUTTON, M. A. – *The setting of standards for agricultural nitrogen emissions: a case study of the Delphi technique*, Journal of Environmental Management, p. 323–337, Volume 69, 2003.
3. ARMSTRONG, J. S. – *Forecasting methods for conflict situations*. In Judgmental forecasting, p. 157–176, 1987, John Wiley & Sons, Inc., New York.
4. _____. – *Research needs in forecasting*, International Journal of Forecasting, p. 449–465, Volume 4, 1988.
5. _____. – *Selecting forecasting methods*. In Principles of forecasting – a handbook for researchers and practitioners, p. 365–386, 1.st ed., 2001, Kluwer Academic Publishers, Norwell, 849 p.
6. ARRAES, R. A. & CHUMVICHITRA, P. – Modelos autoregressivos e poder de previsão: uma aplicação com o ICMS. Texto para Discussão n.º 152. Programa de Pós-Graduação em Economia, Universidade Federal do Ceará, 1996.
7. ASSIMAKOPOULOS, V. & NIKOLOPOULOS, K. – *The theta model: a decomposition approach to forecasting*, International Journal of Forecasting, p. 521–530, Volume 16, 2000.

8. BIANCO, A. M.; BEN; M. G.; MARTÍNEZ, E. J. & YOHAI, V. J. – *Outlier detection in regression models with ARIMA errors using robust estimates*, Journal of Forecasting, p. 565–579, Volume 20, 2001.
9. BOWERMAN, B. L. & O’CONNEL, R. T. – *Time series forecasting, unified concepts and computer implementation*, 2.nd ed., 1987, Duxbury Press, Boston.
10. BOX, G. E. P.; JENKINS, G. M. & REINSEL, G. C. – *Time series analysis: forecasting and control*, 3.rd ed., 1994, Prentice Hall, New Jersey, 587 p.
11. BOX, G. E. P. & LUCENÑO, A. – *Statistical control by monitoring and feedback adjustment*, 1997, John Wiley, New York.
12. BRASIL. Lei Complementar n.º 82, de 27 de março de 1995. Disciplina os limites das despesas com o funcionalismo público, na forma do art. 169 da Constituição Federal. Diário Oficial da União. Brasília, 28 de março de 1995.
13. _____. Lei Complementar n.º 87, de 13 de setembro de 1996. Dispõe sobre o imposto dos Estados e do Distrito Federal sobre operações relativas à circulação de mercadorias e sobre prestações de serviços de transporte interestadual e intermunicipal e de comunicação, e dá outras providências. Diário Oficial da União. Brasília, 16 de setembro de 1996.
14. _____. Lei Complementar n.º 96, de 31 de maio de 1999. Disciplina os limites das despesas com pessoal, na forma do art. 169 da Constituição. Diário Oficial da União. Brasília, 1.º de junho de 1999.
15. _____. Lei Complementar n.º 101, de 4 de maio de 2000. Estabelece normas de finanças públicas voltadas para a responsabilidade na gestão fiscal e dá outras providências. Diário Oficial da União. Brasília, 5 de maio de 2000.
16. BROCKWELL, P. J. & DAVIS, R. A. – *Introduction to time series and forecasting*, 1.st ed., 1996, Springer-Verlag, New York.
17. CANOVA F. & CICCARELI, M. – *Forecasting and turning point predictions in a Bayesian panel VAR model*, Journal of Econometrics, p. 327–359, Volume 120, 2004.

18. CARBONE, R. & ARMSTRONG, J. S. – *Evaluation of extrapolative forecasting methods: results of a survey of academicians and practitioners*, Journal of Forecasting, p. 215–217, Volume 1, 1982.
19. CHO, V. – *A comparison of three different approaches to tourist arrival forecasting*, Tourism Management, p. 323–330, Volume 24, 2003.
20. CIRINCIONE, C.; GURRIERI G. A. & SANDE, B. van de – *Municipal Government revenue forecasting: Issues of method and data*, 1999, Public Budgeting and Finance, p. 26–46, Spring 1999.
21. COCCARO, S. M. B. – A arrecadação do ICMS: um enfoque econométrico. Dissertação de Mestrado. Programa de Pós-Graduação em Economia, Universidade Federal do Rio Grande do Sul, 2000.
22. CONFEDERAÇÃO NACIONAL DO COMÉRCIO – Síntese da economia brasileira – 2004. Rio de Janeiro, 2003, 204 p.
23. DALKEY, N. & HELMER, O. – *An experimental application of the Delphi method to the use of experts*, Journal of the Institute of Management Science, p. 458–467, Volume 9, 1963.
24. ELSAYED, E. A. & BOUCHER, T. O. – *Analysis and control of production systems*, 2.nd ed., 1994, Prentice Hall, New Jersey, 450 p.
25. FREITAS, V. P. – O uso de técnicas de inteligência artificial para a projeção da arrecadação estadual, Secretaria de Estado da Fazenda do Rio Grande do Sul, 2002, Porto Alegre.
26. GAYNOR, P. E. & KIRKPATRICK, R. C. – *Introduction to time-series modeling and forecasting*, 1994, McGraw Hill, Inc., 625 p.
27. GRANGER, C. W. J. & NEWBOLD, P. – *Forecasting economic time series*, 1.st ed., 1986, Academic Press, New York.
28. GUAJARDO, S. A. – *Revenue forecasting and analysis in Nassau County, New York*, Government Finance Review, p. 43–49, V. 19, n. 02, April 2003.

29. GUPTA, U. G. & CLARKE, R. E. – *Theory and applications of the Delphi technique: a bibliography*, Technological Forecasting and Social Change, p. 185–211, Volume 53, 1996.
30. HYNDMAN, R. J. & BILLAH, B. – *Unmasking the theta method*, International Journal of Forecasting, p. 287–290, Volume 19, 2003.
31. IPARDES - Instituto Paranaense de Desenvolvimento Econômico e Social – Modelo de evolução e projeção econômico-financeiro estadual – 1.^a etapa. Curitiba, 1979.
32. _____. – Crescimento, reestruturação e competitividade industrial no Paraná 1985-2000. Curitiba, 2002.
33. _____. – Paraná: Diagnóstico social e econômico. Curitiba, 2003.
34. ITSM Ver. 6.0. *User's manual*, B&D Enterprises, Inc., 1999.
35. JAFFRY, S & CAPON, N. – *Alternative methods of forecasting risks in naval manpower planning*, International Journal of Forecasting, 2004.
36. JOSEPH, N. L. – *Model specification and forecasting foreign exchange rates with vector autoregressions*, Journal of Forecasting, p. 451–484, Volume 20, 2001.
37. KAYO, E. K. & SECURATO, J. R. – Método Delphi: fundamentos, críticas e vieses, Cadernos de Pesquisa em Administração, v. 01, n.º 04, p. 51-61, FEA-USP, 1.º semestre/1997, São Paulo.
38. KIM, J. H. – *Bias-corrected bootstrap prediction regions for vector autoregression*, Journal of Forecasting, p. 141–154, Volume 23, 2004.
39. KLASSEN, R. D. & FLORES, B. E. – *Forecasting practices of Canadian firms: survey results and comparisons*, International Journal of Production Economics, p. 163–174, Volume 70, 2001.
40. KOREISHA, S. G. & FANG, A. Y. – *Updating ARMA predictions for temporal aggregates*, Journal of Forecasting, p. 275–296, Volume 23, 2004.

41. KRAJEWSKI, L. J. & RITZMAN, L. P. – *Operations management, strategy and analysis*, 5.^a ed., 1998, Addison-Wesley, Reading, MA, 880 p.
42. LIEBEL, M. J. & STACHERA FILHO, M. – Boletim Informativo da Inspeção Geral de Arrecadação. Curitiba, setembro/2004.
43. LINSTONE, H. & TUROFF M. – *The Delphi method*, 1.st ed., 1975, Addison-Wesley, Reading, MA.
44. LOO, R. – *The Delphi method: a powerful tool for strategic management*, Policing: An International Journal of Police Strategies & Management, p. 762–769, V. 25, n. 4, 2002.
45. MAÇADA, A. C. G. – Impacto dos investimentos em tecnologia da informação nas variáveis estratégicas e na eficiência dos bancos brasileiros. Tese de Doutorado. Programa de Pós-Graduação em Administração, Universidade Federal do Rio Grande do Sul, 2001.
46. MAKRIDAKIS, S.; ANDERSEN, A.; CARBONE, R.; FILDES, R.; HIBON, R.; LEWANDOWSKI, R.; NEWTON, J.; PARZEN, E. & WINKLER, R. – *The Accuracy of Extrapolation (time series) methods: results of a forecasting competition*, Journal of Forecasting, p. 111–153, Volume 1, 1982.
47. MAKRIDAKIS, S.; WHEELWRIGHT, S. C. & HYNDMAN, R. J. – *Forecasting – methods and applications*, 3.rd ed., 1998, John Wiley, New York, 642 p.
48. MARA, C. M. – *A strategic planning process for a small nonprofit organization – a hospice example*, Nonprofit Management & Leadership, p. 211–223, Volume 11, n. 2 Winter 2000.
49. MARTINO, J. P. – *A review of selected advances in technological forecasting*, Technological Forecasting & Social Change, p. 719–733, V. 70, 2003.
50. McCRAE, M.; LIN, Y.; PAVLIK, D. & GULATI, C. M. – *Can cointegration-based forecasting outperform univariate models? An application to Asian exchange rates*, Journal of Forecasting, p. 355–380, Volume 21, 2002.

51. McMILLAN, D. G. & SPEIGHT A. E. H. – *Daily volatility forecasts: reassessing the performance of GARCH models*, Journal of Forecasting, p. 449–460, Volume 23, 2004.
52. MEADE, N. – *A comparison of the accuracy of short term foreign exchange forecasting methods*, Policing: International Journal of Forecasting, p. 67–83, Volume 18, 2002.
53. MELO, B. S. V. de – *Modelo de previsão para a arrecadação tributária*. Dissertação de Mestrado. Universidade de Brasília, Brasília, 2001, 119p.
54. MEYRICK, J. de – *The Delphi method and health research*, Health education, p. 7–16, Volume 103, n. 1, 2003.
55. MILLS, T. C. – *Time series techniques for economists*, 1990, Cambridge University Press, Cambridge.
56. MONTGOMERY, D. C. – *Introduction to statistical quality control*, 3.rd ed., 1997, John Wiley & Sons, Inc., New York, 677 p.
57. MONTGOMERY, D. C.; JOHNSON, L. A. & GRADINER, J. S. – *Forecasting and Time Series Analysis*, 2.nd ed., 1990, McGraw-Hill Inc., New York, 375 p.
58. MOORE, N. – *Forecasting budgets: 25 keys to successful planning*, 1.st ed., 1999, Lebharr-Friedman Books, New York.
59. MORETTIN, P. A. & TOLOI, C. M. de C. – *Previsão de Séries Temporais*, 1.^a ed., 1985, Editora Atual, São Paulo, 436 p.
60. _____. – *Séries Temporais*, 1.^a ed., 1986, Editora Atual, São Paulo, 133 p.
61. MORRISON, L.E. – *Improving revenue projections: 10 questions - and answers*, Government Finance Review, p. 16–19, V. 18, n. 03, June 2002.
62. MULLEN, P. M. – *Delphi: myths and reality*, Journal of Health Organization and Management, p. 37–52, Volume 17, n. 1, 2003.
63. NCSS. *User's manual*, NCSS Co., Kaysville, Utah, 1996.

64. OKOLI, C. & PAWLOWSKI, S. D. – *The Delphi method as a research tool: an example, design considerations and applications*, Information & Management, p. 15–29, Volume 42, 2004.
65. PARANÁ. Coordenação da Administração Financeira do Estado – I Simpósio sobre metodologias de previsão e classificação de receitas públicas. Curitiba, 1977.
66. _____. Coordenação da Administração Financeira do Estado – Metodologia de previsão das receitas – síntese das atividades desenvolvidas, I Simpósio sobre receitas públicas. Curitiba, 1986.
67. _____. Lei n.º 13.410, de 26 de dezembro de 2001. Introduz alterações à Lei nº 11.580/96 (alíquotas de ICMS sobre combustíveis, energia elétrica, telefonia, bebidas alcoólicas e fumos). Diário Oficial do Estado. Curitiba, 26 de dezembro de 2001.
68. PARENTÉ R. J.; HIÖB, T. N.; SILVER, R. A.; JENKINS, C.; POE, M. P. & MULLINS, R. J. – *The Delphi method, impeachment and terrorism: accuracies of short-range forecasts for volatile world events*, Technological Forecasting and Social Change, p. 1–12, 2003.
69. PARK, B. – *An outlier robust GARCH model and forecasting volatility of exchange rate returns*, Journal of Forecasting, p. 381–393, Volume 21, 2002.
70. PANKRATZ, A. – *Forecasting with univariate Box-Jenkins models*, 1983, John Wiley & Sons, New York.
71. PELLEGRINI, F. R. – Uma metodologia para implantação de sistemas de previsão de demanda. Dissertação de Mestrado. Programa de Pós-Graduação em Engenharia de Produção, Universidade Federal do Rio Grande do Sul, 2000.
72. PELLEGRINI, F. R. & FOGLIATTO F. S. – Passos para implantação de sistemas de previsão de demanda – Técnicas e estudo de caso. Anais do ENEGEP, CD-ROM, 2002.
73. PRUD'HOMME, R. – *State and local finance in Parana: structure and issues*, mimeo, United Nations Development Program – Project BRA/95/005 – Strategic actions in support of urban development, 1998, 36p.

74. RAUCH, W. – *The decision Delphi*, Technological Forecasting and Social Change, p. 159–169, Volume 15, 1979.
75. RIBEIRO, J. L. D. & CATEN, Carla ten. – *Estatística Industrial – Série Monográfica Qualidade*. Porto Alegre. 2000, 135p.
76. SCHNEIDER, J. B. – *The Policy Delphi: a regional planning application*, Technological Forecasting and Social Change, p. 481–497, Volume 3, 1972.
77. SETTY, K. P. S.; PADMANABHAN, S. & NATARAJAN, R. – *A national energy-conservation Policy Delphi: report of the findings*, Technological Forecasting and Social Change, p. 257–267, Volume 31, 1987.
78. SIQUEIRA M. L. – *Modelos de séries temporais para a previsão da arrecadação tributária federal*. Dissertação de Mestrado. Universidade de Pernambuco, Recife, 2002, 220p.
79. SMITH, B. L.; WILLIAMS, B. M. & OSWALD, R. K. – *Comparison of parametric and nonparametric models for traffic flow forecasting*, Transportation Research Part C, p. 303–321, Volume 10, 2002.
80. STATGRAPHICS Ver 2.1. *Statgraphics manual*, Manugistics, Inc., Rockville, 1995.
81. STEVENSON, W. J. – *Estatística Aplicada à Administração*. São Paulo. Editora Harbra Ltda., 1981, 495 p.
82. STINSON, T. F. – *State revenue forecasting: an institutional framework*, Government Finance Review, p. 12–15, V. 18, n. 03, June 2002.
83. TAYLOR, J. W. & BUIZZA, R. – *A comparison of temperature density forecasts from GARCH and atmospheric models*, Journal of Forecasting, p. 337–355, Volume 23, 2004.
84. TRAPLETTI, A.; GEYER, A. & LEISH, F. – *Forecasting exchange rates using cointegration models and intra-day data*, Journal of Forecasting, p. 151–166, Volume 21, 2002.
85. TUROFF, M. – *The design of a Policy Delphi*, Technological Forecasting and Social Change, p. 149–171, Volume 2, 1970.

86. VRONTOS, D.; DELLAPORTAS, P. & POLITIS, D. N. – *Inference for some multivariate ARCH and GARCH models*, Journal of Forecasting, p. 427–446, Volume 22, 2003.
87. WAGNER, H. M. – Pesquisa Operacional. Rio de Janeiro. Prentice-Hall do Brasil Ltda., 1986, 851 p.
88. WEATHERFORD, L. R. & KIMES, S. E. – *A comparison of forecasting methods for hotel revenue management*, International Journal of Forecasting, p. 401–415, Volume 19, 2003.
89. WOOLDRIDGE, J. M. – *Introductory Econometrics: a modern approach*, 2.nd ed., 2003, South-Western, 900 p.
90. WRIGHT, J. T. C. & GIOVINAZZO, R. A. – Delphi: uma ferramenta de apoio ao planejamento prospectivo, Cadernos de Pesquisa em Administração, v. 01, n.º 12, p. 54-65, FEA-USP, 2.º trimestre/2000, São Paulo.
91. YANG, J.; GREENWOOD, D. J.; ROWELL, D. L.; WADSWORTH, G. A. & BURNS, I. G. – *Statistical methods for evaluating a crop nitrogen simulation model, N_{ABLE}*, Agricultural Systems, p. 37–53, Volume 64, 2000.
92. ZHOU, W. – *Integration of different forecasting models*, The Journal of Business Forecasting, p. 26–28, Fall 1999.
93. ZORN, C. K. – *Issues and problems in econometric forecasting: guidance for local revenue forecasters*, Public Budgeting and Finance, p. 100–110, Autumn 1982.

94. ANEXO A – PREVISÃO PARA O EXERCÍCIO 2003 – RESULTADOS DA SÉRIE 72

Tabela A – 1: Série 72 - Modelo de Regressão Linear

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	480,7	8,9%	2.231,2
Fevereiro	541,6	484,7	10,5%	3.236,2
Março	553,5	488,8	11,7%	4.191,1
Abril	576,1	492,8	14,5%	6.937,4
Mai	527,4	496,9	5,8%	931,5
Junho	549,8	500,9	8,9%	2.390,8
Julho	542,1	505,0	6,8%	1.376,1
Agosto	568,6	509,0	10,5%	3.543,4
Setembro	572,2	513,1	10,3%	3.491,0
Outubro	562,6	517,2	8,1%	2.064,1
Novembro	611,2	521,2	14,7%	8.101,5
Dezembro	614,7	525,3	14,5%	7.989,4
TOTAL	6.747,6	6.035,5		
EMP			10,4%	
MQE				3.873,6

Tabela A – 2: Série 72 - Modelo de Suavização Exponencial Simples

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	514,1	2,6%	190,6
Fevereiro	541,6	514,1	5,1%	757,0
Março	553,5	514,1	7,1%	1.553,9
Abril	576,1	514,1	10,8%	3.847,5
Mai	527,4	514,1	2,5%	177,2
Junho	549,8	514,1	6,5%	1.277,6
Julho	542,1	514,1	5,2%	784,0
Agosto	568,6	514,1	9,6%	2.968,7
Setembro	572,2	514,1	10,2%	3.375,6
Outubro	562,6	514,1	8,6%	2.352,6
Novembro	611,2	514,1	15,9%	9.435,2
Dezembro	614,7	514,1	16,4%	10.113,5
TOTAL	6.747,6	6.169,0		
EMP			8,4%	
MQE				3.069,4

Tabela A – 3: Série 72 - Modelo de Suavização Exponencial de Holt

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	531,6	-0,7%	14,1
Fevereiro	541,6	538,6	0,5%	8,8
Março	553,5	545,6	1,4%	62,3
Abril	576,1	552,6	4,1%	552,9
Mai	527,4	559,6	-6,1%	1.035,9
Junho	549,8	566,6	-3,0%	280,2
Julho	542,1	573,6	-5,8%	990,3
Agosto	568,6	580,5	-2,1%	143,2
Setembro	572,2	587,5	-2,7%	235,2
Outubro	562,6	594,5	-5,7%	1.018,8
Novembro	611,2	601,5	1,6%	94,6
Dezembro	614,7	608,5	1,0%	38,1
TOTAL	6.747,6	6.840,7		
EMP			-1,5%	
MQE				372,9

Tabela A – 4: Série 72 - Modelo de Suavização Exponencial de Winters Multiplicativo

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	550,4	-4,3%	506,5
Fevereiro	541,6	513,6	5,2%	786,2
Março	553,5	511,9	7,5%	1.727,2
Abril	576,1	560,7	2,7%	238,8
Mai	527,4	555,0	-5,2%	764,3
Junho	549,8	547,3	0,5%	6,6
Julho	542,1	559,5	-3,2%	304,5
Agosto	568,6	558,2	1,8%	107,1
Setembro	572,2	574,8	-0,5%	7,0
Outubro	562,6	579,6	-3,0%	288,4
Novembro	611,2	601,4	1,6%	96,5
Dezembro	614,7	598,4	2,6%	264,4
TOTAL	6.747,6	6.710,8		
EMP			0,5%	
MQE				424,8

Tabela A – 5: Série 72 - Modelo de Suavização Exponencial de Winters Aditivo

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	539,3	-2,2%	130,7
Fevereiro	541,6	518,8	4,2%	520,6
Março	553,5	519,7	6,1%	1.139,7
Abril	576,1	555,6	3,6%	421,0
Maio	527,4	553,7	-5,0%	691,0
Junho	549,8	550,0	0,0%	0,0
Julho	542,1	562,1	-3,7%	402,4
Agosto	568,6	564,3	0,8%	18,4
Setembro	572,2	576,3	-0,7%	17,1
Outubro	562,6	581,5	-3,4%	356,7
Novembro	611,2	599,1	2,0%	145,9
Dezembro	614,7	598,4	2,6%	263,9
TOTAL	6.747,6	6.718,9		
EMP			0,4%	
MQE				342,3

Tabela A – 6: Série 72 - Modelo de Decomposição

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	501,9	4,9%	677,4
Fevereiro	541,6	457,7	15,5%	7.034,1
Março	553,5	458,8	17,1%	8.961,5
Abril	576,1	499,2	13,3%	5.912,9
Maio	527,4	494,2	6,3%	1.105,2
Junho	549,8	487,9	11,3%	3.832,4
Julho	542,1	492,0	9,2%	2.513,0
Agosto	568,6	491,1	13,6%	6.004,2
Setembro	572,2	506,9	11,4%	4.256,7
Outubro	562,6	510,1	9,3%	2.752,6
Novembro	611,2	524,8	14,1%	7.469,5
Dezembro	614,7	515,1	16,2%	9.901,9
TOTAL	6.747,6	5.939,8		
EMP			11,9%	
MQE				5.035,1

Tabela A – 7: Série 72 - Modelo SARIMA

$$(1, 1, 0) \times (0, 0, 1)_{12}$$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	524,9	0,6%	9,1
Fevereiro	541,6	520,3	3,9%	452,4
Março	553,5	518,9	6,3%	1.200,6
Abril	576,1	528,3	8,3%	2.287,5
Maio	527,4	532,7	-1,0%	27,6
Junho	549,8	529,5	3,7%	415,1
Julho	542,1	536,6	1,0%	30,3
Agosto	568,6	544,1	4,3%	600,6
Setembro	572,2	539,1	5,8%	1.096,7
Outubro	562,6	531,3	5,6%	978,4
Novembro	611,2	549,5	10,1%	3.808,9
Dezembro	614,7	543,6	11,6%	5.051,5
TOTAL	6.747,6	6.398,6		
EMP			5,0%	
MQE				1.329,9

Tabela A – 8: Série 72 - Modelo SARIMA
 $(1, 1, 0) \times (0, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	519,3	1,6%	74,4
Fevereiro	541,6	522,1	3,6%	380,9
Março	553,5	512,7	7,4%	1.665,9
Abril	576,1	546,7	5,1%	862,4
Maio	527,4	539,1	-2,2%	136,6
Junho	549,8	532,1	3,2%	313,2
Julho	542,1	540,2	0,4%	3,7
Agosto	568,6	541,8	4,7%	714,6
Setembro	572,2	548,1	4,2%	580,1
Outubro	562,6	550,6	2,1%	144,8
Novembro	611,2	565,7	7,4%	2.068,7
Dezembro	614,7	551,3	10,3%	4.019,8
TOTAL	6.747,6	6.469,7		
EMP			4,0%	
MQE				913,8

Tabela A – 9: Série 72 - Modelo SARIMA
 $(1, 1, 0) \times (1, 0, 0)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	529,8	-0,4%	3,6
Fevereiro	541,6	520,5	3,9%	447,1
Março	553,5	516,9	6,6%	1.343,0
Abril	576,1	543,9	5,6%	1.035,1
Maio	527,4	546,2	-3,6%	353,3
Junho	549,8	540,4	1,7%	88,7
Julho	542,1	552,8	-2,0%	114,7
Agosto	568,6	562,2	1,1%	40,8
Setembro	572,2	560,1	2,1%	146,7
Outubro	562,6	553,9	1,5%	75,5
Novembro	611,2	580,3	5,1%	958,6
Dezembro	614,7	570,2	7,2%	1.973,6
TOTAL	6.747,6	6.577,1		
EMP			2,4%	
MQE				548,4

Tabela A – 10: Série 72 - Modelo SARIMA

$$(1, 1, 0) \times (1, 0, 1)_{12}$$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	537,1	-1,7%	85,0
Fevereiro	541,6	515,3	4,8%	689,4
Março	553,5	514,4	7,1%	1.525,6
Abril	576,1	548,0	4,9%	789,7
Maio	527,4	547,1	-3,7%	387,3
Junho	549,8	540,6	1,7%	85,6
Julho	542,1	552,8	-2,0%	114,2
Agosto	568,6	555,4	2,3%	173,5
Setembro	572,2	562,8	1,6%	88,6
Outubro	562,6	563,3	-0,1%	0,5
Novembro	611,2	580,7	5,0%	931,9
Dezembro	614,7	577,0	6,1%	1.418,6
TOTAL	6.747,6	6.594,5		
EMP			2,2%	
MQE				524,1

Tabela A – 11: Série 72 - Modelo SARIMA
 $(1, 1, 0) \times (1, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	534,7	-1,3%	46,9
Fevereiro	541,6	510,2	5,8%	984,6
Março	553,5	505,7	8,6%	2.283,7
Abril	576,1	543,7	5,6%	1.047,8
Mai	527,4	537,6	-1,9%	104,0
Junho	549,8	532,7	3,1%	293,0
Julho	542,1	548,2	-1,1%	37,5
Agosto	568,6	534,5	6,0%	1.160,3
Setembro	572,2	545,9	4,6%	692,7
Outubro	562,6	553,2	1,7%	88,8
Novembro	611,2	562,0	8,0%	2.417,9
Dezembro	614,7	560,9	8,7%	2.886,9
TOTAL	6.747,6	6.469,5		
EMP			4,0%	
MQE				1.003,7

Tabela A – 12: Série 72 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 0)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	535,2	-1,4%	54,0
Fevereiro	541,6	511,9	5,5%	882,0
Março	553,5	510,4	7,8%	1.856,2
Abril	576,1	550,8	4,4%	642,4
Mai	527,4	543,8	-3,1%	269,1
Junho	549,8	538,7	2,0%	124,1
Julho	542,1	549,9	-1,4%	61,8
Agosto	568,6	544,4	4,2%	582,9
Setembro	572,2	559,1	2,3%	170,7
Outubro	562,6	568,4	-1,0%	33,5
Novembro	611,2	575,3	5,9%	1.291,9
Dezembro	614,7	574,2	6,6%	1.633,7
TOTAL	6.747,6	6.562,2		
EMP			2,6%	
MQE				633,5

Tabela A – 13: Série 72 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 1)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	528,3	-0,1%	0,2
Fevereiro	541,6	515,1	4,9%	702,8
Março	553,5	512,0	7,5%	1.721,0
Abril	576,1	559,2	2,9%	287,2
Mai	527,4	548,6	-4,0%	450,4
Junho	549,8	543,1	1,2%	45,4
Julho	542,1	552,8	-2,0%	115,1
Agosto	568,6	555,8	2,3%	163,7
Setembro	572,2	567,6	0,8%	20,9
Outubro	562,6	580,1	-3,1%	308,2
Novembro	611,2	591,4	3,2%	392,9
Dezembro	614,7	581,2	5,4%	1.121,9
TOTAL	6.747,6	6.635,2		
EMP			1,6%	
MQE				444,1

Tabela A – 14: Série 72 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	533,1	-1,0%	27,2
Fevereiro	541,6	507,7	6,3%	1.147,6
Março	553,5	495,4	10,5%	3.371,6
Abril	576,1	547,3	5,0%	831,8
Mai	527,4	532,2	-0,9%	22,9
Junho	549,8	526,5	4,2%	543,3
Julho	542,1	533,5	1,6%	74,2
Agosto	568,6	512,3	9,9%	3.163,3
Setembro	572,2	531,2	7,2%	1.678,3
Outubro	562,6	545,1	3,1%	304,3
Novembro	611,2	551,4	9,8%	3.575,5
Dezembro	614,7	540,4	12,1%	5.511,4
TOTAL	6.747,6	6.356,2		
EMP			5,6%	
MQE				1.687,6

ANEXO B – PREVISÃO PARA O EXERCÍCIO 2003 – RESULTADOS DA SÉRIE 36

Tabela B – 1: Série 36 - Modelo de Regressão Linear

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	508,4	3,7%	378,9
Fevereiro	541,6	513,9	5,1%	767,9
Março	553,5	519,4	6,2%	1.166,6
Abril	576,1	524,8	8,9%	2.631,9
Mai	527,4	530,3	-0,5%	8,3
Junho	549,8	535,7	2,6%	198,7
Julho	542,1	541,2	0,2%	0,8
Agosto	568,6	546,7	3,9%	480,3
Setembro	572,2	552,1	3,5%	402,7
Outubro	562,6	557,6	0,9%	25,1
Novembro	611,2	563,0	7,9%	2.321,3
Dezembro	614,7	568,5	7,5%	2.129,8
TOTAL	6.747,6	6.461,6		
EMP			4,1%	
MQE				876,0

Tabela B – 2: Série 36 - Modelo de Suavização Exponencial Simples

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	514,1	2,6%	190,6
Fevereiro	541,6	514,1	5,1%	757,0
Março	553,5	514,1	7,1%	1.553,9
Abril	576,1	514,1	10,8%	3.847,5
Mai	527,4	514,1	2,5%	177,2
Junho	549,8	514,1	6,5%	1.277,6
Julho	542,1	514,1	5,2%	784,0
Agosto	568,6	514,1	9,6%	2.968,7
Setembro	572,2	514,1	10,2%	3.375,6
Outubro	562,6	514,1	8,6%	2.352,6
Novembro	611,2	514,1	15,9%	9.435,2
Dezembro	614,7	514,1	16,4%	10.113,5
TOTAL	6.747,6	6.169,0		
EMP			8,4%	
MQE				3.069,4

Tabela B – 3: Série 36 - Modelo de Suavização Exponencial de Holt

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	525,9	0,4%	4,2
Fevereiro	541,6	533,1	1,6%	72,4
Março	553,5	540,3	2,4%	173,7
Abril	576,1	547,6	5,0%	815,1
Mai	527,4	554,8	-5,2%	750,9
Junho	549,8	562,0	-2,2%	149,0
Julho	542,1	569,3	-5,0%	739,2
Agosto	568,6	576,5	-1,4%	63,0
Setembro	572,2	583,7	-2,0%	133,7
Outubro	562,6	591,0	-5,0%	806,2
Novembro	611,2	598,2	2,1%	169,0
Dezembro	614,7	605,5	1,5%	84,6
TOTAL	6.747,6	6.787,9		
EMP			-0,7%	
MQE				330,1

Tabela B – 4: Série 36 - Modelo de Suavização Exponencial de Winters Multiplicativo

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	550,8	-4,3%	523,0
Fevereiro	541,6	523,0	3,4%	346,2
Março	553,5	520,3	6,0%	1.103,2
Abril	576,1	574,5	0,3%	2,5
Mai	527,4	573,6	-8,8%	2.137,8
Junho	549,8	566,2	-3,0%	266,5
Julho	542,1	586,6	-8,2%	1.979,2
Agosto	568,6	586,1	-3,1%	306,7
Setembro	572,2	597,0	-4,3%	616,7
Outubro	562,6	597,2	-6,2%	1.201,3
Novembro	611,2	620,0	-1,4%	77,5
Dezembro	614,7	620,8	-1,0%	37,5
TOTAL	6.747,6	6.916,1		
EMP			-2,5%	
MQE				716,5

Tabela B – 5: Série 36 - Modelo de Suavização Exponencial de Winters Aditivo

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	542,9	-2,8%	224,8
Fevereiro	541,6	525,8	2,9%	248,2
Março	553,5	525,5	5,1%	784,7
Abril	576,1	568,6	1,3%	57,1
Maio	527,4	569,8	-8,0%	1.802,0
Junho	549,8	566,0	-2,9%	263,0
Julho	542,1	583,5	-7,6%	1.718,7
Agosto	568,6	586,8	-3,2%	331,7
Setembro	572,2	595,8	-4,1%	556,1
Outubro	562,6	597,4	-6,2%	1.213,1
Novembro	611,2	618,9	-1,3%	58,8
Dezembro	614,7	618,9	-0,7%	17,8
TOTAL	6.747,6	6.900,0		
EMP			-2,3%	
MQE				606,3

Tabela B – 6: Série 36 - Modelo de Decomposição

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	532,5	-0,9%	21,6
Fevereiro	541,6	492,5	9,1%	2.413,2
Março	553,5	490,3	11,4%	3.990,2
Abril	576,1	535,6	7,0%	1.644,1
Maio	527,4	532,1	-0,9%	21,8
Junho	549,8	522,8	4,9%	733,2
Julho	542,1	541,0	0,2%	1,2
Agosto	568,6	534,6	6,0%	1.155,0
Setembro	572,2	550,4	3,8%	474,6
Outubro	562,6	552,0	1,9%	112,9
Novembro	611,2	564,5	7,6%	2.179,7
Dezembro	614,7	570,7	7,2%	1.932,6
TOTAL	6.747,6	6.418,9		
EMP			4,8%	
MQE				1.223,3

Tabela B – 7: Série 36 - Modelo SARIMA

$$(1, 1, 0) \times (0, 0, 1)_{12}$$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	525,1	0,5%	8,0
Fevereiro	541,6	518,1	4,3%	551,6
Março	553,5	517,0	6,6%	1.332,1
Abril	576,1	527,1	8,5%	2.399,3
Maio	527,4	536,8	-1,8%	87,6
Junho	549,8	531,8	3,3%	323,8
Julho	542,1	537,4	0,9%	21,7
Agosto	568,6	553,5	2,7%	228,5
Setembro	572,2	542,7	5,2%	870,3
Outubro	562,6	527,6	6,2%	1.224,3
Novembro	611,2	558,4	8,6%	2.788,0
Dezembro	614,7	548,8	10,7%	4.341,1
TOTAL	6.747,6	6.424,3		
EMP			4,6%	
MQE				1.181,4

Tabela B – 8: Série 36 - Modelo SARIMA
(1, 1, 0) × (0, 0, 2)₁₂

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	528,7	-0,2%	0,6
Fevereiro	541,6	520,1	4,0%	460,8
Março	553,5	518,3	6,4%	1.241,3
Abril	576,1	531,5	7,7%	1.991,5
Maio	527,4	548,9	-4,1%	460,5
Junho	549,8	540,8	1,6%	81,2
Julho	542,1	555,8	-2,5%	189,1
Agosto	568,6	582,7	-2,5%	199,4
Setembro	572,2	562,6	1,7%	91,5
Outubro	562,6	535,3	4,8%	743,2
Novembro	611,2	588,2	3,8%	529,1
Dezembro	614,7	571,9	7,0%	1.827,6
TOTAL	6.747,6	6.584,9		
EMP			2,3%	
MQE				651,3

Tabela B – 9: Série 36 - Modelo SARIMA
(1, 1, 0) × (1, 0, 0)₁₂

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	529,5	-0,3%	2,6
Fevereiro	541,6	520,4	3,9%	449,8
Março	553,5	516,6	6,7%	1.365,8
Abril	576,1	544,1	5,6%	1.023,6
Maio	527,4	546,4	-3,6%	359,6
Junho	549,8	540,5	1,7%	86,8
Julho	542,1	553,1	-2,0%	120,7
Agosto	568,6	562,6	1,0%	35,6
Setembro	572,2	560,5	2,0%	137,6
Outubro	562,6	554,2	1,5%	70,4
Novembro	611,2	580,9	5,0%	917,1
Dezembro	614,7	570,8	7,1%	1.926,7
TOTAL	6.747,6	6.579,5		
EMP			2,4%	
MQE				541,4

Tabela B – 10: Série 36 - Modelo SARIMA

$$(1, 1, 0) \times (1, 0, 1)_{12}$$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	527,9	530,9	-0,6%	9,2
Fevereiro	541,6	519,3	4,1%	497,1
Março	553,5	515,5	6,9%	1.445,0
Abril	576,1	546,4	5,2%	881,2
Maio	527,4	547,7	-3,8%	411,9
Junho	549,8	541,6	1,5%	67,9
Julho	542,1	554,8	-2,3%	161,9
Agosto	568,6	562,9	1,0%	31,8
Setembro	572,2	562,9	1,6%	86,5
Outubro	562,6	558,2	0,8%	19,6
Novembro	611,2	584,0	4,5%	741,6
Dezembro	614,7	574,6	6,5%	1.606,4
TOTAL	6.747,6	6.598,8		
EMP			2,1%	
MQE				496,7

Tabela B – 11: Série 36 - Modelo SARIMA
 $(1, 1, 0) \times (1, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	531,3	-0,6%	11,5
Fevereiro	541,6	520,4	3,9%	447,7
Março	553,5	518,0	6,4%	1.263,8
Abril	576,1	538,7	6,5%	1.397,1
Maio	527,4	549,4	-4,2%	485,1
Junho	549,8	525,2	4,5%	607,0
Julho	542,1	535,8	1,2%	39,8
Agosto	568,6	556,1	2,2%	154,4
Setembro	572,2	544,5	4,8%	765,0
Outubro	562,6	526,2	6,5%	1.324,4
Novembro	611,2	569,0	6,9%	1.784,3
Dezembro	614,7	555,1	9,7%	3.546,9
TOTAL	6.747,6	6.469,8		
EMP			4,0%	
MQE				985,6

Tabela B – 12: Série 36 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 0)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	532,2	-0,8%	18,8
Fevereiro	541,6	513,9	5,1%	766,9
Março	553,5	511,2	7,6%	1.790,0
Abril	576,1	547,9	4,9%	798,6
Maio	527,4	543,0	-3,0%	243,1
Junho	549,8	538,0	2,2%	140,3
Julho	542,1	549,2	-1,3%	50,0
Agosto	568,6	547,3	3,7%	450,7
Setembro	572,2	557,7	2,5%	210,8
Outubro	562,6	563,0	-0,1%	0,2
Novembro	611,2	574,4	6,0%	1.357,1
Dezembro	614,7	571,2	7,1%	1.885,0
TOTAL	6.747,6	6.549,0		
EMP			2,8%	
MQE				642,6

Tabela B – 13: Série 36 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 1)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	531,6	-0,7%	13,6
Fevereiro	541,6	514,7	5,0%	723,9
Março	553,5	510,8	7,7%	1.822,0
Abril	576,1	554,5	3,7%	465,7
Maio	527,4	544,6	-3,3%	296,2
Junho	549,8	540,0	1,8%	97,0
Julho	542,1	550,2	-1,5%	66,2
Agosto	568,6	545,4	4,1%	537,0
Setembro	572,2	559,9	2,1%	150,1
Outubro	562,6	571,2	-1,5%	73,7
Novembro	611,2	578,7	5,3%	1.059,3
Dezembro	614,7	572,1	6,9%	1.812,9
TOTAL	6.747,6	6.573,7		
EMP			2,5%	
MQE				593,1

Tabela B – 14: Série 36 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	527,9	539,4	-2,2%	133,4
Fevereiro	541,6	511,0	5,7%	936,6
Março	553,5	512,6	7,4%	1.675,1
Abril	576,1	560,7	2,7%	237,6
Maio	527,4	549,1	-4,1%	469,1
Junho	549,8	526,5	4,2%	542,8
Julho	542,1	483,1	10,9%	3.483,6
Agosto	568,6	498,6	12,3%	4.896,3
Setembro	572,2	512,4	10,4%	3.573,8
Outubro	562,6	531,1	5,6%	991,8
Novembro	611,2	543,0	11,2%	4.647,5
Dezembro	614,7	514,3	16,3%	10.061,9
TOTAL	6.747,6	6.281,9		
EMP			6,7%	
MQE				2.637,4

ANEXO C – PREVISÃO PARA O EXERCÍCIO 2004 – RESULTADOS DA SÉRIE 84

Tabela C – 1: Série 84 - Modelo de Regressão Linear

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	633,8	560,1	11,6%	5.426,0
Fevereiro	621,7	564,7	9,2%	3.253,2
Março	600,8	569,3	5,2%	992,0
Abril	642,6	573,9	10,7%	4.722,5
Mai	632,1	578,4	8,5%	2.877,5
Junho	624,1	583,0	6,6%	1.687,3
Julho	625,3	587,6	6,0%	1.423,6
Agosto	669,5	592,2	11,5%	5.976,5
Setembro	684,5	596,8	12,8%	7.693,9
TOTAL	5.734,3	5.205,9		
EMP			9,1%	
MQE				3.783,6

Tabela C – 2: Série 84 - Modelo de Suavização Exponencial Simples

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	633,8	608,1	4,1%	659,9
Fevereiro	621,7	608,1	2,2%	186,2
Março	600,8	608,1	-1,2%	53,5
Abril	642,6	608,1	5,4%	1.189,5
Mai	632,1	608,1	3,8%	575,6
Junho	624,1	608,1	2,6%	256,2
Julho	625,3	608,1	2,8%	297,3
Agosto	669,5	608,1	9,2%	3.769,9
Setembro	684,5	608,1	11,2%	5.834,9
TOTAL	5.734,3	5.472,7		
EMP			4,4%	
MQE				1.424,8

Tabela C – 3: Série 84 - Modelo de Suavização Exponencial de Holt

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	633,8	609,3	3,9%	600,7
Fevereiro	621,7	616,5	0,8%	26,9
Março	600,8	623,8	-3,8%	531,1
Abril	642,6	631,1	1,8%	131,9
Mai	632,1	638,4	-1,0%	39,6
Junho	624,1	645,6	-3,5%	464,4
Julho	625,3	652,9	-4,4%	761,3
Agosto	669,5	660,2	1,4%	86,3
Setembro	684,5	667,5	2,5%	289,1
TOTAL	5.734,3	5.745,3		
EMP			-0,3%	
MQE				325,7

Tabela C – 4: Série 84 - Modelo de Suavização Exponencial de Winters Multiplicativo

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	633,8	615,5	2,9%	334,7
Fevereiro	621,7	607,2	2,3%	210,9
Março	600,8	620,0	-3,2%	369,6
Abril	642,6	636,6	0,9%	35,9
Mai	632,1	644,9	-2,0%	163,8
Junho	624,1	635,9	-1,9%	138,7
Julho	625,3	648,9	-3,8%	556,6
Agosto	669,5	665,9	0,5%	12,6
Setembro	684,5	674,3	1,5%	104,0
TOTAL	5.734,3	5.749,1		
EMP			-0,3%	
MQE				214,1

Tabela C – 5: Série 84 - Modelo de Suavização Exponencial de Winters Aditivo

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	633,8	610,6	3,7%	538,6
Fevereiro	621,7	609,7	1,9%	145,0
Março	600,8	622,1	-3,6%	456,8
Abril	642,6	635,0	1,2%	57,1
Mai	632,1	639,5	-1,2%	55,3
Junho	624,1	638,6	-2,3%	211,5
Julho	625,3	651,1	-4,1%	663,8
Agosto	669,5	664,0	0,8%	30,4
Setembro	684,5	668,5	2,3%	256,3
TOTAL	5.734,3	5.739,1		
EMP			-0,1%	
MQE				268,3

Tabela C – 6: Série 84 - Modelo de Decomposição

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	633,8	584,0	7,9%	2.475,4
Fevereiro	621,7	541,5	12,9%	6.437,0
Março	600,8	544,1	9,4%	3.214,9
Abril	642,6	587,6	8,5%	3.018,3
Mai	632,1	574,9	9,1%	3.272,9
Junho	624,1	571,4	8,4%	2.777,6
Julho	625,3	573,6	8,3%	2.680,2
Agosto	669,5	575,5	14,0%	8.828,5
Setembro	684,5	590,5	13,7%	8.837,2
TOTAL	5.734,3	5.143,0		
EMP			10,3%	
MQE				4.615,8

Tabela C – 7: Série 84 - Modelo SARIMA
 $(1, 1, 0) \times (0, 0, 1)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	614,7	3,0%	365,3
Fevereiro	621,7	622,3	-0,1%	0,3
Março	600,8	627,4	-4,4%	710,7
Abril	642,6	632,7	1,5%	98,3
Maio	632,1	611,6	3,2%	418,1
Junho	624,1	621,8	0,4%	5,4
Julho	625,3	615,8	1,5%	89,9
Agosto	669,5	623,3	6,9%	2.134,2
Setembro	684,5	626,7	8,4%	3.331,9
TOTAL	5.734,3	5.596,3		
EMP			2,3%	
MQE				794,9

Tabela C – 8: Série 84 - Modelo SARIMA
 $(1, 1, 0) \times (0, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	621,4	1,9%	152,3
Fevereiro	621,7	632,7	-1,8%	120,9
Março	600,8	644,2	-7,2%	1.890,7
Abril	642,6	648,2	-0,9%	31,1
Maio	632,1	628,2	0,6%	15,3
Junho	624,1	641,1	-2,7%	289,9
Julho	625,3	639,5	-2,3%	200,2
Agosto	669,5	671,0	-0,2%	2,3
Setembro	684,5	661,2	3,4%	540,8
TOTAL	5.734,3	5.787,5		
EMP			-1,0%	
MQE				360,4

Tabela C – 9: Série 84 - Modelo SARIMA
 $(1, 1, 0) \times (1, 0, 0)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	618,8	2,4%	225,2
Fevereiro	621,7	628,5	-1,1%	45,8
Março	600,8	635,0	-5,7%	1.169,7
Abril	642,6	648,5	-0,9%	35,7
Maio	632,1	619,7	2,0%	154,4
Junho	624,1	632,9	-1,4%	78,5
Julho	625,3	628,4	-0,5%	9,2
Agosto	669,5	644,0	3,8%	647,7
Setembro	684,5	646,2	5,6%	1.467,0
TOTAL	5.734,3	5.701,9		
EMP			0,5%	
MQE				425,9

Tabela C – 10: Série 84 - Modelo SARIMA
 $(1, 1, 0) \times (1, 0, 1)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	622,5	1,8%	127,7
Fevereiro	621,7	625,2	-0,6%	12,3
Março	600,8	629,1	-4,7%	800,0
Abril	642,6	651,5	-1,4%	80,1
Maio	632,1	628,5	0,6%	12,8
Junho	624,1	637,0	-2,1%	165,4
Julho	625,3	637,8	-2,0%	154,4
Agosto	669,5	651,6	2,7%	318,6
Setembro	684,5	655,0	4,3%	870,0
TOTAL	5.734,3	5.738,1		
EMP			-0,2%	
MQE				282,4

Tabela C – 11: Série 84 - Modelo SARIMA
 $(1, 1, 0) \times (1, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	619,7	2,2%	198,8
Fevereiro	621,7	640,3	-3,0%	343,6
Março	600,8	650,0	-8,2%	2.428,7
Abril	642,6	663,2	-3,2%	427,1
Maio	632,1	637,5	-0,9%	29,3
Junho	624,1	646,9	-3,7%	519,8
Julho	625,3	646,2	-3,3%	435,3
Agosto	669,5	685,2	-2,4%	248,2
Setembro	684,5	676,4	1,2%	65,5
TOTAL	5.734,3	5.865,4		
EMP			-2,4%	
MQE				521,8

Tabela C – 12: Série 84 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 0)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	622,3	1,8%	132,1
Fevereiro	621,7	626,1	-0,7%	19,5
Março	600,8	628,5	-4,6%	769,5
Abril	642,6	652,0	-1,5%	88,2
Maio	632,1	632,0	0,0%	0,0
Junho	624,1	638,8	-2,4%	217,8
Julho	625,3	641,6	-2,6%	265,6
Agosto	669,5	657,6	1,8%	140,1
Setembro	684,5	658,2	3,8%	692,6
TOTAL	5.734,3	5.757,2		
EMP			-0,5%	
MQE				258,4

Tabela C – 13: Série 84 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 1)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	633,8	625,8	1,3%	63,9
Fevereiro	621,7	630,7	-1,4%	80,0
Março	600,8	633,5	-5,5%	1.072,7
Abril	642,6	647,3	-0,7%	22,2
Maio	632,1	631,2	0,1%	0,7
Junho	624,1	642,0	-2,9%	320,6
Julho	625,3	645,8	-3,3%	418,7
Agosto	669,5	664,6	0,7%	24,0
Setembro	684,5	659,1	3,7%	644,7
TOTAL	5.734,3	5.779,9		
EMP			-0,9%	
MQE				294,2

Tabela C – 14: Série 84 – Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	633,8	627,3	1,0%	41,7
Fevereiro	621,7	634,4	-2,0%	161,8
Março	600,8	640,2	-6,6%	1.556,4
Abril	642,6	644,3	-0,3%	3,1
Maio	632,1	624,9	1,1%	51,9
Junho	624,1	636,8	-2,0%	161,3
Julho	625,3	638,4	-2,1%	170,2
Agosto	669,5	658,5	1,6%	121,0
Setembro	684,5	650,7	4,9%	1.142,6
TOTAL	5.734,3	5.755,5		
EMP			-0,5%	
MQE				378,9

ANEXO D – PREVISÃO PARA O EXERCÍCIO 2004 – RESULTADOS DA SÉRIE 48

Tabela D – 1: Série 48 - Modelo de Regressão Linear

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	633,8	593,9	6,3%	1.593,7
Fevereiro	621,7	599,9	3,5%	477,3
Março	600,8	605,9	-0,9%	26,5
Abril	642,6	611,9	4,8%	938,3
Mai	632,1	618,0	2,2%	199,0
Junho	624,1	624,0	0,0%	0,0
Julho	625,3	630,0	-0,8%	22,1
Agosto	669,5	636,1	5,0%	1.117,0
Setembro	684,5	642,1	6,2%	1.796,0
TOTAL	5.734,3	5.561,7		
EMP			2,9%	
MQE				685,5

Tabela D – 2: Série 48 - Modelo de Suavização Exponencial Simples

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	633,8	609,3	3,9%	599,8
Fevereiro	621,7	609,3	2,0%	154,9
Março	600,8	609,3	-1,4%	72,5
Abril	642,6	609,3	5,2%	1.108,4
Mai	632,1	609,3	3,6%	519,6
Junho	624,1	609,3	2,4%	219,3
Julho	625,3	609,3	2,6%	257,4
Agosto	669,5	609,3	9,0%	3.624,3
Setembro	684,5	609,3	11,0%	5.653,5
TOTAL	5.734,3	5.483,5		
EMP			4,2%	
MQE				1.356,6

Tabela D – 3: Série 48 - Modelo de Suavização Exponencial de Holt

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	633,8	612,0	3,4%	472,3
Fevereiro	621,7	619,9	0,3%	3,4
Março	600,8	627,7	-4,5%	727,6
Abril	642,6	635,6	1,1%	48,7
Mai	632,1	643,4	-1,8%	129,3
Junho	624,1	651,3	-4,4%	740,2
Julho	625,3	659,1	-5,4%	1.144,1
Agosto	669,5	667,0	0,4%	6,2
Setembro	684,5	674,9	1,4%	92,5
TOTAL	5.734,3	5.791,0		
EMP			-1,1%	
MQE				373,8

Tabela D – 4: Série 48 - Modelo de Suavização Exponencial de Winters Multiplicativo

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	633,8	611,7	3,5%	488,3
Fevereiro	621,7	604,6	2,8%	294,2
Março	600,8	618,5	-3,0%	315,3
Abril	642,6	639,1	0,5%	12,0
Mai	632,1	639,9	-1,2%	61,5
Junho	624,1	632,2	-1,3%	65,4
Julho	625,3	646,4	-3,4%	445,9
Agosto	669,5	667,6	0,3%	3,4
Setembro	684,5	668,2	2,4%	265,8
TOTAL	5.734,3	5.728,2		
EMP			0,1%	
MQE				216,9

Tabela D – 5: Série 48 - Modelo de Suavização Exponencial de Winters Aditivo

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	633,8	608,8	3,9%	622,8
Fevereiro	621,7	607,2	2,3%	212,0
Março	600,8	620,7	-3,3%	399,3
Abril	642,6	636,7	0,9%	34,9
Mai	632,1	637,0	-0,8%	23,8
Junho	624,1	635,3	-1,8%	125,7
Julho	625,3	648,9	-3,8%	555,1
Agosto	669,5	664,8	0,7%	21,9
Setembro	684,5	665,1	2,8%	375,7
TOTAL	5.734,3	5.724,4		
EMP			0,1%	
MQE				263,5

Tabela D – 6: Série 48 - Modelo de Decomposição

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P)²
Janeiro	633,8	619,9	2,2%	191,4
Fevereiro	621,7	588,3	5,4%	1.119,9
Março	600,8	589,4	1,9%	128,9
Abril	642,6	635,3	1,1%	52,3
Mai	632,1	618,1	2,2%	196,1
Junho	624,1	615,4	1,4%	75,7
Julho	625,3	628,2	-0,5%	8,4
Agosto	669,5	628,2	6,2%	1.701,2
Setembro	684,5	640,6	6,4%	1.923,3
TOTAL	5.734,3	5.563,5		
EMP			2,9%	
MQE				599,7

Tabela D – 7: Série 48 - Modelo SARIMA
 $(1, 1, 0) \times (0, 0, 1)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	614,0	3,1%	391,0
Fevereiro	621,7	628,7	-1,1%	48,3
Março	600,8	637,4	-6,1%	1.343,4
Abril	642,6	645,2	-0,4%	7,1
Maiο	632,1	605,2	4,3%	724,5
Junho	624,1	624,0	0,0%	0,0
Julho	625,3	616,1	1,5%	84,3
Agosto	669,5	621,5	7,2%	2.305,9
Setembro	684,5	632,2	7,6%	2.732,0
TOTAL	5.734,3	5.624,3		
EMP			1,8%	
MQE				848,5

Tabela D – 8: Série 48 - Modelo SARIMA
 $(1, 1, 0) \times (0, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	614,0	3,1%	389,9
Fevereiro	621,7	628,9	-1,2%	51,9
Março	600,8	637,9	-6,2%	1.376,3
Abril	642,6	645,8	-0,5%	10,6
Maiο	632,1	605,0	4,3%	732,3
Junho	624,1	624,2	0,0%	0,0
Julho	625,3	606,4	3,0%	359,5
Agosto	669,5	615,0	8,1%	2.965,3
Setembro	684,5	624,9	8,7%	3.547,6
TOTAL	5.734,3	5.602,1		
EMP			2,2%	
MQE				1.048,2

Tabela D – 9: Série 48 - Modelo SARIMA
 $(1, 1, 0) \times (1, 0, 0)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	619,1	2,3%	214,6
Fevereiro	621,7	628,6	-1,1%	46,7
Março	600,8	635,1	-5,7%	1.181,2
Abril	642,6	648,6	-0,9%	36,4
Maiο	632,1	619,8	1,9%	149,5
Junho	624,1	633,1	-1,4%	80,8
Julho	625,3	628,5	-0,5%	10,2
Agosto	669,5	644,1	3,8%	643,1
Setembro	684,5	646,3	5,6%	1.460,6
TOTAL	5.734,3	5.703,2		
EMP			0,4%	
MQE				424,8

Tabela D – 10: Série 48 - Modelo SARIMA
 $(1, 1, 0) \times (1, 0, 1)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	618,9	2,3%	221,4
Fevereiro	621,7	629,9	-1,3%	66,4
Março	600,8	637,6	-6,1%	1.354,8
Abril	642,6	650,4	-1,2%	61,5
Maiο	632,1	618,1	2,2%	194,0
Junho	624,1	633,4	-1,5%	86,0
Julho	625,3	627,2	-0,3%	3,7
Agosto	669,5	643,7	3,8%	662,4
Setembro	684,5	646,4	5,6%	1.448,4
TOTAL	5.734,3	5.705,7		
EMP			0,4%	
MQE				455,4

Tabela D – 11: Série 48 - Modelo SARIMA
 $(1, 1, 0) \times (1, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	621,0	2,0%	162,3
Fevereiro	621,7	638,4	-2,7%	278,0
Março	600,8	646,7	-7,6%	2.111,0
Abril	642,6	658,9	-2,5%	266,3
Maiο	632,1	626,9	0,8%	26,5
Junho	624,1	631,2	-1,1%	50,7
Julho	625,3	626,1	-0,1%	0,6
Agosto	669,5	656,4	2,0%	172,0
Setembro	684,5	649,6	5,1%	1.217,9
TOTAL	5.734,3	5.755,2		
EMP			-0,5%	
MQE				476,2

Tabela D – 12: Série 48 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 0)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R - P) ²
Janeiro	633,8	618,4	2,4%	236,8
Fevereiro	621,7	630,4	-1,4%	75,0
Março	600,8	638,8	-6,3%	1.443,6
Abril	642,6	650,1	-1,2%	56,3
Maiο	632,1	616,3	2,5%	248,0
Junho	624,1	632,6	-1,4%	72,6
Julho	625,3	625,3	0,0%	0,0
Agosto	669,5	642,0	4,1%	754,9
Setembro	684,5	644,8	5,8%	1.572,5
TOTAL	5.734,3	5.698,7		
EMP			0,5%	
MQE				495,5

Tabela D – 13: Série 48 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 1)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	633,8	619,7	2,2%	198,8
Fevereiro	621,7	630,1	-1,3%	70,2
Março	600,8	637,4	-6,1%	1.339,6
Abril	642,6	652,3	-1,5%	95,1
Maio	632,1	620,5	1,8%	133,8
Junho	624,1	635,1	-1,8%	122,1
Julho	625,3	630,1	-0,8%	22,9
Agosto	669,5	647,4	3,3%	487,5
Setembro	684,5	649,8	5,1%	1.205,3
TOTAL	5.734,3	5.722,4		
EMP			0,1%	
MQE				408,4

Tabela D – 14: Série 48 - Modelo SARIMA
 $(1, 1, 0) \times (2, 0, 2)_{12}$

Mês	Realizado (R)	Previsto (P)	(R-P)/R	(R – P) ²
Janeiro	633,8	625,8	1,3%	63,6
Fevereiro	621,7	629,9	-1,3%	66,5
Março	600,8	622,2	-3,6%	457,9
Abril	642,6	660,7	-2,8%	329,7
Maio	632,1	659,2	-4,3%	738,2
Junho	624,1	599,9	3,9%	586,3
Julho	625,3	575,3	8,0%	2.498,8
Agosto	669,5	606,0	9,5%	4.036,3
Setembro	684,5	599,3	12,4%	7.256,3
TOTAL	5.734,3	5.578,3		
EMP			2,6%	
MQE				1.781,5